

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

MASTER UNIVERSITARIO EN ANALISIS DE DATOS MASIVOS (BIG DATA)

TRABAJO FIN DE MÁSTER

Análisis del mercado laboral y predicción de los cambios provocados por la Inteligencia Artificial mediante técnicas de Big Data

Pedro Ariznavarreta Mayado

Dirigido por

Carlos Jaime Pages Ogilvie

CURSO 2025-2026

TÍTULO: Análisis del mercado laboral y predicción de los cambios provocados por la Inteligencia Artificial mediante técnicas de Big Data

AUTOR: Pedro Ariznavarreta Mayado

TITULACIÓN: MASTER BIG DATA

DIRECTOR/ES DEL PROYECTO: Ingeniero Carlos Jaime Pages Ogilvie

FECHA: SEPTEIMBRE de 2026

RESUMEN

Este Trabajo de Fin de Máster analiza la evolución del mercado laboral español y su relación con la exposición ocupacional a la inteligencia artificial mediante técnicas de integración de datos, análisis exploratorio y modelización predictiva. El estudio parte de la consideración de que la inteligencia artificial no debe entenderse únicamente como un posible factor de sustitución laboral, sino también como una tecnología capaz de complementar tareas, modificar las competencias requeridas y transformar el contenido de las ocupaciones.

La investigación integra datos trimestrales de la Encuesta de Población Activa del Instituto Nacional de Estadística con indicadores de exposición ocupacional procedentes de AIOE y del Anthropic Economic Index. Como resultado, se construyó un panel compuesto por diez grandes grupos ocupacionales y 61 trimestres, desde 2011T1 hasta 2026T1, con un total de 610 observaciones. El conjunto de datos incorpora información sobre empleo, variaciones trimestrales e interanuales, exposición general a la inteligencia artificial, exposición específica a modelos de lenguaje y categorías agregadas de exposición ocupacional.

Sobre este panel se compararon ocho enfoques predictivos: persistencia trimestral, crecimiento cero, regresión lineal, Ridge, Elastic Net, Random Forest, Gradient Boosting y un ensemble ponderado. La evaluación se realizó mediante un esquema de backtesting walk-forward, respetando el orden temporal de las observaciones. Random Forest obtuvo el mejor resultado fuera de muestra, con un RMSE de 2,393, un MAE de 1,874 y un R^2 de 0,143, lo que supone una mejora del 9,41 % en RMSE respecto al baseline de crecimiento cero. A partir de estos resultados, los escenarios futuros se generaron mediante un ensemble ponderado de Random Forest, Gradient Boosting y Ridge, con el objetivo de combinar capacidad predictiva, estabilidad y diversidad metodológica. Debido a la capacidad explicativa moderada de los modelos, las predicciones deben interpretarse como estimaciones exploratorias sujetas a incertidumbre y no como relaciones causales atribuibles a la inteligencia artificial.

Los resultados muestran que los grupos técnicos, profesionales, directivos y administrativos concentran una mayor exposición potencial a la inteligencia artificial, mientras que determinados perfiles manuales y agrarios presentan niveles inferiores. Sin embargo, una exposición elevada puede coexistir con una evolución positiva del empleo, por lo que estos indicadores no deben interpretarse como medidas directas de sustitución laboral o pérdida de puestos de trabajo.

Finalmente, se desarrolló una aplicación web destinada al análisis exploratorio de los datos y un cuadro de mando interactivo en Power BI para presentar la evolución histórica, comparar el rendimiento de los modelos y explorar los escenarios predictivos y los niveles de riesgo estimados. En conjunto, el proyecto proporciona una base analítica reproducible para estudiar la relación entre empleo, exposición tecnológica y transformación ocupacional en España.

Los conceptos clave son:

1. Inteligencia artificial generativa

2. Exposición ocupacional a IA

3. Mercado laboral español

4. Integración de datos

5. Análisis predictivo

6. Transformación del empleo

ABSTRACT

This Master's Thesis analyses the evolution of the Spanish labour market and its relationship with occupational exposure to artificial intelligence through data integration, exploratory data analysis, and predictive modelling techniques. The study is based on the premise that artificial intelligence should not be understood exclusively as a potential driver of job substitution, but also as a technology capable of complementing tasks, modifying skill requirements, and transforming the content of occupations.

The research integrates quarterly data from the Spanish Labour Force Survey, published by the Spanish National Statistics Institute, with occupational exposure indicators obtained from AIOE and the Anthropic Economic Index. This integration produced a panel dataset comprising ten major occupational groups and 61 quarters, from 2011Q1 to 2026Q1, with a total of 610 observations. The dataset includes information on employment, quarterly and year-on-year changes, general exposure to artificial intelligence, specific exposure to language models, and aggregated occupational exposure categories.

Eight predictive approaches were compared using this panel: quarterly persistence, zero growth, linear regression, Ridge, Elastic Net, Random Forest, Gradient Boosting, and a weighted ensemble. The models were evaluated through a walk-forward backtesting procedure that preserved the temporal order of the observations. Random Forest achieved the best out-of-sample performance, with an RMSE of 2.393, an MAE of 1.874, and an R^2 of 0.143, representing a 9.41% improvement in RMSE over the zero-growth baseline. Based on these results, future scenarios were generated using a weighted ensemble of Random Forest, Gradient Boosting, and Ridge to combine predictive performance, stability, and methodological diversity. Given the models' moderate explanatory power, the forecasts should be interpreted as exploratory estimates subject to uncertainty rather than as evidence of causal effects attributable to artificial intelligence.

The results show that technical, professional, managerial, and administrative occupational groups exhibit higher levels of potential exposure to artificial intelligence, whereas certain manual and agricultural profiles present lower levels. Nevertheless, high exposure may coexist with positive employment trends. Therefore, these indicators should not be interpreted as direct measures of job substitution or job losses.

Finally, a web application was developed for exploratory data analysis, together with an interactive Power BI dashboard designed to present historical trends, compare model performance, and explore predictive scenarios and estimated risk levels. Overall, the project provides a reproducible analytical foundation for studying the relationship between employment, technological exposure, and occupational transformation in Spain.

Keywords:

1. Generative Artificial Intelligence

2. Occupational Exposure to AI

3. Spanish Labor Market

4. Data Integration

5. Predictive Analytics

6. Employment Transformation

TABLA RESUMEN

	DATOS
Nombre y apellidos:	Pedro Ariznavarreta Mayado
Título del proyecto:	Análisis del mercado laboral y predicción de los cambios provocados por la Inteligencia Artificial mediante técnicas de Big Data
Directores del proyecto:	Carlos Jaime Pages Ogilvie
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa:	NO
El proyecto ha implementado un producto: (esta entrada se puede marcar junto a la siguiente)	SI
El proyecto ha consistido en el desarrollo de una investigación o innovación: (esta entrada se puede marcar junto a la anterior)	SI
Objetivo general del proyecto:	Analizar la evolución del mercado laboral español y su relación con la exposición ocupacional a la inteligencia artificial mediante la integración y el análisis de datos, la comparación de diferentes modelos predictivos y el desarrollo de herramientas interactivas para la exploración y visualización de los resultados.

Índice

RESUMEN 3

ABSTRACT 5

TABLA RESUMEN 7

Capítulo 1. INTRODUCCIÓN 12

1.1 Contexto y justificación 12

1.2 Planteamiento del problema 12

1.3 Objetivos del proyecto 13

1.4 Resultados obtenidos 14

1.5 Estructura de la memoria 14

Capítulo 2. MARCO TEÓRICO 16

2.1 Estado del arte 16

2.2 Contexto y justificación 18

2.3 Planteamiento del problema 19

Capítulo 3. OBJETIVOS 21

3.1 Objetivos generales 21

3.2 Objetivos específicos 21

3.3 Beneficios del proyecto 22

Capítulo 4. DESARROLLO DEL PROYECTO 24

4.1 Planificación del proyecto 24

4.2 Descripción de la solución, metodologías y herramientas empleadas 42

4.3 Recursos requeridos 74

4.4 Presupuesto 75

4.5 Viabilidad 76

4.6 Resultados del proyecto 77

Capítulo 5. DISCUSIÓN 89

Capítulo 6. CONCLUSIONES 93

6.1 Conclusiones del trabajo 93

6.2 Conclusiones personales 94

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO 96

Capítulo 8. REFERENCIAS 98

Capítulo 9. ANEXOS 100

Índice de Figuras

1. Cronograma mensual de las actividades del proyecto.....42
2. Arquitectura general y flujo de procesamiento de la solución.....43
3. Estructura de directorios y organización de archivos del proyecto.....44
4. Estructura conceptual del panel analítico integrado.....60
5. Página de resumen ejecutivo del dashboard desarrollado en Power BI.....79
6. Página de predicción y riesgo del dashboard desarrollado en Power BI.....83
7. Pantalla principal y guía de interpretación del dashboard web.....84
8. Visualizaciones de exposición a la IA y evolución del empleo en el dashboard web.....84
9. Página de análisis histórico del empleo del dashboard desarrollado en Power BI.....86
10. Página de predicción y riesgo del dashboard desarrollado en Power BI.....87

Índice de Tablas

1. Comparación del rendimiento fuera de muestra.....34
2. Fases, actividades y resultados de la planificación del proyecto.....41
3. Herramientas y tecnologías utilizadas en el proyecto.....46
4. Fuentes de datos y archivos originales incorporados al proyecto.....50
5. Correspondencia agregada entre los grandes grupos CNO-11 y SOC.....56
6. Variables principales del panel analítico integrado.....60
7. Comparación del rendimiento fuera de muestra de los modelos.....68
8. Recursos tecnológicos y fuentes de datos utilizados en el proyecto 75
9. Estimación de costes y recursos empleados en el proyecto 76
10. Distribución del empleo por categoría de exposición a la IA en 2026T1.....78
11. Rendimiento fuera de muestra de los modelos predictivos.....80
12. Principales predicciones de crecimiento e indicador empírico de contracción en T+1.....81
13. Evolución agregada prevista del empleo entre 2026T2 y 2028T1.....82

Capítulo 1. INTRODUCCIÓN

1.1 Contexto y justificación

La inteligencia artificial se ha consolidado como uno de los principales factores de transformación económica y organizativa de los últimos años. Aunque la automatización lleva décadas modificando los procesos productivos, la expansión de la inteligencia artificial generativa desde finales de 2022 ha ampliado notablemente el conjunto de tareas potencialmente afectadas. Su alcance ya no se limita a actividades rutinarias o repetitivas, sino que comprende tareas cognitivas, administrativas, documentales, analíticas y comunicativas presentes en el trabajo cotidiano de numerosos perfiles profesionales (OECD, 2023).[1]

Este cambio resulta especialmente relevante para el mercado laboral, ya que puede modificar tanto la demanda de competencias como la organización del trabajo. La literatura señala que la inteligencia artificial no debe interpretarse únicamente como una tecnología de sustitución, sino también como una herramienta capaz de complementar las capacidades humanas, aumentar la productividad y transformar las ocupaciones sin hacerlas desaparecer por completo (Acemoglu y Restrepo, 2018).[2] Por ello, el análisis de su relación con el empleo requiere una aproximación empírica que combine la evolución del mercado laboral con indicadores de exposición ocupacional a la inteligencia artificial.

En España, esta cuestión adquiere un interés adicional debido a la estructura del mercado laboral, el peso del sector servicios, la distribución desigual de la digitalización y la persistencia de determinados desequilibrios estructurales. Según la Encuesta de Población Activa del Instituto Nacional de Estadística, en el primer trimestre de 2026 España registró aproximadamente 22.293.000 personas ocupadas y una tasa de paro del 10,83 %.[3] Estos datos reflejan la dimensión de un mercado laboral amplio y dinámico, aunque todavía condicionado por distintas tensiones estructurales.

Este Trabajo de Fin de Máster se justifica, por tanto, por una doble razón. Desde el punto de vista académico, conecta la literatura sobre automatización, inteligencia artificial y empleo con una aplicación específica al mercado laboral español. Desde una perspectiva práctica, aporta un conjunto de datos integrado, una comparación sistemática de diferentes modelos predictivos, un procedimiento exploratorio para generar escenarios futuros y dos herramientas interactivas de visualización. La aplicación web se destina al análisis exploratorio de los datos, mientras que el cuadro de mando desarrollado en Power BI permite examinar la evolución histórica, comparar el rendimiento de los modelos y explorar los escenarios predictivos y los niveles de riesgo estimados.

1.2 Planteamiento del problema

El problema central del proyecto consiste en determinar cómo puede analizarse la relación entre la exposición ocupacional a la inteligencia artificial y la evolución del mercado laboral español a partir de datos observados de empleo. La cuestión no es trivial, ya que la evidencia académica e institucional señala que la IA puede producir efectos heterogéneos: en algunos casos, puede

desplazar determinadas tareas; en otros, puede mejorar la productividad, reorganizar el contenido del trabajo o favorecer la aparición de nuevas funciones laborales (Gmyrek, Berg y Bescond, 2023).[4]

La exposición a la inteligencia artificial no equivale automáticamente a destrucción de empleo. Una ocupación altamente expuesta puede experimentar la automatización o desaparición de determinadas tareas, pero también puede verse reforzada mediante herramientas de asistencia, procesos de automatización parcial o aumentos de eficiencia. En consecuencia, el problema no puede abordarse mediante afirmaciones generales sobre tecnología y empleo, sino a través de un análisis que relacione grupos ocupacionales, series temporales e indicadores de exposición.

En el contexto español existe, además, una dificultad metodológica: los datos laborales oficiales se organizan mediante la Clasificación Nacional de Ocupaciones de 2011 (CNO-11), mientras que muchas métricas internacionales de exposición a la inteligencia artificial se construyen a partir de clasificaciones como SOC u O*NET. Esta diferencia obliga a realizar procesos de correspondencia, agregación, limpieza e integración de datos. Dichos procesos deben quedar documentados y justificados para garantizar la trazabilidad de las transformaciones, reconocer las posibles pérdidas de información y facilitar la reproducibilidad del análisis.

En este marco, la pregunta principal del TFM puede formularse del siguiente modo: ¿qué grandes grupos ocupacionales del mercado laboral español presentan una mayor exposición potencial a la inteligencia artificial, cómo ha evolucionado su empleo y en qué medida pueden utilizarse los patrones observados para generar predicciones exploratorias sobre su evolución futura? Esta pregunta orienta el trabajo hacia la construcción de una base analítica sólida, la comparación de diferentes enfoques predictivos y el examen de las relaciones entre empleo, exposición ocupacional y tecnología, sin asumir de antemano un efecto causal o unidireccional de la inteligencia artificial sobre el trabajo.

1.3 Objetivos del proyecto

El proyecto tiene como finalidad estudiar la evolución del mercado laboral español y su relación con la exposición ocupacional a la inteligencia artificial mediante la integración de datos laborales, indicadores internacionales y técnicas de Big Data. Para ello, se construye una base analítica reproducible, se examinan los patrones históricos del empleo por grandes grupos ocupacionales y se comparan distintos modelos predictivos para generar estimaciones exploratorias sobre su posible evolución futura. El trabajo se completa con una aplicación web destinada al análisis exploratorio y un cuadro de mando en Power BI para comunicar los resultados históricos, la evaluación de los modelos y los escenarios predictivos. Todo el análisis se plantea desde una perspectiva asociativa y exploratoria, sin atribuir a la inteligencia artificial un efecto causal directo sobre el empleo.

1.4 Resultados obtenidos

El proyecto ha generado un conjunto de datos integrado que relaciona el empleo de los diez grandes grupos ocupacionales de la CNO-11 con indicadores de exposición a la inteligencia artificial procedentes de AIOE y del Anthropic Economic Index. El panel resultante contiene 610 observaciones correspondientes a 61 trimestres, desde 2011T1 hasta 2026T1, e incorpora variables de empleo, crecimiento trimestral e interanual, percentiles y categorías agregadas de exposición. A partir de este panel se generaron, además, diferentes resultados derivados del proceso de modelización, como predicciones, métricas de evaluación e indicadores exploratorios de riesgo.

Sobre este conjunto de datos se compararon ocho enfoques predictivos: persistencia trimestral, crecimiento cero, regresión lineal, Ridge, Elastic Net, Random Forest, Gradient Boosting y un ensemble ponderado. La evaluación fuera de muestra se realizó mediante un procedimiento de backtesting walk-forward. Random Forest obtuvo el mejor rendimiento, con un RMSE de 2,393, un MAE de 1,874 y un R^2 de 0,143, lo que representa una mejora del 9,41 % en RMSE respecto al baseline de crecimiento cero. El ensemble ponderado obtuvo un RMSE de 2,429 y se utilizó para generar los escenarios futuros debido a su capacidad para combinar el comportamiento de Random Forest, Gradient Boosting y Ridge.

Aunque los modelos de aprendizaje automático mejoraron los resultados de los enfoques de referencia, su capacidad explicativa continuó siendo moderada. Por este motivo, las predicciones se interpretan como estimaciones exploratorias sujetas a incertidumbre y no como evidencia causal del efecto de la inteligencia artificial sobre el empleo. Los indicadores de riesgo elaborados a partir de estas predicciones tampoco representan probabilidades causales de desaparición de puestos de trabajo.

Finalmente, se desarrollaron dos herramientas complementarias de visualización. La aplicación web permite realizar un análisis exploratorio mediante indicadores descriptivos, comparaciones ocupacionales, evolución temporal y una tabla de datos filtrable. Por su parte, el cuadro de mando de Power BI está compuesto por cuatro páginas dedicadas al resumen ejecutivo, el análisis histórico del empleo, la comparación y evaluación de los modelos predictivos, y la predicción exploratoria y el riesgo ocupacional. En conjunto, estos productos proporcionan una base empírica y reproducible para analizar patrones laborales, comparar grupos ocupacionales y explorar posibles tendencias futuras sin interpretar la exposición a la inteligencia artificial como una estimación directa de destrucción de empleo.

1.5 Estructura de la memoria

La memoria sigue la estructura establecida en la plantilla del Trabajo de Fin de Máster. El primer capítulo introduce el proyecto y presenta su contexto, el problema de investigación, los objetivos y una síntesis de los principales resultados obtenidos. El segundo capítulo desarrolla los antecedentes y el estado del arte mediante una revisión de la literatura sobre automatización, inteligencia artificial, exposición ocupacional, productividad, competencias y mercado laboral.

El tercer capítulo expone los objetivos generales y específicos del trabajo, así como sus beneficios metodológicos, analíticos, prácticos y académicos. El cuarto capítulo describe el desarrollo del proyecto, incluyendo su planificación, las fuentes de información utilizadas, el proceso de adquisición, limpieza e integración de los datos, el análisis exploratorio, la construcción y comparación de los modelos predictivos, el procedimiento de validación temporal y el desarrollo de las herramientas de visualización.

Los capítulos posteriores presentan los resultados obtenidos y su discusión, prestando especial atención al rendimiento comparado de los modelos, la incertidumbre asociada a las predicciones y la distinción entre exposición ocupacional, riesgo estimado y efectos causales. A continuación, se recogen las principales conclusiones del estudio y las posibles líneas de trabajo futuro. Finalmente, la memoria incluye las referencias bibliográficas y los anexos técnicos, en los que se incorpora documentación complementaria sobre los datos, el código, los resultados de la modelización, las visualizaciones y la reproducibilidad del proyecto.

Capítulo 2. MARCO TEÓRICO

2.1 Estado del arte

La relación entre tecnología y empleo constituye una de las cuestiones centrales de la economía laboral contemporánea. Durante décadas, el debate sobre la automatización se ha centrado en determinar si las innovaciones tecnológicas destruyen empleo, lo transforman o crean nuevas oportunidades laborales. La evidencia acumulada muestra que la respuesta no es lineal: los cambios tecnológicos pueden desplazar determinadas tareas, pero también generar aumentos de productividad, nuevas ocupaciones y diferentes formas de complementar el trabajo humano (Acemoglu y Restrepo, 2018).[2]

Uno de los enfoques más influyentes es el propuesto por Autor, quien sostiene que los análisis simplistas tienden a sobrestimar la sustitución directa de trabajadores y a infravalorar la capacidad de la tecnología para complementar las habilidades humanas (Autor, 2015).[5] Desde esta perspectiva, las máquinas y los sistemas automatizados sustituyen con mayor facilidad las tareas rutinarias, predecibles y codificables, mientras que las personas conservan ventajas relativas en ámbitos como la resolución de problemas, la adaptabilidad, el juicio contextual, la creatividad y la interacción social.

Acemoglu y Restrepo amplían este planteamiento mediante un marco basado en tareas, según el cual la automatización puede reducir la demanda de trabajo en determinadas funciones, pero también elevar la productividad global y generar nuevas tareas en las que el trabajo humano continúe siendo necesario (Acemoglu y Restrepo, 2018).[2] Esta perspectiva resulta especialmente útil para interpretar los posibles efectos de la inteligencia artificial, ya que evita asumir que su adopción conduce automáticamente a una reducción neta del empleo.

La aparición y difusión de la inteligencia artificial generativa ha desplazado parcialmente el foco de la automatización desde tareas principalmente manuales o repetitivas hacia tareas cognitivas, informacionales y vinculadas con la producción de conocimiento. Los grandes modelos de lenguaje pueden intervenir en actividades de redacción, programación, síntesis documental, análisis de información, atención al cliente o apoyo a la toma de decisiones. Esto amplía la exposición potencial de las ocupaciones administrativas, técnicas y profesionales (Eloundou et al., 2023).[6]

El trabajo de Eloundou, Manning, Mishkin y Rock constituye una referencia clave en este nuevo escenario. Sus resultados indican que una proporción relevante de la población ocupada podría tener al menos una parte de sus tareas afectada por los grandes modelos de lenguaje y que la exposición potencial aumenta cuando estos se combinan con otras herramientas de software (Eloundou et al., 2023).[6] La aportación central del estudio consiste en medir la exposición por tareas, en lugar de asumir la sustitución completa de las ocupaciones, lo que resulta metodológicamente coherente con la literatura económica basada en el contenido del trabajo.

La Organización Internacional del Trabajo señala que el efecto predominante de la IA generativa será previsiblemente la transformación y ampliación de las tareas, en lugar de la automatización

completa de las ocupaciones (Gmyrek, Berg y Bescond, 2023).[4] No obstante, la organización identifica una exposición especialmente elevada en los trabajos administrativos y de oficina, así como posibles efectos diferenciales por género debido a la concentración femenina en determinadas ocupaciones de carácter administrativo.

La OCDE, por su parte, advierte que todavía no existe evidencia concluyente de una reducción generalizada de la demanda de empleo causada por la inteligencia artificial, aunque reconoce que la velocidad de avance de la IA generativa puede modificar la naturaleza del trabajo, la calidad del empleo y las competencias requeridas en numerosas actividades económicas (OECD, 2023).[1] Esta cautela institucional refuerza la necesidad de abordar el problema mediante datos y de evitar interpretaciones deterministas.

Una línea de investigación especialmente relevante para este TFM es la construcción de métricas de exposición ocupacional a la inteligencia artificial. En este campo destaca el indicador AIOE desarrollado por Felten, Raj y Seamans, que relaciona las capacidades de la inteligencia artificial con las ocupaciones y habilidades para estimar su exposición relativa (Felten, Raj y Seamans, 2021).[7] Este tipo de indicador resulta útil para los estudios laborales porque permite relacionar la exposición tecnológica con variables como el empleo, los salarios, los sectores económicos o las características ocupacionales.

Frente a estas medidas de exposición potencial, el Anthropic Economic Index aporta una perspectiva basada en patrones observados de utilización de inteligencia artificial. Su metodología analiza de forma agregada y con mecanismos de protección de la privacidad las interacciones con Claude, y las relaciona con tareas y ocupaciones definidas en O*NET. Esta fuente permite distinguir entre la capacidad teórica de la tecnología y su utilización efectiva, así como analizar en qué medida las interacciones presentan un carácter de automatización o de colaboración entre la persona y el sistema (Handa et al., 2025).[8] La combinación de AIOE y del Anthropic Economic Index permite, por tanto, incorporar al estudio dos perspectivas complementarias: exposición potencial y uso observado.

Asimismo, la Comisión Europea, a través del Joint Research Centre, ha desarrollado una metodología que relaciona tareas laborales, capacidades cognitivas y avances de la inteligencia artificial para estimar su impacto ocupacional. Sus resultados apuntan a una mayor exposición en profesiones asociadas con la comprensión, la búsqueda de información y el razonamiento abstracto, frente a trabajos de carácter predominantemente manual o físico (Tolan et al., 2021).[9] Esta conclusión es coherente con los patrones observados en la literatura sobre IA generativa y refuerza la utilidad de los análisis comparativos por ocupación.

La evidencia empírica sobre productividad también permite contextualizar el problema. Noy y Zhang muestran que el uso de ChatGPT en tareas profesionales de escritura puede reducir el tiempo necesario para completarlas y mejorar la calidad de los resultados (Noy y Zhang, 2023).[10] Del mismo modo, Brynjolfsson, Li y Raymond documentan aumentos de productividad en actividades de atención al cliente mediante un asistente conversacional, con beneficios más intensos para los trabajadores menos experimentados (Brynjolfsson, Li y Raymond, 2023).[11] En ambos casos, la inteligencia artificial aparece como una tecnología de asistencia capaz de

reorganizar tareas y elevar el rendimiento, más que como una herramienta de sustitución completa del empleo.

En el ámbito de las competencias, el World Economic Forum identifica la inteligencia artificial, el big data, la automatización y la digitalización como algunos de los principales motores de transformación del empleo hacia 2030 (World Economic Forum, 2025).[12] El informe destaca tanto el crecimiento esperado de los perfiles técnicos y digitales como la importancia sostenida de habilidades transversales, entre ellas el pensamiento analítico, la resiliencia, la creatividad, la capacidad de aprendizaje y el liderazgo.

En Europa, Cedefop aporta una perspectiva complementaria mediante previsiones de empleo, ocupaciones y cualificaciones hasta 2035 (Cedefop, 2025).[13] Estas previsiones resultan útiles para enmarcar el caso español en un contexto más amplio de transición digital y recualificación laboral. En España, informes como los elaborados por Randstad Research señalan que la inteligencia artificial puede generar oportunidades en sectores tecnológicos y profesionales, aunque también puede aumentar la presión sobre las tareas rutinarias presentes en el comercio, la administración y los servicios (Randstad Research, 2024).[14]

Desde el punto de vista predictivo, la heterogeneidad de los efectos laborales y la naturaleza temporal de los datos desaconsejan depender de un único algoritmo. La comparación entre modelos de referencia, regresiones regularizadas, métodos no lineales y combinaciones de modelos permite evaluar si el aumento de complejidad produce una mejora real fuera de muestra. Asimismo, la validación debe respetar el orden cronológico de los datos para evitar que información futura intervenga en el entrenamiento de observaciones anteriores. (Hyndman y Athanasopoulos, 2021).[15] Esta necesidad justifica el uso posterior de un procedimiento de backtesting walk-forward y la comparación mediante métricas homogéneas de error y capacidad explicativa.

En conjunto, el estado del arte permite identificar una brecha concreta de investigación. Existen numerosos estudios internacionales sobre exposición a la inteligencia artificial y transformación del trabajo, pero continúa siendo necesario aplicar estas métricas y marcos conceptuales al mercado laboral español mediante datos actualizados, series históricas, procedimientos de validación temporal y una metodología reproducible de integración de fuentes. Este TFM se inscribe precisamente en esa necesidad, combinando indicadores de exposición potencial y uso observado con datos laborales españoles y distintos enfoques de modelización predictiva.

2.2 Contexto y justificación

El contexto del proyecto viene determinado por la convergencia de dos procesos. Por un lado, el mercado laboral español ha mostrado una evolución positiva de la ocupación durante los últimos años, aunque mantiene debilidades estructurales como una tasa de paro superior a la media europea, brechas asociadas a la edad y al género, y una adaptación tecnológica desigual entre sectores y empresas. Por otro lado, la inteligencia artificial generativa se está incorporando progresivamente a herramientas empresariales, flujos documentales, procesos de atención al cliente, análisis de datos, generación de contenidos y sistemas de apoyo a la gestión del conocimiento (Instituto Nacional de Estadística, 2026; European Commission, 2025).[16]

La justificación del proyecto es, por tanto, doble. En el ámbito académico, el TFM permite aplicar técnicas de integración, análisis exploratorio y modelización predictiva a un problema de actualidad situado en la intersección entre economía laboral, transformación digital y ciencia de datos. Desde una perspectiva práctica, el trabajo permite identificar los grupos ocupacionales que presentan una mayor exposición potencial a la inteligencia artificial, analizar la evolución histórica de su empleo y explorar posibles tendencias futuras. Esta información puede aportar evidencia útil para orientar iniciativas de formación, recualificación y orientación profesional, aunque no permite determinar efectos causales de la inteligencia artificial sobre el empleo.

La aportación diferencial del enfoque reside en la combinación de datos oficiales del mercado laboral español con indicadores internacionales de exposición potencial y utilización observada de inteligencia artificial. Esta integración permite trasladar el debate general sobre si la IA destruirá o creará empleo hacia un análisis más concreto basado en grupos ocupacionales, periodos temporales y patrones observables. Además, el proyecto incorpora una dimensión metodológica relevante mediante la construcción de un proceso reproducible de adquisición, limpieza, transformación, correspondencia e integración de fuentes heterogéneas.

El trabajo también incorpora una comparación sistemática de diferentes enfoques predictivos, desde modelos de referencia y regresiones regularizadas hasta algoritmos de aprendizaje automático y un ensemble ponderado. Su evaluación mediante backtesting walk-forward permite analizar el rendimiento fuera de muestra respetando el orden temporal de los datos. Esta comparación aporta mayor solidez técnica que la utilización de un único algoritmo y permite reconocer de forma explícita las limitaciones y la incertidumbre de las estimaciones.

Otro elemento de justificación es la utilidad de la visualización para interpretar y comunicar los resultados. La aplicación web permite realizar el análisis exploratorio de los datos mediante indicadores, filtros, gráficos comparativos y series temporales. De forma complementaria, el cuadro de mando desarrollado en Power BI permite consultar el resumen ejecutivo, analizar la evolución histórica, comparar el rendimiento de los modelos y explorar los escenarios predictivos y los niveles de riesgo estimados. En un ámbito con un elevado componente técnico y una presencia creciente en el debate público, esta capacidad de comunicación visual aporta valor tanto académico como aplicado.

2.3 Planteamiento del problema

La revisión de la literatura y del contexto muestra que la inteligencia artificial puede producir transformaciones relevantes en el mercado laboral, pero que sus efectos no son inmediatos, homogéneos ni fáciles de medir. Las ocupaciones con mayor exposición no tienen por qué ser necesariamente las que experimenten una mayor reducción del empleo. También pueden ser aquellas en las que la inteligencia artificial aumente la productividad, modifique la distribución de las tareas o genere nuevas necesidades de competencias.

Esta situación plantea una necesidad clara de investigación: relacionar datos observados de empleo con indicadores de exposición a la inteligencia artificial para identificar qué grupos

ocupacionales presentan un mayor potencial de transformación y analizar cómo ha evolucionado su empleo. En España, este análisis resulta metodológicamente exigente debido al uso de clasificaciones ocupacionales diferentes en las fuentes nacionales e internacionales. Esta circunstancia obliga a construir correspondencias, utilizar variables proxy y documentar cuidadosamente las decisiones de agregación y enlace entre las distintas clasificaciones.

El problema científico-técnico abordado por este TFM puede formularse de la siguiente manera: existe incertidumbre sobre la relación entre la exposición ocupacional a la inteligencia artificial y la evolución del mercado laboral español. Por ello, resulta necesario construir un conjunto de datos integrado que permita analizar el empleo por grandes grupos ocupacionales, estudiar sus patrones temporales y evaluar la capacidad de diferentes modelos para generar predicciones exploratorias sobre su evolución futura.

Este planteamiento desplaza el foco desde la especulación hacia la medición empírica. El proyecto no pretende demostrar una relación causal entre la inteligencia artificial y el empleo, sino desarrollar una infraestructura analítica reproducible para estudiar su asociación. La prioridad metodológica consiste en garantizar la calidad de los datos, la trazabilidad del proceso y la coherencia entre las variables laborales y tecnológicas.

A partir de esta base, se comparan modelos de referencia, regresiones regularizadas, algoritmos de aprendizaje automático y un ensemble ponderado.

Capítulo 3. OBJETIVOS

3.1 Objetivos generales

El objetivo general del presente Trabajo de Fin de Máster consiste en analizar la evolución del mercado laboral español y su relación con la exposición ocupacional a la inteligencia artificial mediante la integración de datos laborales, indicadores internacionales de exposición y técnicas de Big Data, así como explorar la capacidad de diferentes modelos predictivos para estimar la evolución trimestral del empleo.

Este objetivo se articula en cuatro ejes complementarios. El primero es descriptivo y se centra en comprender la situación y la evolución histórica del empleo por grandes grupos ocupacionales. El segundo es tecnológico y busca identificar qué ocupaciones presentan una mayor exposición potencial a la IA generativa y a otras capacidades de inteligencia artificial. El tercero es metodológico y consiste en construir un conjunto de datos integrado, trazable y reproducible. El cuarto es predictivo y aplicado, ya que comprende la construcción, comparación y validación temporal de diferentes modelos, la generación de escenarios exploratorios mediante un ensemble ponderado y la presentación de los resultados a través de una aplicación web orientada al análisis exploratorio y un cuadro de mando interactivo en Power BI.

3.2 Objetivos específicos

Los objetivos específicos del proyecto son los siguientes:

1. Analizar la evolución del empleo en el mercado laboral español mediante series trimestrales procedentes de la Encuesta de Población Activa.

2. Identificar los grandes grupos ocupacionales con mayor exposición potencial a la inteligencia artificial y a los modelos de lenguaje.

3. Examinar la relación entre la evolución histórica del empleo y los diferentes niveles de exposición ocupacional, sin presuponer la existencia de una relación causal.

4. Descargar, procesar, limpiar, transformar e integrar datos laborales y métricas internacionales de exposición mediante técnicas de ingeniería de datos.

5. Construir un panel integrado que relacione el empleo de los grandes grupos ocupacionales de la CNO-11 con indicadores de exposición potencial y utilización observada procedentes de AIOE y del Anthropic Economic Index.

6. Desarrollar un procedimiento documentado de correspondencia entre las clasificaciones ocupacionales nacionales e internacionales utilizadas por las distintas fuentes.

7. Construir y comparar ocho enfoques predictivos para estimar el crecimiento trimestral del empleo: persistencia trimestral, crecimiento cero, regresión lineal, Ridge, Elastic Net, Random Forest, Gradient Boosting y un ensemble ponderado.

8. Evaluar el rendimiento fuera de muestra de los modelos mediante backtesting walk-forward y las métricas RMSE, MAE y R^2, analizando sus resultados, estabilidad y limitaciones.

9. Generar escenarios predictivos exploratorios mediante un ensemble ponderado de Random Forest, Gradient Boosting y Ridge, incorporando indicadores de incertidumbre y riesgo ocupacional.

10. Desarrollar una aplicación web para el análisis exploratorio de los datos y un cuadro de mando interactivo en Power BI para presentar la evolución histórica, la comparación de modelos y los escenarios predictivos.

11. Garantizar la trazabilidad y reproducibilidad del proceso mediante la documentación de las fuentes, las transformaciones, las decisiones metodológicas y los resultados generados.

12. Analizar las implicaciones sociales y económicas de los resultados, especialmente en relación con la transformación de tareas, las competencias, la adaptación profesional y la desigualdad ocupacional.

3.3 Beneficios del proyecto

El primer beneficio del proyecto es metodológico. La construcción de un conjunto de datos integrado, documentado y reproducible permite trabajar con fuentes heterogéneas sin perder la trazabilidad de las decisiones de adquisición, limpieza, transformación, agregación y correspondencia ocupacional. Este planteamiento facilita que el análisis pueda revisarse, replicarse, actualizarse o ampliarse mediante la incorporación de nuevas fuentes, variables y periodos.

El segundo beneficio es analítico. El panel generado permite observar qué grupos ocupacionales concentran un mayor volumen de empleo, cuáles presentan niveles más elevados de exposición potencial o uso observado de inteligencia artificial y cómo evoluciona el empleo dentro de cada categoría de exposición. Además, la comparación de ocho enfoques predictivos permite determinar qué métodos ofrecen un mejor rendimiento fuera de muestra. A partir de sus resultados, el ensemble ponderado permite generar escenarios trimestrales exploratorios, comparar grupos ocupacionales e incorporar indicadores de incertidumbre y riesgo derivados de los errores observados durante el backtesting.

El tercer beneficio es práctico. Los resultados pueden aportar evidencia para orientar iniciativas de formación, recualificación y adaptación profesional, especialmente en ocupaciones con una elevada exposición potencial a la inteligencia artificial y un peso relevante en el empleo. La aplicación web facilita el análisis exploratorio de los datos, mientras que el cuadro de mando de Power BI permite consultar la evolución histórica, comparar el rendimiento de los modelos y explorar los escenarios predictivos. Estas herramientas pueden resultar útiles para empresas, trabajadores e instituciones interesados en analizar las necesidades de competencias y las posibles transformaciones en la organización del trabajo. No obstante, cualquier decisión concreta debe apoyarse en análisis adicionales, ya que el proyecto no demuestra relaciones causales ni genera predicciones deterministas.

El cuarto beneficio es académico. El proyecto conecta la literatura reciente sobre automatización, inteligencia artificial generativa, productividad, competencias y exposición ocupacional con datos observados del mercado laboral español. De este modo, traslada el debate internacional sobre inteligencia artificial y empleo a un análisis aplicado, documentado y contextualizado para España, incorporando una dimensión descriptiva, una comparación técnica de modelos y una aproximación predictiva exploratoria.

Capítulo 4. DESARROLLO DEL PROYECTO

4.1 Planificación del proyecto

El desarrollo del proyecto se organizó en distintas fases consecutivas, aunque algunas actividades se solaparon debido al carácter iterativo propio del análisis de datos. La planificación comenzó con la delimitación del problema de investigación y la revisión de la literatura sobre inteligencia artificial, exposición ocupacional y mercado laboral. Posteriormente, se seleccionaron y adquirieron las fuentes de datos, se realizaron las tareas de limpieza, transformación y correspondencia entre clasificaciones ocupacionales, y se construyó el panel analítico utilizado en el estudio.

Sobre esta base se desarrolló el análisis exploratorio y se construyeron diferentes modelos para estimar el crecimiento trimestral del empleo. La fase de modelización comprendió la definición de los modelos de referencia, la estimación de regresiones regularizadas y algoritmos de aprendizaje automático, su evaluación mediante backtesting walk-forward y la construcción de un ensemble ponderado para generar escenarios exploratorios. A continuación, se desarrollaron la aplicación web de análisis exploratorio y el cuadro de mando interactivo de Power BI. Finalmente, se llevó a cabo una fase de validación, documentación y revisión de los datos, las métricas, las predicciones y las visualizaciones.

La planificación se diseñó para asegurar la trazabilidad del proyecto. Cada fase generó resultados intermedios que sirvieron como entrada para la siguiente, como referencias bibliográficas, archivos originales, conjuntos de datos procesados, resultados exploratorios, métricas de evaluación, predicciones y visualizaciones. Este planteamiento permitió detectar y corregir problemas de calidad o coherencia antes de incorporar los resultados definitivos a la memoria. También facilitó la repetición del proceso completo cuando se introdujeron modificaciones en los datos o en la estrategia de modelización.

4.1.1 Revisión bibliográfica sobre inteligencia artificial, automatización y empleo

La primera fase del proyecto consistió en la revisión de la literatura académica e institucional relacionada con los efectos de la inteligencia artificial y la automatización sobre el mercado laboral. El propósito de esta fase fue delimitar el problema de investigación, identificar los principales enfoques teóricos y determinar qué variables e indicadores podían utilizarse para estudiar empíricamente el caso español.

La revisión comenzó con los trabajos centrados en la relación histórica entre tecnología y empleo. Estos estudios muestran que la introducción de nuevas tecnologías no produce necesariamente una sustitución completa de trabajadores, sino que puede modificar la composición de las tareas realizadas dentro de cada ocupación. Desde esta perspectiva, la automatización puede desplazar determinadas actividades, pero también complementar las capacidades humanas, aumentar la productividad y favorecer la aparición de nuevas funciones profesionales.

El enfoque basado en tareas resultó especialmente relevante para el proyecto. A diferencia de los análisis que clasifican una ocupación completa como automatizable o no automatizable, este planteamiento considera que una misma profesión está formada por tareas con distintos niveles de exposición tecnológica. Por tanto, la incorporación de inteligencia artificial puede modificar parcialmente una ocupación sin provocar necesariamente su desaparición.

A continuación, la revisión se centró en la inteligencia artificial generativa y en los grandes modelos de lenguaje. La expansión de estas tecnologías desde finales de 2022 ha ampliado el ámbito de la automatización hacia actividades cognitivas, administrativas y comunicativas. Entre ellas se encuentran la redacción de documentos, la síntesis de información, la programación, la atención al cliente, el análisis de datos y el apoyo a la toma de decisiones. Como consecuencia, algunas ocupaciones profesionales y administrativas pueden presentar una exposición elevada, aunque dicha exposición no debe interpretarse directamente como riesgo de pérdida de empleo.

También se analizaron informes de organismos internacionales como la Organización para la Cooperación y el Desarrollo Económicos, la Organización Internacional del Trabajo, la Comisión Europea y el Foro Económico Mundial. Estos documentos coinciden en señalar que los efectos de la inteligencia artificial serán heterogéneos y dependerán de factores como el contenido de las tareas, el nivel de cualificación, la capacidad de adaptación de los trabajadores, el sector económico y el grado de adopción tecnológica de las empresas.

Otro objetivo de la revisión fue identificar metodologías para medir la exposición ocupacional a la inteligencia artificial. En este ámbito se estudió el indicador AI Occupational Exposure, desarrollado por Felten, Raj y Seamans, que relaciona las capacidades de la inteligencia artificial con habilidades y ocupaciones. También se examinó su variante específica para modelos de lenguaje, utilizada para aproximar la exposición de distintas profesiones a las capacidades de la inteligencia artificial generativa.

Como complemento, se revisó el Anthropic Economic Index, que proporciona indicadores construidos a partir de interacciones observadas con sistemas de inteligencia artificial y de su correspondencia con tareas y ocupaciones. Mientras que AIOE constituye una medida teórica de exposición potencial, los datos de Anthropic aportan una aproximación al uso observado de la inteligencia artificial dentro de su propio conjunto de interacciones. Por tanto, estos datos no representan directamente el grado de adopción de la inteligencia artificial en España, sino una referencia internacional complementaria que permite diferenciar entre exposición teórica y utilización observada.

La revisión bibliográfica también permitió identificar una limitación metodológica importante: la mayoría de los indicadores internacionales utiliza clasificaciones ocupacionales estadounidenses, principalmente SOC y O*NET, mientras que las estadísticas españolas del Instituto Nacional de Estadística emplean la Clasificación Nacional de Ocupaciones de 2011. Esta diferencia hizo necesario planificar una fase específica de correspondencia y agregación entre clasificaciones antes de integrar las fuentes.

Como resultado de esta primera fase, se establecieron cinco decisiones metodológicas fundamentales:

1. Utilizar el gran grupo ocupacional de la CNO-11 y el trimestre como unidad principal de análisis.

2. Emplear los datos de la Encuesta de Población Activa como fuente oficial para medir la evolución del empleo en España.

3. Incorporar AIOE y el Anthropic Economic Index como indicadores complementarios de exposición potencial y utilización observada de inteligencia artificial.

4. Interpretar la exposición como un potencial de transformación de las tareas, evitando identificarla directamente con automatización completa, destrucción de empleo o causalidad.

5. Comparar distintos enfoques predictivos mediante un procedimiento de validación temporal, en lugar de fundamentar las conclusiones en un único algoritmo.

La revisión permitió formular la pregunta de investigación en términos medibles: determinar qué grandes grupos ocupacionales del mercado laboral español presentan una mayor exposición potencial a la inteligencia artificial, analizar cómo ha evolucionado su empleo y evaluar hasta qué punto diferentes modelos pueden anticipar exploratoriamente su crecimiento trimestral fuera de muestra.

4.1.2 Selección y descarga de fuentes de datos

La segunda fase del proyecto consistió en identificar y seleccionar fuentes de datos que permitieran relacionar la evolución del empleo en España con diferentes indicadores de exposición ocupacional a la inteligencia artificial. La selección se realizó atendiendo a criterios de fiabilidad, relevancia metodológica, actualidad, disponibilidad pública, nivel de desagregación y posibilidad de tratamiento automatizado.

Se priorizaron fuentes oficiales, académicas o respaldadas por instituciones reconocidas. Asimismo, se buscó que los datos estuvieran desagregados por ocupación y disponibles en formatos estructurados, como CSV o XLSX. Este requisito resultó necesario para garantizar la reproducibilidad del proceso, facilitar su actualización y reducir la introducción manual de información.

Como fuente principal para analizar el mercado laboral español se seleccionó la Encuesta de Población Activa del Instituto Nacional de Estadística. Se utilizaron dos conjuntos de datos. El primero contiene información trimestral sobre personas ocupadas por situación profesional, sexo y ocupación, y constituye la base principal del panel y del proceso de modelización predictiva. El segundo incorpora la distribución de las personas ocupadas por grupo de edad, sexo y ocupación, y se utilizó como fuente complementaria para el análisis descriptivo. Ambos conjuntos emplean la Clasificación Nacional de Ocupaciones de 2011 y expresan el empleo en miles de personas.

La Encuesta de Población Activa fue elegida porque constituye una de las principales fuentes oficiales para el estudio del mercado laboral español. Su periodicidad trimestral permite analizar

la evolución histórica del empleo y construir variables temporales, como las tasas de variación respecto al trimestre anterior y al mismo trimestre del año precedente. Aunque el proyecto presta especial atención al periodo más reciente, se conservaron las observaciones disponibles desde 2011 para disponer de una serie histórica más amplia durante el entrenamiento y la validación temporal de los modelos predictivos.

Para medir la exposición potencial de las ocupaciones a la inteligencia artificial se seleccionó el indicador AI Occupational Exposure (AIOE), desarrollado por Felten, Raj y Seamans. Este indicador relaciona diferentes capacidades de la inteligencia artificial con las habilidades requeridas en cada ocupación y proporciona una puntuación de exposición para ocupaciones clasificadas mediante el sistema estadounidense SOC.

También se incorporó la variante Language Modeling AIOE (LM AIOE), orientada específicamente a medir la exposición ocupacional a tecnologías de procesamiento y generación de lenguaje. Esta fuente resultó especialmente relevante debido a la expansión reciente de la inteligencia artificial generativa y de los grandes modelos de lenguaje. Su incorporación permitió diferenciar entre una exposición general a la inteligencia artificial y una exposición más relacionada con tareas lingüísticas, documentales y cognitivas.

Como fuente complementaria se utilizó el Anthropic Economic Index. Este conjunto contiene indicadores construidos a partir de interacciones observadas con sistemas de inteligencia artificial y de su correspondencia con tareas y ocupaciones. A diferencia de AIOE, que representa una medida teórica de exposición potencial, los datos de Anthropic ofrecen una aproximación al uso observado dentro de su propia plataforma. Por tanto, no representan directamente la adopción de inteligencia artificial en el mercado laboral español y pueden estar condicionados por sesgos relacionados con la plataforma, la selección de usuarios y la cobertura ocupacional.

Durante esta fase también se consideraron otras fuentes, como los datos sobre habilidades y proyecciones laborales de la Oficina de Estadísticas Laborales de Estados Unidos, los informes del Servicio Público de Empleo Estatal y las previsiones de competencias del Centro Europeo para el Desarrollo de la Formación Profesional. Sin embargo, estas fuentes no se incorporaron al panel principal debido a dificultades de descarga, diferencias en el nivel de desagregación o falta de correspondencia directa con la estructura ocupacional utilizada.

La adquisición de las fuentes seleccionadas se automatizó mediante un script desarrollado en Python. Este programa accede a las direcciones de descarga, almacena los archivos originales y registra el resultado de cada operación. Los datos sin modificar se conservaron en el directorio data/raw, mientras que las versiones transformadas se almacenaron posteriormente en data/processed. Esta separación permite preservar los archivos originales, repetir el procesamiento y comprobar las transformaciones aplicadas en cada fase.

Asimismo, se generó un registro de descarga que contiene la fecha, la fuente, la dirección de acceso, el nombre del archivo, el tamaño descargado y el estado de la operación. Durante la ejecución inicial se descargaron correctamente las dos tablas de la Encuesta de Población Activa, los indicadores AIOE y LM AIOE, y los datos del Anthropic Economic Index. La descarga directa de la fuente de habilidades de la Oficina de Estadísticas Laborales no pudo completarse debido

a una respuesta HTTP 403. El incidente quedó documentado y la fuente fue excluida de la versión final del panel.

Como resultado de esta fase se obtuvieron las fuentes necesarias para construir tres componentes del análisis: la evolución histórica del empleo español, la exposición teórica de las ocupaciones a la inteligencia artificial y el uso observado en el conjunto de datos de Anthropic. La integración posterior de estos componentes permitió construir una base analítica común, manteniendo la distinción conceptual entre empleo observado en España, exposición ocupacional potencial y utilización de inteligencia artificial observada en una plataforma internacional.

4.1.3 Limpieza e integración de datos

La tercera fase del proyecto comprendió la limpieza, transformación e integración de las fuentes descargadas. El objetivo fue convertir conjuntos de datos con estructuras y clasificaciones diferentes en un panel homogéneo, trazable y adecuado tanto para el análisis exploratorio como para el posterior desarrollo y evaluación de los modelos predictivos.

En primer lugar, se conservaron sin modificar los archivos originales dentro del directorio data/raw. Las operaciones de limpieza se aplicaron sobre copias de trabajo y sus resultados se almacenaron en data/processed. Esta separación permitió preservar la información de origen, comprobar las transformaciones realizadas y volver a ejecutar el proceso completo cuando fue necesario.

El tratamiento de los datos de la Encuesta de Población Activa comenzó con la normalización de los nombres de las variables. Los encabezados se transformaron a minúsculas, se eliminaron las tildes y los caracteres especiales, y se adoptó el formato snake_case. De esta forma, se obtuvo una nomenclatura homogénea y compatible con las herramientas empleadas durante el procesamiento.

Los valores de empleo del INE requerían una transformación específica debido al uso del formato numérico español. Los separadores de miles y las comas decimales se convirtieron a una representación numérica procesable mediante Python. Los valores no disponibles se identificaron y transformaron en valores ausentes, evitando que fueran interpretados como cantidades válidas.

Los periodos trimestrales, representados originalmente mediante valores como 2026T1, se transformaron en fechas ordenables. También se generaron las variables de año y trimestre para facilitar el análisis temporal, la construcción de gráficos y la incorporación de componentes de tendencia y estacionalidad en los modelos predictivos.

A partir de la descripción textual de cada ocupación se extrajeron el código del gran grupo de la Clasificación Nacional de Ocupaciones y su denominación. Para construir el panel principal se seleccionaron las observaciones correspondientes a ambos sexos y al total de situaciones profesionales. Asimismo, se excluyeron los registros agregados correspondientes al total de ocupaciones, ya que su inclusión habría duplicado el empleo contabilizado en los distintos grupos CNO.

Una vez ordenadas cronológicamente las observaciones dentro de cada grupo ocupacional, se calcularon dos variables derivadas. La variación trimestral representa el cambio porcentual del empleo respecto al trimestre inmediatamente anterior:

$$Crecimiento_t^{trimestral} = \frac{Empleo_t - Empleo_{t-1}}{Empleo_{t-1}} \times 100$$

La variación interanual compara el empleo de cada trimestre con el observado en el mismo trimestre del año anterior:

$$Crecimiento_t^{interanual} = \frac{Empleo_t - Empleo_{t-4}}{Empleo_{t-4}} \times 100$$

Estas variables permitieron diferenciar las fluctuaciones de corto plazo de las tendencias anuales. En particular, la comparación interanual reduce parcialmente la influencia de la estacionalidad al comparar trimestres equivalentes de años consecutivos. Las observaciones iniciales para las que no existían los retardos necesarios se mantuvieron como valores ausentes en estas variables derivadas y se excluyeron cuando el análisis requería disponer de ellas.

Los conjuntos de datos AIOE también fueron normalizados antes de su integración. Las puntuaciones generales de exposición a la inteligencia artificial y las puntuaciones específicas de exposición a modelos de lenguaje se convirtieron a valores numéricos y se relacionaron mediante el código SOC. A partir de este código se identificó el gran grupo ocupacional correspondiente.

Los datos del Anthropic Economic Index se dividieron en dos niveles. El primero contenía indicadores de utilización observada por ocupación y se integró con AIOE mediante el código SOC. El segundo contenía información sobre la penetración de la inteligencia artificial en diferentes tareas y se conservó como conjunto complementario para el análisis descriptivo. Durante la limpieza se eliminaron los duplicados exactos, por lo que el conjunto resultante quedó formado por 17.992 tareas únicas.

La principal dificultad de la integración fue que las fuentes españolas e internacionales utilizaban clasificaciones ocupacionales diferentes. Los datos del INE empleaban CNO-11, mientras que AIOE y Anthropic utilizaban SOC y descripciones de tareas procedentes de O*NET. Para resolver esta incompatibilidad se construyó una correspondencia agregada entre los diez grandes grupos CNO y los grandes grupos SOC relacionados.

Esta correspondencia se utilizó como una aproximación analítica y no como una equivalencia oficial entre clasificaciones. Algunos grandes grupos SOC se asignaron a más de un grupo CNO debido a la amplitud y heterogeneidad de las categorías ocupacionales. Por ello, se distinguió entre las 774 ocupaciones SOC únicas procesadas y las 1.057 asignaciones acumuladas generadas por la correspondencia, que incluyen los solapamientos entre distintos grupos CNO.

Para calcular la exposición de cada gran grupo CNO se seleccionaron las ocupaciones SOC asociadas y se obtuvo la media de sus puntuaciones. Cada ocupación SOC se contabilizó una sola vez dentro de cada grupo CNO al que fue asignada. Este procedimiento evitó calcular una media simple entre grandes grupos SOC, lo que habría concedido el mismo peso a categorías compuestas por cantidades muy diferentes de ocupaciones.

A partir de las puntuaciones agregadas se calcularon percentiles relativos de exposición. La clasificación final se construyó principalmente a partir del percentil de exposición a modelos de lenguaje, agrupando los grandes grupos CNO en categorías de exposición baja, media y alta según su posición en la distribución. El grupo de ocupaciones militares se mantuvo sin categoría porque no se encontraron ocupaciones SOC disponibles en la fuente AIOE que permitieran realizar una estimación equivalente.

La integración final se realizó mediante la combinación de las series trimestrales del INE con los indicadores agregados de exposición. La unidad de análisis resultante fue la combinación de un gran grupo CNO y un periodo trimestral. Además, se creó la variable objetivo de los modelos, correspondiente al crecimiento porcentual del empleo durante el trimestre siguiente. Para 2026T1 no existe dentro del panel un valor observado del trimestre posterior, por lo que esta observación se excluyó del entrenamiento supervisado y se utilizó como punto de origen para generar los escenarios futuros.

El panel final quedó compuesto por 610 observaciones, correspondientes a diez grandes grupos CNO y 61 trimestres comprendidos entre 2011T1 y 2026T1. Cada combinación de grupo ocupacional y periodo aparece una sola vez y todos los grupos disponen de la misma cobertura temporal.

Como control de calidad, se incorporaron validaciones automáticas para comprobar la ausencia de claves duplicadas en el panel, la presencia de los diez grupos CNO, la igualdad de la cobertura temporal, la unicidad de las ocupaciones SOC dentro de cada asignación CNO y la eliminación de duplicados exactos en los datos de Anthropic. Si alguna de estas condiciones no se cumple, el proceso se detiene antes de generar los resultados posteriores.

El resultado de esta fase fue un panel integrado y reproducible que relaciona la evolución del empleo en España con diferentes indicadores de exposición ocupacional a la inteligencia artificial. No obstante, la correspondencia entre CNO-11 y SOC continúa siendo una aproximación agregada y constituye una de las principales limitaciones metodológicas del proyecto.

4.1.4 Análisis exploratorio de los datos

La cuarta fase del proyecto consistió en realizar un análisis exploratorio del panel integrado. El objetivo fue comprobar la calidad y coherencia de los datos, describir la evolución histórica del empleo español e identificar posibles patrones relacionados con la exposición ocupacional a la inteligencia artificial.

En primer lugar, se revisaron la cobertura temporal, la presencia de valores ausentes, la distribución de las variables y la consistencia de las series de empleo. También se comprobó que

los diez grandes grupos CNO dispusieran de 61 observaciones trimestrales y que no existieran combinaciones duplicadas de grupo ocupacional y periodo.

Posteriormente, se analizó la distribución del empleo en el último periodo disponible. En el primer trimestre de 2026, el conjunto de los diez grandes grupos CNO representaba aproximadamente 22,3 millones de personas ocupadas. Los grupos con mayor volumen de empleo fueron los trabajadores de los servicios de restauración, servicios personales, protección y ventas, y los técnicos y profesionales científicos e intelectuales.

A continuación, se examinaron los indicadores de exposición a la inteligencia artificial. Los resultados mostraron una mayor exposición relativa entre directores y gerentes, técnicos y profesionales científicos e intelectuales, empleados administrativos y técnicos y profesionales de apoyo. Por el contrario, los trabajadores cualificados del sector agrícola y determinados perfiles industriales presentaron valores inferiores. Estos resultados son coherentes con la capacidad de la inteligencia artificial generativa para intervenir en tareas cognitivas, lingüísticas, informacionales y administrativas.

El empleo también se agrupó según las categorías de exposición baja, media y alta. En el primer trimestre de 2026, los grupos clasificados con exposición alta concentraban aproximadamente 10,4 millones de personas ocupadas, frente a alrededor de 9 millones en los grupos de exposición media y 2,8 millones en los de exposición baja. Las ocupaciones militares, para las que no se obtuvo una categoría equivalente, representaban aproximadamente 0,1 millones de personas. Estas cifras reflejan el volumen de empleo incluido en cada categoría, pero no representan el número de trabajadores sustituidos, automatizados o directamente afectados por la inteligencia artificial.

También se estudió la evolución temporal del empleo mediante las variaciones trimestrales e interanuales. La comparación mostró que una exposición elevada a la inteligencia artificial podía coexistir con una evolución positiva del empleo. Asimismo, el análisis conjunto del crecimiento y la exposición no reveló una asociación simple y uniforme aplicable a todos los grupos ocupacionales. Por tanto, los resultados descriptivos no permiten concluir que una mayor exposición implique necesariamente una reducción de la ocupación.

Por último, se analizaron los datos de penetración por tareas del Anthropic Economic Index. Su distribución presentó una elevada concentración de valores cercanos a cero y un conjunto reducido de tareas con niveles elevados de utilización observada. Este comportamiento indica que el uso registrado dentro del conjunto de datos de Anthropic no se distribuye uniformemente entre las distintas tareas y ocupaciones. No obstante, estos resultados no deben interpretarse como una medida representativa de la adopción general de inteligencia artificial en el mercado laboral español.

Los resultados de esta fase se utilizaron para seleccionar y construir las variables predictoras, detectar limitaciones metodológicas y diseñar las visualizaciones del proyecto. También sirvieron como base para desarrollar la aplicación web, cuya función se limita al análisis exploratorio del panel. El análisis realizado tuvo un carácter descriptivo, por lo que no permite

establecer relaciones causales entre la exposición a la inteligencia artificial y los cambios observados en el empleo.

4.1.5 Desarrollo y validación del modelo predictivo

La quinta fase del proyecto consistió en construir, comparar y validar diferentes modelos capaces de estimar el crecimiento porcentual del empleo de cada gran grupo CNO durante el trimestre siguiente. La modelización se planteó con una finalidad exploratoria, debido al reducido número de grupos ocupacionales, al carácter agregado de los datos y a que los indicadores de exposición a la inteligencia artificial constituyen aproximaciones construidas mediante correspondencias entre clasificaciones.

Como variable objetivo se utilizó el crecimiento porcentual del empleo durante el trimestre siguiente. Para obtenerla, las observaciones se ordenaron cronológicamente dentro de cada gran grupo CNO y se comparó el empleo de cada periodo con el registrado en el trimestre posterior:

$$Crecimiento_{t+1} = \frac{Empleo_{t+1} - Empleo_t}{Empleo_t} \times 100$$

Las variables explicativas incluyeron el logaritmo del empleo actual, las variaciones trimestral e interanual, el percentil de exposición a modelos de lenguaje, el indicador de utilización observada de Anthropic, una tendencia temporal y dos componentes cíclicos para representar la estacionalidad trimestral mediante funciones seno y coseno. También se incorporaron interacciones entre la exposición a la inteligencia artificial y las variaciones trimestral e interanual del empleo. Finalmente, se añadieron variables indicadoras para los grandes grupos CNO, con el propósito de representar diferencias estructurales entre ocupaciones.

Enfoques comparados

Se compararon ocho enfoques predictivos:

1. Crecimiento cero: modelo de referencia que supone que el empleo no experimentará variación durante el trimestre siguiente.

2. Persistencia trimestral: modelo de referencia que utiliza como predicción el crecimiento observado durante el trimestre actual.

3. Regresión lineal: proporciona una referencia paramétrica sin regularización y permite evaluar si existe una relación lineal básica entre las variables y el crecimiento posterior.

4. Ridge: aplica una penalización cuadrática sobre los coeficientes y resulta adecuada ante la presencia de variables correlacionadas y muestras de tamaño limitado (Hoerl y Kennard, 1970).[17]

5. Elastic Net: combina penalizaciones L1 y L2, permitiendo regularizar los coeficientes y reducir la influencia de variables poco informativas (Zou y Hastie, 2005).[18]

6. Random Forest: combina múltiples árboles de regresión entrenados sobre muestras y subconjuntos de variables diferentes, lo que permite representar relaciones no lineales e interacciones (Breiman, 2001).[19]

7. Gradient Boosting: construye árboles de forma secuencial para corregir los errores residuales de los estimadores anteriores (Friedman, 2001).[20]

8. Ensemble ponderado: combina las predicciones de los tres modelos con mejor rendimiento en la ventana de validación, asignándoles pesos inversamente proporcionales a su RMSE.

La comparación permitió evaluar si el incremento de complejidad producía una mejora real fuera de muestra. Asimismo, evitó fundamentar la selección definitiva en un único algoritmo elegido de antemano.

Selección de hiperparámetros

La selección de hiperparámetros se realizó mediante una ventana temporal independiente formada por los cuatro trimestres inmediatamente anteriores al periodo reservado para el backtesting. Los modelos se entrenaron únicamente con observaciones anteriores a esta ventana y se seleccionó, para cada algoritmo, la configuración que obtuvo el menor RMSE de validación.

En Ridge se evaluaron valores de Alpha iguales a 0,01; 0,1; 1; 10 y 100, resultando seleccionado alpha=100. En Elastic Net se compararon distintas combinaciones de regularización y proporción L1, seleccionándose alpha=10 y l1_ratio=0,75.

La configuración seleccionada para Random Forest estuvo compuesta por 80 árboles, una profundidad máxima de 5 niveles, un mínimo de 8 observaciones por hoja y 5 variables candidatas en cada división. Para Gradient Boosting se seleccionaron 50 estimadores, una tasa de aprendizaje de 0,07, una profundidad máxima de 2 niveles y un mínimo de 12 observaciones por hoja.

La estandarización de las variables se ajustó utilizando exclusivamente las observaciones disponibles en cada conjunto de entrenamiento. De este modo, la información estadística de los periodos evaluados no intervino en el ajuste de los modelos.

Validación temporal

La evaluación fuera de muestra se realizó mediante un procedimiento de backtesting walk-forward con ventana de entrenamiento expansiva. Para cada trimestre de prueba, los modelos se entrenaron exclusivamente con las observaciones cronológicamente anteriores y generaron predicciones para el periodo siguiente. Tras cada iteración, la ventana de entrenamiento se amplió con las nuevas observaciones disponibles.

El conjunto de prueba estuvo formado por los ocho últimos trimestres con variable objetivo conocida, desde 2024T1 hasta 2025T4. Al considerar los diez grandes grupos ocupacionales, se obtuvieron 80 predicciones fuera de muestra por modelo. Todos los enfoques se evaluaron sobre las mismas observaciones para garantizar una comparación homogénea.

El rendimiento se midió mediante la raíz del error cuadrático medio (RMSE), el error absoluto medio (MAE) y el coeficiente de determinación (R^2). El RMSE concede una mayor penalización a los errores elevados, el MAE representa la magnitud absoluta media de las desviaciones y el R^2 compara la capacidad explicativa del modelo con la utilización de la media observada.

1. Comparación del rendimiento fuera de muestra (Fuente: elaboración propia a partir de las 80 predicciones fuera de muestra obtenidas mediante backtesting walk-forward.)

Modelo	RMSE	MAE	R^2	Mejora del RMSE frente a crecimiento cero
Random Forest	2,393	1,874	0,143	9,41 %
Gradient Boosting	2,415	1,929	0,127	8,59 %
Ensemble ponderado	2,429	1,943	0,116	8,04 %
Ridge	2,544	2,051	0,031	3,70 %
Elastic Net	2,557	2,065	0,021	3,20 %
Regresión lineal	2,633	2,161	−0,038	0,31 %
Crecimiento cero	2,641	2,089	−0,045	0,00 %
Persistencia trimestral	4,201	3,235	−1,643	−59,05 %

Random Forest obtuvo el mejor rendimiento, con un RMSE de 2,393, un MAE de 1,874 y un R^2 de 0,143. Su RMSE fue un 9,41 % inferior al del baseline de crecimiento cero. Gradient Boosting y el ensemble ponderado ocuparon la segunda y tercera posición, respectivamente. Ridge mejoró los dos modelos de referencia, pero su rendimiento fue inferior al de los métodos basados en árboles.

La robustez de la mejora de Random Forest frente al crecimiento cero se examinó mediante 2.000 remuestreos bootstrap realizados por bloques trimestrales. La diferencia media entre ambos RMSE fue de −0,248 puntos y su intervalo del 95 % se situó entre −0,432 y −0,049. Al permanecer el intervalo por debajo de cero, el análisis aporta evidencia de que la mejora observada no depende exclusivamente de uno de los trimestres evaluados. No obstante, su magnitud continúa siendo moderada.

El análisis de importancia por permutación se utilizó para estudiar qué variables contribuían en mayor medida a las predicciones de Random Forest. Este procedimiento midió el incremento del RMSE producido al alterar aleatoriamente cada variable. Sus resultados se interpretaron como importancia predictiva y no como evidencia de causalidad.

Construcción del ensemble y generación de escenarios

Aunque Random Forest obtuvo el menor error fuera de muestra, los escenarios futuros se generaron mediante un ensemble ponderado para combinar capacidad predictiva, estabilidad y diversidad metodológica. Los tres modelos seleccionados en la ventana de validación fueron Random Forest, Gradient Boosting y Ridge. Sus pesos, calculados de forma inversamente proporcional al RMSE de validación, fueron los siguientes:

- Random Forest: 0,3379.

- Gradient Boosting: 0,3342.

- Ridge: 0,3279.

Una vez finalizada la validación, estos tres modelos se ajustaron utilizando todas las observaciones con variable objetivo conocida. A partir de 2026T1 se generaron predicciones recursivas para ocho horizontes trimestrales, desde T+1 hasta T+8. En cada iteración, el empleo previsto se incorporó al historial utilizado para construir las variables del horizonte siguiente. En consecuencia, los errores pueden acumularse conforme aumenta el horizonte temporal.

Incertidumbre e indicadores de riesgo

Para representar la incertidumbre se utilizaron los residuos fuera de muestra del ensemble ponderado. A partir de su distribución empírica se calcularon los percentiles 5 y 95, que se añadieron a las predicciones puntuales para obtener límites aproximados del 90 %. Este procedimiento evita imponer una distribución normal a los errores, aunque no constituye un intervalo probabilístico calibrado para cada grupo y horizonte.

También se estimó una frecuencia empírica de contracción. Para cada predicción se calculó la proporción de residuos del backtesting que, al combinarse con el crecimiento previsto, habrían producido un crecimiento inferior a cero. Se aplicó un suavizado para evitar valores extremos en una muestra reducida. Este indicador no representa una probabilidad causal de destrucción de empleo, sino una medida exploratoria basada en los errores históricos del modelo.

Por último, se construyeron dos indicadores sintéticos de priorización. El primero, denominado exposure_weighted_risk_thousand, combina el empleo previsto, la frecuencia empírica de contracción y la puntuación relativa de exposición a la inteligencia artificial:

$$Riesgo_{ponderado} = Empleo_{previsto} \times Frecuencia_{contraccion} \times Exposicion_{relativa}$$

A partir de este valor se calculó risk_index, que refuerza el peso de la exposición y permite ordenar los grupos ocupacionales dentro de cada horizonte. Las categorías de riesgo bajo, medio y alto se asignaron según la posición relativa del índice en cada periodo predictivo.

Aunque exposure_weighted_risk_thousand conserva la escala de miles de personas, ninguno de estos indicadores representa una previsión de despidos ni una estimación del número de puestos de trabajo que desaparecerán. Su finalidad es exclusivamente comparativa y exploratoria.

En conjunto, los resultados muestran que los modelos basados en árboles aportan una capacidad predictiva superior a los enfoques lineales y a los modelos de referencia. Sin embargo, el R^2 máximo de 0,143 indica que una parte considerable de la variabilidad trimestral continúa sin ser explicada. Debido a esta capacidad explicativa moderada, al carácter agregado de los datos y a la ausencia de una medición directa de adopción de inteligencia artificial en España, los escenarios se presentan como herramientas exploratorias de apoyo al análisis y no como predicciones causales o deterministas.

4.1.6 Desarrollo de las herramientas de visualización

La sexta fase del proyecto consistió en desarrollar herramientas de visualización destinadas a facilitar la exploración de los datos y la interpretación de los resultados. Su finalidad fue transformar los conjuntos procesados, las métricas de evaluación y los escenarios predictivos en información comprensible tanto para usuarios con conocimientos técnicos como para personas interesadas en la evolución del mercado laboral.

Aplicación web de análisis exploratorio

En primer lugar, se desarrolló un dashboard web local mediante HTML, CSS y JavaScript. Esta solución permite visualizar los datos sin depender de servicios externos ni de infraestructuras de pago. El dashboard carga el panel procesado desde un archivo CSV y genera los indicadores y gráficos directamente en el navegador.

La aplicación web se diseñó exclusivamente como una herramienta de análisis exploratorio. Su propósito es permitir la consulta de la evolución histórica del empleo y de los indicadores de exposición ocupacional, mientras que la evaluación de los modelos y los escenarios predictivos se presentan en Power BI.

La interfaz incorpora diferentes filtros interactivos. El usuario puede seleccionar el periodo analizado, la categoría de exposición a la inteligencia artificial, el año inicial de la serie temporal y un término de búsqueda relacionado con la ocupación. Estos filtros actualizan simultáneamente los indicadores, los gráficos y la tabla de trabajo de acuerdo con el subconjunto seleccionado.

En la parte superior del dashboard se incluyeron varios indicadores clave. Entre ellos se encuentran el empleo total, el crecimiento interanual medio, el número de grupos ocupacionales seleccionados, la exposición media a modelos de lenguaje, la variación trimestral media y el indicador medio de utilización observada procedente de Anthropic.

También se incorporaron las siguientes visualizaciones:

- distribución del empleo por categoría de exposición;

- comparación del empleo entre los grandes grupos CNO;

- clasificación de los grupos según su exposición a modelos de lenguaje;

- gráfico de dispersión entre exposición a la inteligencia artificial y crecimiento interanual;

- evolución temporal del empleo por categoría de exposición;

- tabla detallada con las principales variables laborales y tecnológicas.

Los colores permiten distinguir las categorías de exposición baja, media y alta, además del grupo sin categoría. Estas clasificaciones representan posiciones relativas dentro de la distribución de exposición y no identifican directamente ocupaciones seguras, amenazadas o destinadas a desaparecer.

Cuadro de mando en Power BI

Como complemento de la aplicación web, se desarrolló un cuadro de mando interactivo en Microsoft Power BI. Su modelo de datos se amplió para incorporar información histórica, resultados de backtesting, métricas de evaluación, importancia de variables y escenarios predictivos.

El modelo incluye una dimensión ocupacional para identificar los grandes grupos CNO y una dimensión de modelos para facilitar el filtrado de los algoritmos evaluados. Estas dimensiones se relacionan con diferentes tablas de hechos que contienen el histórico de empleo, las predicciones fuera de muestra, las métricas por grupo ocupacional y los escenarios futuros del ensemble. La tabla de importancia por permutación se conserva como tabla analítica independiente, al no requerir una relación directa con el resto del modelo.

Entre los principales archivos utilizados se encuentran:

- powerbi_dim_cno.csv, con la información descriptiva de los grupos ocupacionales;

- powerbi_fact_employment_history.csv, con la evolución histórica del empleo;

- metricas_comparacion_modelos.csv, con las métricas generales de los modelos;

- metricas_por_grupo_y_modelo.csv, con los errores desagregados por modelo y grupo ocupacional;

- predicciones_backtesting_todos_modelos.csv, con las predicciones fuera de muestra;

- importancia_variables_permutacion.csv, con la importancia predictiva de las variables;

- powerbi_fact_forecast_v2.csv, con los escenarios del ensemble para los horizontes T+1 a T+8.

Las relaciones principales se configuraron con cardinalidad de uno a varios desde las dimensiones ocupacional y de modelos hacia las correspondientes tablas de hechos. Esta estructura permite aplicar filtros comunes y mantener la coherencia entre los indicadores históricos, las métricas de evaluación y los resultados predictivos.

El cuadro de mando de Power BI se organizó en cuatro páginas:

1. Resumen ejecutivo. Reúne los principales indicadores de empleo, exposición y crecimiento, junto con gráficos de comparación ocupacional, evolución histórica y crecimiento previsto para T+1.

2. Análisis histórico de empleo. Permite seleccionar un intervalo temporal y analizar la evolución trimestral, el empleo inicial y final, la variación acumulada y el crecimiento interanual medio por grupo ocupacional.

3. Comparación y evaluación de modelos predictivos. Presenta el modelo con mejor rendimiento, las métricas RMSE, MAE y R^2, la mejora frente al crecimiento cero, la comparación del error entre los ocho enfoques, el comportamiento real frente al predicho, el error por grupo ocupacional y la importancia de variables de Random Forest.

4. Predicción exploratoria y riesgo ocupacional. Muestra la evolución prevista del empleo entre T+1 y T+8, el crecimiento estimado por grupo ocupacional, la distribución del empleo previsto

por nivel de riesgo, la frecuencia empírica ponderada de contracción y diferentes indicadores correspondientes al horizonte seleccionado.

Para construir estas páginas se desarrollaron medidas DAX destinadas a calcular el empleo observado, el empleo asociado a exposición alta, el crecimiento interanual, las métricas del modelo seleccionado, el mejor modelo, el empleo previsto, el crecimiento previsto ponderado y la variación acumulada. También se configuraron segmentadores, filtros interactivos, etiquetas comprensibles y textos metodológicos destinados a facilitar la interpretación de los resultados.

La visualización se utilizó, además, como mecanismo de control de calidad. La representación gráfica de las series temporales facilitó la detección de valores anómalos, cambios bruscos, periodos incompletos y posibles incoherencias en la agregación de las categorías. La comparación visual de las predicciones y los valores observados también permitió examinar los periodos y grupos ocupacionales en los que los modelos presentaban errores más elevados.

El resultado de esta fase fue un sistema de visualización compuesto por dos herramientas complementarias. La aplicación web permite realizar el análisis exploratorio del panel integrado, mientras que Power BI presenta el resumen ejecutivo, la evolución histórica, la evaluación técnica de los modelos y los escenarios predictivos. Ambas soluciones utilizan datos generados por el mismo proceso reproducible, aunque sus resultados deben interpretarse desde una perspectiva descriptiva y exploratoria y no como evidencia de relaciones causales entre inteligencia artificial y empleo.

4.1.7 Documentación, revisión y redacción

La séptima fase del proyecto estuvo dedicada a documentar el proceso desarrollado, revisar la consistencia de los resultados y trasladar el trabajo técnico a la memoria del TFM. Esta fase se realizó de forma transversal, ya que la documentación y el control de calidad acompañaron a la adquisición, transformación, análisis, modelización y visualización de los datos.

En primer lugar, se elaboró una bitácora metodológica en la que se registraron las fuentes seleccionadas, los criterios de inclusión, las decisiones adoptadas y las principales limitaciones detectadas. También se documentaron la estructura de carpetas, los archivos generados y las transformaciones aplicadas a cada conjunto de datos. Este registro permitió mantener la trazabilidad del proyecto y justificar posteriormente las decisiones metodológicas incluidas en la memoria.

Asimismo, se preparó una guía de reproducibilidad con las instrucciones necesarias para ejecutar el pipeline completo. El proceso se organizó en scripts independientes para la descarga de las fuentes, la limpieza e integración de los datos, el análisis exploratorio, la comparación de los modelos y la generación de escenarios predictivos. Adicionalmente, se desarrolló un script principal encargado de ejecutar las distintas etapas en el orden adecuado y detener el proceso cuando se produce algún error.

También se documentaron el funcionamiento de la aplicación web y la construcción del cuadro de mando de Power BI. Esta documentación incluye la descripción de los archivos utilizados, las

tablas del modelo analítico, las relaciones establecidas, las principales medidas DAX y la organización de las cuatro páginas del informe. De esta forma, las herramientas de visualización pueden actualizarse cuando se generen nuevas versiones de los datos procesados.

Durante la revisión se comprobó la coherencia entre los archivos originales, los conjuntos procesados, las métricas de evaluación, las predicciones y los resultados incorporados a las visualizaciones y a la memoria. Entre los controles realizados se encontraban la detección de duplicados, la validación de las claves formadas por el grupo CNO y el periodo, la revisión de la cobertura temporal y la comprobación del número de observaciones disponibles para cada grupo ocupacional.

Este proceso permitió identificar y corregir diferentes problemas. Se eliminaron duplicados exactos en los datos de tareas del Anthropic Economic Index, se revisó el cálculo de la exposición agregada por grupo CNO y se corrigió la agregación del empleo por categoría de exposición. También se distinguió entre el número de ocupaciones SOC únicas y el número acumulado de asignaciones CNO–SOC, ya que estas últimas incluyen solapamientos entre grupos.

La revisión de la modelización predictiva dio lugar a una ampliación sustancial del planteamiento inicial. Además de los baselines de persistencia trimestral y crecimiento cero, se incorporaron regresión lineal, Ridge, Elastic Net, Random Forest, Gradient Boosting y un ensemble ponderado. Todos los enfoques se evaluaron sobre los mismos ocho trimestres mediante backtesting walk-forward, utilizando RMSE, MAE y R^2 como métricas de comparación.

También se incorporaron un análisis bootstrap por bloques trimestrales para comprobar la robustez de la mejora del mejor modelo y un procedimiento de importancia por permutación para estudiar la contribución predictiva de las variables. Los escenarios futuros dejaron de depender exclusivamente de Ridge y pasaron a generarse mediante un ensemble ponderado de Random Forest, Gradient Boosting y Ridge.

La frecuencia empírica de contracción dejó de estimarse mediante una distribución normal teórica y pasó a calcularse utilizando los residuos fuera de muestra del ensemble. También se añadieron límites predictivos basados en los percentiles 5 y 95 de dichos residuos y se revisó la clasificación del riesgo para calcularla de manera independiente dentro de cada horizonte.

Otro cambio relevante fue la sustitución del nombre affected_jobs_estimate_thousand, que podía interpretarse erróneamente como una estimación del número de puestos afectados o destruidos. El indicador pasó a denominarse exposure_weighted_risk_thousand, reflejando que se trata de una medida sintética que combina empleo previsto, exposición relativa y frecuencia empírica de contracción. La documentación aclara expresamente que este indicador no representa despidos esperados ni puestos de trabajo que vayan a desaparecer.

Una vez estabilizados los datos y el proceso de modelización, se procedió a redactar la memoria. La redacción se estructuró siguiendo la plantilla proporcionada por la universidad e integrando el marco teórico, los objetivos, la metodología, los resultados, la discusión y las conclusiones. Se prestó especial atención a diferenciar entre exposición potencial, utilización observada, transformación de tareas, predicción y sustitución laboral, evitando atribuir causalidad a relaciones descriptivas o predictivas.

Para representar las expresiones matemáticas se utilizó notación compatible con LaTeX. Este procedimiento permitió presentar de manera homogénea las fórmulas de crecimiento trimestral, crecimiento interanual, variable objetivo e indicadores derivados. La memoria principal se mantuvo, en todo caso, dentro de la plantilla proporcionada por la universidad.

También se revisó la coherencia entre la pregunta de investigación, los objetivos específicos, las variables seleccionadas, los resultados de los modelos y las conclusiones obtenidas. Las afirmaciones se ajustaron al alcance real del análisis, presentando los modelos y escenarios como herramientas exploratorias y no como sistemas capaces de anticipar de manera determinista la desaparición de puestos de trabajo.

Por último, se revisaron la terminología, la estructura de los apartados, la presentación de tablas y figuras, la coherencia de las cifras entre la memoria y Power BI, y la correspondencia entre las citas incluidas en el texto y la bibliografía. Los elementos técnicos de mayor extensión, como las tablas de correspondencia, la estructura de los conjuntos de datos, la configuración de los modelos y determinados fragmentos de código, se reservaron para los anexos con el propósito de mantener la claridad de la memoria principal.

Como resultado de esta fase se obtuvo un proyecto documentado con las limitaciones de los datos disponibles. La revisión no se limitó a corregir aspectos formales, sino que permitió mejorar la metodología, comparar alternativas predictivas, reducir interpretaciones ambiguas y reforzar la validez de las conclusiones presentadas.

4.1.8 Cronograma del proyecto

La planificación temporal del proyecto se organizó en fases relacionadas entre sí. Aunque se estableció una secuencia general, algunas actividades se desarrollaron de forma parcialmente simultánea. La revisión bibliográfica, la documentación y la redacción continuaron durante buena parte del proyecto, mientras que los resultados del análisis exploratorio y la validación predictiva obligaron a revisar determinadas decisiones de limpieza, integración y modelización.

La planificación comenzó en febrero de 2026 con la revisión bibliográfica y la delimitación del problema de investigación. La implementación técnica se inició en mayo con la definición de la estrategia de datos, la selección de las fuentes y la construcción de la primera versión del pipeline. Durante junio se avanzó en la integración de los datos, el análisis exploratorio y el desarrollo inicial de las herramientas de visualización.

En julio se desarrolló una primera aproximación predictiva basada en regresión Ridge, se implementó el procedimiento de backtesting y se prepararon las primeras exportaciones para Power BI. Durante agosto se realizó una auditoría completa de los datos y del proceso de modelización, se corrigieron diferentes problemas metodológicos y se regeneraron los resultados.

En la fase final se amplió el análisis predictivo mediante la comparación de ocho enfoques, se incorporaron la evaluación bootstrap, la importancia de variables por permutación y el ensemble ponderado, y se actualizaron las páginas de Power BI. Paralelamente, se completaron la memoria, los anexos técnicos y la revisión final del proyecto.

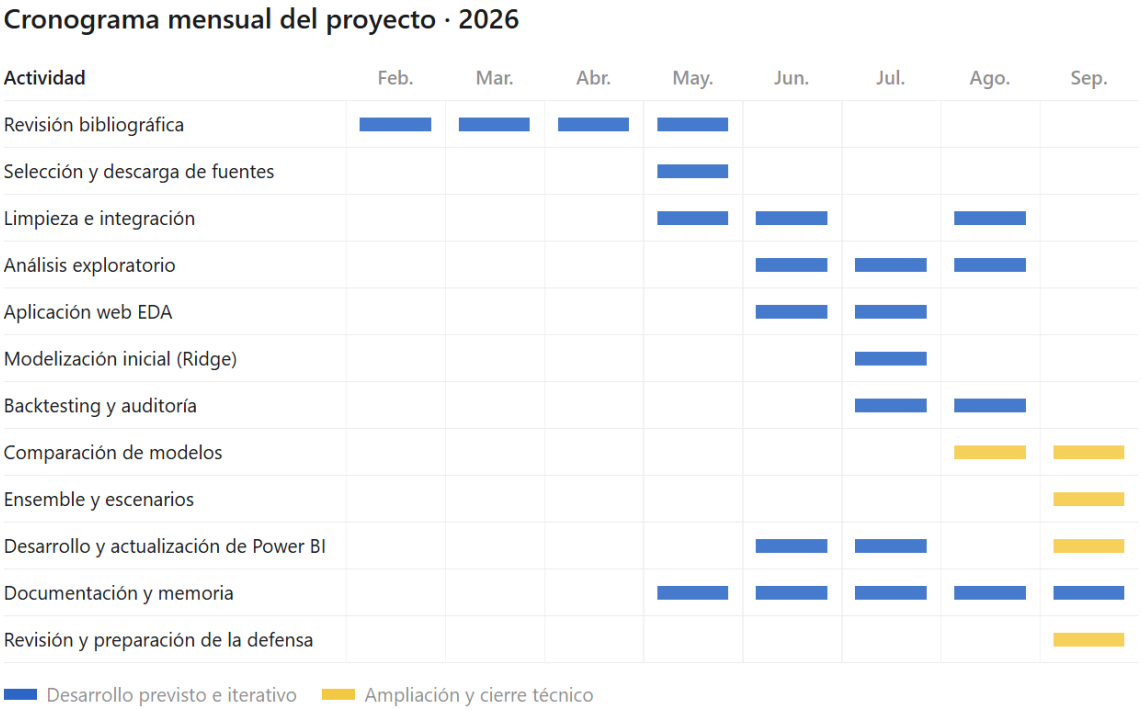
La siguiente tabla resume las actividades desarrolladas y los principales resultados obtenidos en cada fase:

2. Fases, actividades y resultados de la planificación del proyecto (Fuente: elaboración propia)

Fase	Periodo aproximado	Actividades principales	Resultado
Revisión bibliográfica	Febrero–mayo de 2026	Revisión de trabajos sobre automatización, IA generativa, exposición ocupacional y mercado laboral.	Marco teórico, pregunta de investigación y criterios metodológicos.
Selección y descarga de fuentes	Mayo de 2026	Selección de INE, AIOE y Anthropic; automatización de descargas y registro de incidencias.	Fuentes originales almacenadas en `data/raw`.
Limpieza e integración	Mayo–junio de 2026	Normalización, tratamiento de valores, creación de variables temporales y correspondencia CNO–SOC.	Panel integrado inicial y conjuntos procesados.
Análisis exploratorio	Junio–julio de 2026	Estudio del empleo, crecimiento, exposición a la IA y penetración por tareas.	Informe exploratorio y selección de variables.
Aplicación web	Junio–julio de 2026	Desarrollo del dashboard web y comprobación de filtros y visualizaciones.	Aplicación funcional de análisis exploratorio.
Modelización inicial	Julio de 2026	Desarrollo de Ridge, selección de regularización y primeras predicciones.	Primera versión del modelo predictivo.
Auditoría y corrección	Julio–agosto de 2026	Backtesting temporal, revisión de duplicados, agregaciones, correspondencias e indicadores de riesgo.	Pipeline corregido y resultados validados.
Ampliación técnica	Agosto–septiembre de 2026	Comparación de ocho enfoques, selección de hiperparámetros, bootstrap, importancia por permutación y ensemble.	Evaluación comparativa y escenarios predictivos definitivos.
Actualización de Power BI	Septiembre de 2026	Incorporación de métricas, backtesting, importancia de variables y escenarios del ensemble.	Cuadro de mando definitivo con cuatro páginas.
Documentación y redacción	Mayo–septiembre de 2026	Elaboración de la bitácora, guía de reproducibilidad, memoria y anexos.	Memoria y documentación técnica.
Revisión y preparación de la defensa	Septiembre de 2026	Revisión formal, actualización de índices y preparación de la presentación.	Versión final del TFM y material para la defensa.

Para representar gráficamente la planificación se elaboró el siguiente cronograma mensual:

1. Cronograma mensual de las actividades del proyecto (Fuente: elaboración propia)



La planificación inicial se modificó durante el desarrollo del proyecto. Las principales desviaciones estuvieron relacionadas con la complejidad de la correspondencia entre las clasificaciones CNO y SOC, la revisión de los indicadores de riesgo y la necesidad de ampliar la modelización inicial para comparar distintos enfoques predictivos. Estas circunstancias exigieron dedicar más tiempo del previsto a la validación, la interpretación de los resultados y la actualización de Power BI.

Sin embargo, estas revisiones permitieron mejorar la calidad final del trabajo. La estructura modular del pipeline facilitó repetir las etapas de procesamiento y modelización sin reconstruir manualmente el proyecto. De esta forma, las correcciones y ampliaciones se propagaron a los conjuntos procesados, las métricas de evaluación, los escenarios predictivos y las tablas destinadas a Power BI.

4.2 Descripción de la solución, metodologías y herramientas empleadas

4.2.1 Visión general y arquitectura de la solución

La solución desarrollada consiste en un sistema reproducible para integrar datos del mercado laboral español con indicadores internacionales de exposición ocupacional a la inteligencia artificial. El sistema permite adquirir, transformar y relacionar fuentes heterogéneas, analizar la evolución del empleo, comparar diferentes modelos predictivos, generar escenarios trimestrales y presentar los resultados mediante herramientas interactivas de visualización.

La arquitectura se diseñó de forma modular. Cada componente realiza una función concreta y genera archivos intermedios que pueden revisarse antes de continuar con la siguiente etapa. Esta separación facilita la detección de errores, la actualización de las fuentes y la repetición de los análisis sin necesidad de reconstruir manualmente todo el proyecto.

El flujo general de la solución se divide en seis capas:

1. Adquisición de datos. Descarga automatizada de las fuentes laborales y de los indicadores de exposición y utilización observada de inteligencia artificial.

2. Almacenamiento. Conservación separada de los archivos originales, los conjuntos transformados y los resultados de la modelización.

3. Preparación de datos. Limpieza, normalización, transformación temporal, tratamiento de valores ausentes y eliminación de duplicados.

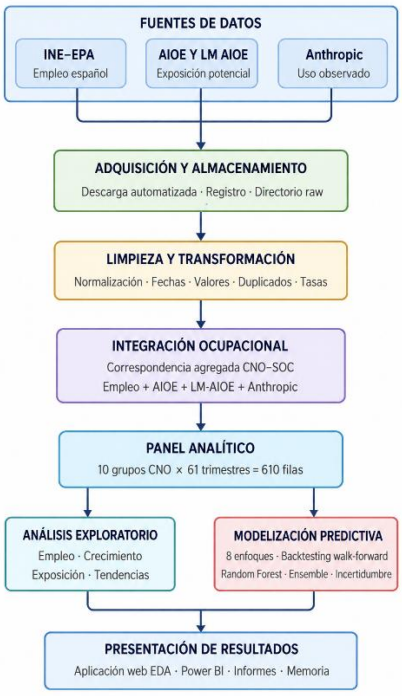
4. Integración ocupacional. Correspondencia agregada entre las clasificaciones CNO-11 y SOC y construcción del panel analítico.

5. Análisis y modelización. Análisis exploratorio, creación de variables, comparación de ocho enfoques predictivos, validación temporal y generación de escenarios mediante un ensemble ponderado.

6. Presentación de resultados. Generación de informes, aplicación web de análisis exploratorio y cuadro de mando interactivo en Power BI.

La representación general de la arquitectura se muestra en la figura correspondiente:

2. Arquitectura general y flujo de procesamiento de la solución (Fuente: elaboración propia)



Las fuentes de entrada se dividieron en dos grandes bloques. El primero contiene los datos oficiales de empleo procedentes de la Encuesta de Población Activa. El segundo está formado por los indicadores internacionales de exposición potencial y utilización observada procedentes de AIOE, LM AIOE y del Anthropic Economic Index. Esta separación se mantiene hasta la fase de integración para evitar mezclar conceptos diferentes antes de completar su limpieza y validación.

Los archivos originales se almacenan en el directorio data/raw, mientras que las tablas limpias, el panel integrado, las métricas de evaluación y los escenarios predictivos se guardan en data/processed. La documentación metodológica y los informes generados se encuentran en docs, el código fuente en scripts y los componentes de la aplicación web en dashboard.

3. Estructura de directorios y organización de archivos del proyecto (Fuente: elaboración propia)

```
TFM_MASTER/
│
├── data/                          Datos del proyecto
│   ├── raw/                       Datos originales
│   └── processed/                 Datos transformados, métricas y escenarios
│       └── model_comparison/      Evaluación y comparación de modelos
├── scripts/                       Descarga, integración y modelización
├── dashboard/                     Aplicación web de análisis exploratorio
├── docs/                          Documentación e informes técnicos
├── Visualizacion_V2.pbix          Cuadro de mando interactivo
└── TFM_Pedro_Ariznavarreta.docx   Memoria del proyecto
```

El componente de adquisición registra el resultado de cada descarga y conserva las fuentes originales. A continuación, el proceso de limpieza transforma los valores laborales, normaliza las variables, crea indicadores temporales e integra las métricas de exposición. La salida principal de esta etapa es el panel panel_ine_cno_ai_exposure.csv.

Este panel se utiliza como entrada del componente de modelización. El proceso genera las predicciones del backtesting, las métricas generales y desagregadas por grupo ocupacional, los resultados del ajuste de hiperparámetros, la importancia de variables por permutación y los escenarios del ensemble para los ocho horizontes trimestrales. También produce los límites predictivos y los indicadores exploratorios de contracción y riesgo ocupacional.

Entre los principales archivos generados para Power BI se encuentran:

- powerbi_dim_cno.csv, con la dimensión ocupacional;

- powerbi_fact_employment_history.csv, con el histórico de empleo;

- metricas_comparacion_modelos.csv, con las métricas generales;

- metricas_por_grupo_y_modelo.csv, con los errores por ocupación;

- predicciones_backtesting_todos_modelos.csv, con las predicciones fuera de muestra;

- importancia_variables_permutacion.csv, con la importancia predictiva;

- powerbi_fact_forecast_v2.csv, con los escenarios T+1 a T+8 del ensemble.

Estas tablas alimentan las cuatro páginas del cuadro de mando: resumen ejecutivo, análisis histórico, comparación de modelos y predicción exploratoria y riesgo ocupacional.

La ejecución de las principales etapas se coordina mediante un script general que ordena el procesamiento, la integración, la modelización y la generación de resultados. Si alguna validación crítica falla, el proceso se detiene para impedir que se produzcan resultados a partir de datos inconsistentes.

La arquitectura desarrollada no constituye una plataforma de procesamiento distribuido en sentido estricto. El volumen de información disponible puede tratarse en memoria mediante Python, pandas y NumPy. No obstante, se aplicaron principios propios de los proyectos de datos, como automatización, modularidad, separación entre datos originales y procesados, trazabilidad, validación y reproducibilidad.

El diseño permite incorporar nuevas observaciones trimestrales del INE y regenerar los resultados mediante la repetición del pipeline. También facilita sustituir o mejorar la correspondencia CNO–SOC y ampliar los modelos comparados, siempre que se conserve la estructura de entrada y salida esperada por los componentes posteriores.

La solución debe entenderse como una infraestructura analítica para estudiar asociaciones y elaborar predicciones exploratorias. La arquitectura no permite determinar que la inteligencia artificial haya causado los cambios observados en el empleo, ya que los indicadores de exposición son agregados y no representan una medida directa de adopción tecnológica en las empresas españolas.

4.2.2 Entorno tecnológico y herramientas utilizadas

El proyecto se desarrolló principalmente en un entorno local mediante una combinación de herramientas de código abierto, aplicaciones de escritorio y formatos de datos ampliamente compatibles. La selección tecnológica respondió a cuatro criterios principales: capacidad para procesar datos estructurados, facilidad de automatización, reproducibilidad y adecuación al volumen de información disponible sin necesidad de utilizar una infraestructura de elevado coste.

La herramienta principal fue Python, empleado para implementar la adquisición, limpieza, transformación, integración, análisis y modelización de los datos. Su elección se justificó por la disponibilidad de bibliotecas especializadas, su facilidad para trabajar con archivos CSV y XLSX y su amplia utilización en proyectos de ingeniería y ciencia de datos.

Las principales herramientas y tecnologías empleadas se resumen en la siguiente tabla:

3. Herramientas y tecnologías utilizadas en el proyecto (Fuente: elaboración propia)

Herramienta o tecnología	Aplicación en el proyecto
Python	Automatización del pipeline, procesamiento y modelado
pandas	Lectura, limpieza, transformación, agrupación e integración de datos
NumPy	Operaciones matemáticas, matrices y cálculo del modelo ridge
Biblioteca estándar de Python	Descarga de archivos, tratamiento de rutas, expresiones regulares y lectura de XML
HTML	Estructura del dashboard web
CSS	Diseño visual y adaptación de la interfaz
JavaScript	Interactividad, filtros y generación de gráficos
SVG	Representación de gráficos dentro del navegador
Power BI Desktop	Herramienta prevista para ampliar la visualización y explotación de los resultados
Microsoft Word	Redacción y presentación de la memoria
CSV y XLSX	Intercambio y almacenamiento de datos
Markdown	Documentación técnica e informes intermedios

Python

Python se utilizó como lenguaje central del proyecto. El código se dividió en varios scripts, de modo que cada uno fuera responsable de una parte concreta del proceso. Esta organización permitió ejecutar las fases de manera independiente durante el desarrollo y coordinarlas posteriormente mediante un script principal.

Los principales programas desarrollados fueron:

- download_data.py, encargado de descargar y registrar las fuentes;

- clean_and_link_data.py, responsable de limpiar, transformar e integrar los datos;

- train_forecast_model.py, utilizado para entrenar, validar y ejecutar el modelo predictivo;

- run_full_pipeline.py, encargado de ejecutar secuencialmente las etapas principales.

El uso de rutas construidas dinámicamente permite ejecutar los scripts desde el directorio raíz del proyecto sin depender de ubicaciones absolutas específicas. Esta decisión mejora la portabilidad del código.

pandas

La biblioteca pandas se empleó para la mayor parte del procesamiento tabular. Entre sus principales usos se encuentran:

- lectura y escritura de archivos CSV;

- normalización de nombres y tipos de variables;

- conversión de periodos a fechas;

- ordenación de series temporales;

- eliminación de duplicados;

- tratamiento de valores ausentes;

- agrupación por ocupación y periodo;

- cálculo de variaciones trimestrales e interanuales;

- integración de tablas mediante claves comunes;

- generación de datasets destinados a Power BI.

Pandas también permitió construir el panel analítico y comprobar que cada combinación de grupo CNO y trimestre apareciera una única vez.

NumPy

NumPy se utilizó para las operaciones numéricas necesarias durante el modelado. La regresión ridge se implementó mediante operaciones matriciales, aplicando una penalización a los coeficientes para reducir su inestabilidad.

También se utilizó para:

- transformaciones logarítmicas;

- estandarización de variables;

- generación de variables trigonométricas para representar la estacionalidad;

- cálculo de errores y residuos;

- obtención de percentiles empíricos;

- construcción de intervalos predictivos.

La implementación directa del modelo permitió controlar de forma transparente el procedimiento de ajuste y evitar dependencias adicionales para un problema de tamaño reducido.

Bibliotecas de la distribución estándar

Además de pandas y NumPy, se utilizaron módulos incluidos en la distribución estándar de Python. Entre ellos se encuentran:

- pathlib, para la gestión de directorios y archivos;

- urllib, para la descarga automatizada de fuentes;

- csv, para registrar el resultado de las descargas;

- datetime, para generar marcas temporales;

- re, para normalizar textos y extraer códigos ocupacionales;

- zipfile y xml.etree.ElementTree, para leer el contenido interno de determinados archivos XLSX;

- subprocess, para coordinar la ejecución secuencial del pipeline.

La lectura directa de los archivos XLSX mediante su estructura XML interna permitió procesar los ficheros de AIOE sin depender de una aplicación externa de hoja de cálculo durante la ejecución.

HTML, CSS y JavaScript

El dashboard local se desarrolló mediante tecnologías web estándar. HTML se utilizó para definir la estructura de la interfaz, CSS para establecer su diseño y JavaScript para cargar, filtrar y representar los datos.

La lógica implementada en JavaScript permite:

- cargar el panel desde un archivo CSV;

- interpretar los tipos de las variables;

- seleccionar periodos y años;

- filtrar por categoría de exposición;

- buscar ocupaciones;

- recalcular los indicadores;

- actualizar dinámicamente los gráficos y la tabla de resultados.

Las visualizaciones se construyeron mediante elementos SVG generados desde JavaScript. Esta decisión evitó depender de bibliotecas gráficas externas y permitió mantener el dashboard como una solución ligera, ejecutable mediante un servidor web local.

Microsoft Power BI

Como complemento de la aplicación web, se desarrolló un informe interactivo en Microsoft Power BI Desktop. El modelo analítico incorpora una dimensión ocupacional, una dimensión de modelos y diferentes tablas de hechos con el histórico de empleo, las predicciones del backtesting, las métricas de evaluación, los errores por grupo y los escenarios generados mediante el ensemble.

El archivo definitivo Visualizacion_V2.pbix contiene cuatro páginas:

- Resumen ejecutivo, con los principales indicadores de empleo, exposición y crecimiento;

- Análisis histórico de empleo, destinada a examinar la evolución temporal y comparar los grupos ocupacionales;

- Comparación y evaluación de modelos predictivos, con las métricas fuera de muestra, la importancia de variables y los errores por grupo;

- Predicción exploratoria y riesgo ocupacional, con los escenarios T+1 a T+8, la distribución del empleo previsto por riesgo y la frecuencia empírica ponderada de contracción.

También se crearon medidas DAX, relaciones entre tablas, filtros interactivos y textos metodológicos para facilitar la interpretación de los resultados. El pipeline genera los archivos CSV utilizados por Power BI, lo que permite actualizar las fuentes cuando se incorporen nuevos

periodos. No obstante, la actualización y publicación del archivo PBIX deben realizarse desde Power BI Desktop.

Microsoft Word, Markdown y LaTeX

Microsoft Word se utilizó para elaborar la memoria académica siguiendo la plantilla proporcionada por la universidad. Los documentos técnicos intermedios se redactaron en Markdown debido a su sencillez y facilidad de mantenimiento.

La documentación en Markdown incluye la bitácora de datos, el informe exploratorio, la guía de reproducibilidad, la explicación del modelo y la auditoría de las correcciones realizadas. Posteriormente, la información relevante se trasladó y adaptó a la memoria.

LaTeX se utilizó como apoyo para representar las ecuaciones matemáticas y componer determinadas tablas técnicas incorporadas al documento. Su utilización se limitó a estos elementos y no constituyó el entorno principal de redacción de la memoria.

Entorno de ejecución

El proyecto se ejecutó en un ordenador personal con sistema operativo Windows. Todo el procesamiento se realizó localmente, sin utilizar servidores externos ni servicios de computación en la nube. Esta decisión redujo los costes y facilitó el control de los datos y los archivos generados.

El entorno tecnológico fue suficiente para el volumen de información utilizado. Aunque el TFM se enmarca en un máster de Big Data, la selección de herramientas se ajustó al tamaño real del problema. El uso de una infraestructura distribuida habría añadido complejidad sin aportar una mejora significativa para los conjuntos de datos disponibles.

En conjunto, las herramientas seleccionadas permitieron construir una solución automatizada, modular y reproducible. La utilización de tecnologías abiertas para el procesamiento facilita que el código pueda revisarse, modificarse y ejecutarse nuevamente cuando se actualicen las fuentes de datos, mientras que Word y Power BI proporcionan los entornos necesarios para comunicar los resultados académicos y analíticos.

4.2.3 Adquisición y organización de los datos

La adquisición de los datos se diseñó como un proceso automatizado y reproducible. El objetivo fue evitar descargas manuales, conservar una copia de cada archivo original y registrar las posibles incidencias producidas durante el acceso a las fuentes.

El proceso se implementó mediante el script download_data.py. Para cada fuente se definieron los siguientes elementos:

- nombre identificativo;

- dirección de descarga;

- nombre del archivo de destino;

- institución o entidad responsable;

- finalidad del conjunto de datos dentro del proyecto.

El script realiza una petición HTTP a cada dirección y almacena el contenido recibido en el directorio data/raw. En las peticiones se incorpora una cabecera de identificación para mejorar la compatibilidad con aquellos servidores que restringen las solicitudes automatizadas.

Cada operación queda registrada en el archivo docs/download_log.csv. Este registro contiene la fecha y hora, la fuente, la dirección de acceso, el nombre del archivo, el estado de la descarga, el tamaño y, cuando corresponde, el mensaje de error. Esta información permite comprobar la procedencia de los datos e identificar fuentes que hayan dejado de estar disponibles o cuya estructura haya cambiado.

Las seis fuentes descargadas correctamente e incorporadas al proyecto fueron las siguientes:

4. Fuentes de datos y archivos originales incorporados al proyecto (Fuente: elaboración propia)

Fuente	Archivo original	Contenido
INE–EPA, tabla 65136	`ine_epa_ocupados_situacion_sexo_ocupacion_65136.csv`	Empleo por situación profesional, sexo y ocupación
INE–EPA, tabla 65135	`ine_epa_ocupados_edad_sexo_ocupacion_65135.csv`	Empleo por edad, sexo y ocupación
AIOE Data Appendix	`aioe_data_appendix.xlsx`	Exposición general a inteligencia artificial
Language Modeling AIOE	`aioe_language_modeling.xlsx`	Exposición específica a modelos de lenguaje
Anthropic Job Exposure	`anthropic_job_exposure.csv`	Exposición observada por ocupación
Anthropic Task Penetration	`anthropic_task_penetration.csv`	Penetración observada por tarea

Durante la primera ejecución, estas seis fuentes se descargaron correctamente. También se intentó incorporar una fuente de habilidades laborales de la Oficina de Estadísticas Laborales de Estados Unidos. Sin embargo, el servidor devolvió una respuesta HTTP 403, por lo que el archivo no se integró en la versión final del proyecto. La incidencia se conservó en el registro de descarga para mantener la trazabilidad del proceso.

Los archivos almacenados en data/raw no se modifican durante el procesamiento. Las transformaciones se realizan en memoria y se exportan como nuevos archivos dentro de data/processed. De esta manera, cualquier resultado puede contrastarse con la información original.

La organización de los archivos procesados sigue una secuencia lógica. En primer lugar, se generan las versiones limpias de cada fuente:

- ine_employment_by_situation_clean.csv;

- ine_employment_by_age_clean.csv;

- aioe_occupation_exposure_clean.csv;

- anthropic_job_exposure_clean.csv;

- anthropic_task_penetration_clean.csv.

A continuación, se crean las tablas de integración:

- soc_ai_exposure_integrated.csv, con las medidas de exposición relacionadas mediante el código SOC;

- cno_ai_exposure_proxy.csv, con los indicadores agregados para los grandes grupos CNO;

- panel_ine_cno_ai_exposure.csv, utilizado como conjunto principal del análisis exploratorio y predictivo.

Los resultados de la comparación de modelos se almacenan en el subdirectorio data/processed/model_comparison. Entre sus principales archivos se encuentran:

- ajuste_hiperparametros.csv, con las configuraciones evaluadas durante la validación;

- predicciones_backtesting_todos_modelos.csv, con las predicciones fuera de muestra de los ocho enfoques;

- metricas_comparacion_modelos.csv, con los valores de RMSE, MAE, R^2 y mejora frente al crecimiento cero;

- metricas_por_grupo_y_modelo.csv, con los errores desagregados por modelo y grupo ocupacional;

- importancia_variables_permutacion.csv, con la importancia predictiva de las variables;

- previsiones_ensemble_8_trimestres.csv, con los escenarios generados para los horizontes T+1 a T+8;

- configuracion_modelos.json, con los hiperparámetros seleccionados, los pesos del ensemble y los resultados del análisis de robustez.

Para alimentar el cuadro de mando de Power BI se generan o utilizan principalmente los siguientes archivos:

- powerbi_dim_cno.csv, como dimensión ocupacional;

- powerbi_fact_employment_history.csv, con el histórico trimestral de empleo;

- powerbi_fact_forecast_v2.csv, con los escenarios del ensemble entre T+1 y T+8;

- powerbi_fact_risk_summary_v2.csv, con los indicadores correspondientes al horizonte más próximo;

- metricas_comparacion_modelos.csv, para la comparación general de los algoritmos;

- metricas_por_grupo_y_modelo.csv, para analizar los errores por ocupación;

- predicciones_backtesting_todos_modelos.csv, para comparar los valores observados y predichos;

- importancia_variables_permutacion.csv, para mostrar la contribución predictiva de las variables.

Los archivos correspondientes a la primera versión basada en Ridge se conservaron como evidencia del desarrollo iterativo y para mantener la trazabilidad, pero las visualizaciones

predictivas definitivas emplean las salidas identificadas como v2 y los resultados almacenados en model_comparison.

La separación entre archivos originales, transformaciones intermedias y resultados finales facilita el seguimiento del linaje de los datos. Por ejemplo, una predicción puede relacionarse con una observación del panel; esta, con una serie limpia del INE y, finalmente, con el archivo original descargado.

El proceso de descarga no se incluyó dentro de la ejecución ordinaria del pipeline completo. Esta decisión evita sustituir automáticamente los datos originales cada vez que se ejecuta la modelización. La actualización de las fuentes se realiza de forma deliberada mediante download_data.py y, posteriormente, se pone en marcha el procesamiento a través de run_full_pipeline.py.

Esta organización permite actualizar el proyecto cuando el INE publique un nuevo trimestre. El procedimiento consiste en descargar nuevamente las fuentes, revisar el registro de ejecución y lanzar el pipeline. Si la estructura de los archivos no ha cambiado, los conjuntos procesados, las métricas de evaluación, los escenarios predictivos y las exportaciones destinadas a las herramientas de visualización pueden regenerarse automáticamente.

La estrategia adoptada garantiza un nivel adecuado de trazabilidad para el alcance del proyecto. No obstante, la reproducibilidad también depende de la permanencia de las direcciones de descarga y de que las entidades proveedoras mantengan la estructura de sus archivos. Por esta razón, se conservan localmente las versiones utilizadas para generar los resultados incluidos en el TFM.

4.2.4 Procesamiento y transformación de los datos

Una vez almacenadas las fuentes originales, se ejecutó el proceso de preparación mediante el script clean_and_link_data.py. Esta etapa tuvo como objetivo transformar archivos con estructuras, formatos y clasificaciones diferentes en conjuntos homogéneos que pudieran integrarse y analizarse de forma conjunta.

El procesamiento se organizó mediante funciones independientes para cada fuente. Esta estructura modular permitió aplicar reglas específicas a los datos del INE, AIOE y Anthropic sin mezclar sus transformaciones. Las tablas resultantes se combinaron únicamente después de completar su limpieza y validación individual.

Tratamiento de los datos del INE

Los archivos de la Encuesta de Población Activa se recibieron en formato CSV y utilizaban el punto y coma como separador. Todas las columnas se cargaron inicialmente como texto para evitar conversiones automáticas incorrectas, especialmente en los valores numéricos escritos según el formato español.

Los nombres de las variables se normalizaron mediante las siguientes operaciones:

- conversión a minúsculas;

- eliminación de espacios al principio y al final;

- sustitución de vocales acentuadas y de la letra ñ;

- eliminación de caracteres especiales;

- sustitución de espacios y separadores por guiones bajos.

Como resultado, los encabezados quedaron representados mediante el formato snake_case. Esta transformación facilitó su utilización posterior en Python y evitó errores relacionados con espacios, acentos o diferencias entre mayúsculas y minúsculas.

Los valores de empleo del INE estaban expresados en miles de personas y empleaban separadores españoles. Para convertirlos a valores numéricos se eliminaron los puntos utilizados como separadores de miles y se sustituyeron las comas decimales por puntos. Los campos vacíos y los símbolos empleados por el INE para representar información no disponible se transformaron en valores ausentes.

Los periodos aparecían originalmente mediante expresiones como 2026T1. Estas cadenas se dividieron para extraer el año y el trimestre y se transformaron en fechas correspondientes al final de cada periodo trimestral. También se generaron variables independientes de año y trimestre.

El gran grupo CNO se extrajo de la descripción textual de la ocupación. Los registros correspondientes al total agregado se identificaron mediante una categoría específica para evitar que fueran confundidos con un grupo ocupacional.

Después de ordenar las observaciones por sexo, situación profesional, grupo CNO y fecha, se calcularon las variaciones trimestrales e interanuales. Para ello se utilizaron únicamente observaciones pertenecientes a la misma combinación de categorías.

La variación trimestral se calculó como:

$$g_{i,t}^{QoQ} = \left(\frac{E_{i,t}}{E_{i,t-1}} - 1 \right) \times 100$$

donde Ei,t representa el empleo del grupo ocupacional i durante el trimestre t.

La variación interanual se calculó mediante:

$$g_{i,t}^{YoY} = \left(\frac{E_{i,t}}{E_{i,t-4}} - 1 \right) \times 100$$

La comparación interanual reduce parcialmente la influencia de la estacionalidad, ya que relaciona cada observación con el mismo trimestre del año anterior. Las observaciones iniciales para las que no existían los retardos necesarios conservaron un valor ausente en estas variables.

Para construir el panel principal se seleccionaron las observaciones correspondientes a ambos sexos y al total de situaciones profesionales. También se excluyó el total agregado de todas las

ocupaciones, puesto que su inclusión duplicaría el empleo ya distribuido entre los diez grandes grupos CNO.

Tratamiento de los indicadores AIOE

Los datos AIOE se obtuvieron mediante dos archivos XLSX. El primero contenía la puntuación general de exposición ocupacional a la inteligencia artificial y el segundo incluía una medida específica de exposición a modelos de lenguaje.

Los archivos se leyeron a partir de su estructura XML interna. Para ello, se identificaron las hojas correspondientes, se recuperaron las cadenas compartidas y se reconstruyeron las filas y columnas de cada tabla.

Los nombres de las principales columnas se adaptaron a la nomenclatura del proyecto:

- soc_code;

- soc_title;

- aioe_score;

- language_modeling_aioe_score.

Las puntuaciones se convirtieron a valores numéricos y ambas tablas se relacionaron utilizando el código SOC como clave. A partir de este código se extrajeron los dos primeros dígitos para obtener el gran grupo SOC.

La tabla limpia de AIOE quedó formada por 774 ocupaciones SOC únicas. Para cada una se conservaron el código, la denominación, la puntuación general de exposición, la exposición específica a modelos de lenguaje y el gran grupo SOC.

Tratamiento de los datos de Anthropic

Los datos del Anthropic Economic Index se procesaron mediante dos conjuntos diferentes. El archivo de exposición por ocupación contenía códigos SOC e indicadores de utilización observada. Sus variables se renombraron para mantener una nomenclatura coherente y se extrajo el gran grupo SOC.

Posteriormente, se eliminaron los posibles códigos ocupacionales duplicados, conservando una única observación por código. La tabla resultante se integró con AIOE mediante soc_code.

El archivo de penetración por tarea se utilizó como fuente complementaria para el análisis descriptivo. La variable de penetración se convirtió a formato numérico y se eliminaron los registros exactamente duplicados. Después de esta operación se conservaron 17.992 tareas únicas.

Integración de los indicadores SOC

Las puntuaciones AIOE, LM AIOE y el indicador observado de Anthropic se combinaron en una tabla integrada a nivel SOC. La integración se realizó mediante una unión izquierda, tomando AIOE como conjunto principal. De este modo, se mantuvieron todas las ocupaciones AIOE aunque alguna no dispusiera de información equivalente en Anthropic.

Para facilitar la comparación entre indicadores expresados en escalas diferentes, se calcularon percentiles relativos:

$$P_i = \frac{rango_i}{N} \times 100$$

donde rango_i representa la posición de la ocupación dentro de la distribución y N es el número de observaciones válidas.

Los percentiles obtenidos no representan probabilidades ni porcentajes de tareas automatizables. Únicamente expresan la posición relativa de cada ocupación respecto al resto de las ocupaciones incluidas en cada fuente.

Generación de archivos procesados

Cada transformación generó un archivo independiente en data/processed. Esta decisión permitió revisar las etapas intermedias y localizar con mayor facilidad cualquier error.

Las principales salidas de limpieza y transformación fueron:

- datos del INE limpios por situación profesional;

- datos del INE limpios por edad;

- exposición AIOE por ocupación SOC;

- utilización observada de Anthropic por ocupación SOC;

- penetración de Anthropic por tarea;

- exposición integrada a nivel SOC.

A partir de estas tablas, la fase posterior de correspondencia ocupacional generó la exposición agregada a nivel CNO y el panel definitivo de empleo y exposición.

El procedimiento se diseñó para que las transformaciones fueran deterministas. Partiendo de los mismos archivos originales y utilizando la misma versión del código, el pipeline genera las mismas tablas procesadas.

No se aplicaron técnicas de imputación estadística sobre los valores ausentes de exposición dentro del panel descriptivo. Cuando una ocupación o grupo no disponía de una medida equivalente, el valor se mantuvo como ausente y su categoría se identificó como sin_categoria.

Para construir la matriz numérica utilizada por los modelos, los valores ausentes de exposición se codificaron operativamente como cero y se incorporaron variables indicadoras del grupo CNO. Esta decisión permitió procesar las ocupaciones sin puntuación equivalente, especialmente las ocupaciones militares, pero no debe interpretarse como una estimación de exposición nula. La ausencia de una puntuación comparable continúa siendo una limitación del análisis.

El resultado de esta etapa fue un conjunto de tablas limpias, estructuradas y validadas, preparadas para aplicar la correspondencia entre CNO-11 y SOC, construir el panel analítico definitivo y ejecutar posteriormente la comparación de modelos.

4.2.5 Integración entre las clasificaciones CNO y SOC

La integración de los datos laborales españoles con los indicadores internacionales de exposición a la inteligencia artificial requirió relacionar dos sistemas de clasificación ocupacional diferentes. La Encuesta de Población Activa utiliza la Clasificación Nacional de Ocupaciones de 2011, mientras que AIOE y el Anthropic Economic Index emplean la clasificación estadounidense SOC.

La CNO-11 y la clasificación SOC no presentan una equivalencia directa. Aunque ambas organizan las ocupaciones según el tipo de trabajo desarrollado, utilizan estructuras, niveles de detalle y criterios de agrupación diferentes. Por tanto, los códigos de una clasificación no pueden sustituirse directamente por los de la otra.

Una correspondencia más detallada habría requerido construir una cadena de conversión entre CNO-11, ISCO-08 y SOC mediante tablas oficiales y ocupaciones desagregadas. Sin embargo, las fuentes utilizadas no compartían el mismo nivel de detalle y la unidad principal del análisis estaba formada por los diez grandes grupos ocupacionales. Por esta razón, se adoptó una correspondencia agregada basada en la similitud semántica y funcional entre los grandes grupos CNO y las familias SOC relacionadas.

La correspondencia utilizada fue la siguiente:

5. Correspondencia agregada entre los grandes grupos CNO-11 y SOC (Fuente: elaboración propia)

Gran grupo CNO	Denominación resumida	Grandes grupos SOC asignados
0	Ocupaciones militares	55
1	Directores y gerentes	11
2	Profesionales científicos e intelectuales	15, 17, 19, 23, 25, 27 y 29
3	Técnicos y profesionales de apoyo	13, 21, 27 y 29
4	Empleados administrativos y de oficina	43
5	Trabajadores de servicios y vendedores	31, 33, 35, 37, 39 y 41
6	Trabajadores cualificados del sector agrícola	45
7	Artesanos, industria y construcción	47, 49 y 51
8	Operadores de instalaciones y maquinaria	51 y 53
9	Ocupaciones elementales	35, 37, 45 y 53

La asignación se realizó atendiendo a la similitud general entre las familias ocupacionales. Por ejemplo, el grupo CNO de directores y gerentes se relacionó con el gran grupo SOC 11, correspondiente a ocupaciones de gestión. Los profesionales científicos e intelectuales se asociaron con familias SOC relacionadas con informática, ingeniería, ciencias, educación, derecho, salud y comunicación.

Algunos grandes grupos SOC se asignaron a más de un grupo CNO. Esta situación se produjo porque ambas clasificaciones delimitan las ocupaciones de manera diferente. Determinadas familias profesionales o productivas pueden contener perfiles que, dentro de la clasificación española, se distribuyen entre profesionales, técnicos, trabajadores cualificados, operadores u ocupaciones elementales.

Estos solapamientos no producen duplicados dentro de cada grupo CNO, puesto que cada código SOC se contabiliza una sola vez al calcular su exposición. Sin embargo, una misma ocupación SOC puede contribuir a la estimación de más de un grupo CNO. Por este motivo, no resulta correcto sumar las asignaciones y presentarlas como si fueran ocupaciones diferentes.

El conjunto procesado contiene 774 ocupaciones SOC únicas. La suma de las ocupaciones asociadas a los distintos grupos CNO asciende a 1.057 asignaciones debido a los solapamientos. Ambos valores se conservaron de forma diferenciada en la documentación y en los controles de calidad.

Para cada gran grupo CNO se seleccionaron las ocupaciones SOC pertenecientes a las familias asociadas. A continuación, se calculó la media aritmética de las puntuaciones disponibles:

$$Exposición_c = \frac{1}{N_c} \sum_{j=1}^{N_c} Exposición_j$$

donde Exposición_c representa el indicador agregado del grupo CNO c, N_c es el número de ocupaciones SOC únicas asociadas y Exposición_j es la puntuación correspondiente a cada ocupación SOC.

El cálculo se aplicó de manera independiente a tres indicadores:

- exposición general AIOE;

- exposición específica a modelos de lenguaje;

- utilización observada procedente de Anthropic.

El promedio se realizó directamente sobre las ocupaciones SOC únicas. En una versión inicial se habían calculado primero medias por gran grupo SOC y, posteriormente, una media entre esos resultados. Este procedimiento concedía el mismo peso a grupos formados por cantidades diferentes de ocupaciones. La versión definitiva corrigió esta limitación y asignó el mismo peso a cada ocupación SOC dentro de su correspondencia CNO.

Después de calcular las puntuaciones agregadas, se obtuvieron percentiles relativos para los grupos CNO. La clasificación principal se basó en el percentil de exposición a modelos de

lenguaje, por ser el indicador más directamente relacionado con las capacidades de la inteligencia artificial generativa.

Los grupos se distribuyeron en tres categorías mediante los siguientes intervalos:

- exposición baja: percentil igual o inferior a 33,333;

- exposición media: percentil superior a 33,333 e igual o inferior a 66,666;

- exposición alta: percentil superior a 66,666.

Estas categorías representan posiciones relativas dentro del conjunto de grandes grupos analizados. No significan que una ocupación clasificada con exposición alta vaya a desaparecer ni que una categoría baja esté libre de posibles transformaciones tecnológicas.

La tabla resultante incluyó las siguientes variables:

- código del gran grupo CNO;

- grandes grupos SOC asociados;

- número de ocupaciones SOC utilizadas;

- puntuación media AIOE;

- puntuación media de exposición a modelos de lenguaje;

- utilización observada media de Anthropic;

- percentiles relativos;

- categoría de exposición.

En el caso de las ocupaciones militares, no se encontraron observaciones AIOE correspondientes al grupo SOC 55 dentro del archivo utilizado. Por ello, sus indicadores se mantuvieron como valores ausentes y el grupo se clasificó como sin_categoria en las etapas posteriores. No se aplicó una imputación descriptiva porque habría supuesto atribuir una exposición sin respaldo empírico.

La tabla de exposición agregada se integró posteriormente con las series del INE mediante el código del gran grupo CNO. Dado que los indicadores de exposición se mantienen constantes durante el periodo estudiado, cada grupo conserva la misma puntuación en todos los trimestres. Las variaciones temporales del panel proceden, por tanto, de los datos de empleo y no de cambios trimestrales en la exposición o adopción tecnológica.

Esta característica limita la capacidad para estudiar la evolución de la adopción de inteligencia artificial. El panel permite comparar grupos con distintos niveles estructurales de exposición, pero no mide cómo cambia el uso de esta tecnología en las empresas españolas durante cada trimestre.

La correspondencia CNO–SOC debe interpretarse como una aproximación metodológica destinada a realizar un análisis exploratorio a gran escala. No constituye una tabla de equivalencias oficial ni permite trasladar automáticamente los resultados a ocupaciones

individuales. Esta limitación se tendrá en cuenta durante la interpretación y discusión de los resultados.

4.2.6 Construcción del panel analítico

Una vez procesadas las fuentes y calculados los indicadores agregados de exposición, se construyó el panel analítico utilizado en las fases posteriores. Su finalidad fue reunir en una misma estructura la evolución trimestral del empleo y las características de exposición a la inteligencia artificial de cada gran grupo ocupacional.

La unidad de análisis se definió como la combinación:

$$grangrupoCNO + periodotrimestral$$

Esta elección permitió tratar cada grupo ocupacional como una serie temporal y comparar su evolución con la del resto de los grupos.

Selección de observaciones laborales

La tabla de empleo por situación profesional contenía información desagregada por sexo, ocupación y relación laboral. Para evitar duplicidades se aplicaron los siguientes filtros:

- sexo igual a «Ambos sexos»;

- situación profesional igual a «Total»;

- exclusión del total agregado de todas las ocupaciones;

- conservación de los diez grandes grupos CNO.

Después de aplicar estos criterios, cada gran grupo quedó representado una sola vez en cada trimestre. El panel abarca desde 2011T1 hasta 2026T1, lo que proporciona 61 periodos trimestrales.

La dimensión resultante puede expresarse como:

$$10\ gruposCNO \times 61\ trimestres = 610\ observaciones$$

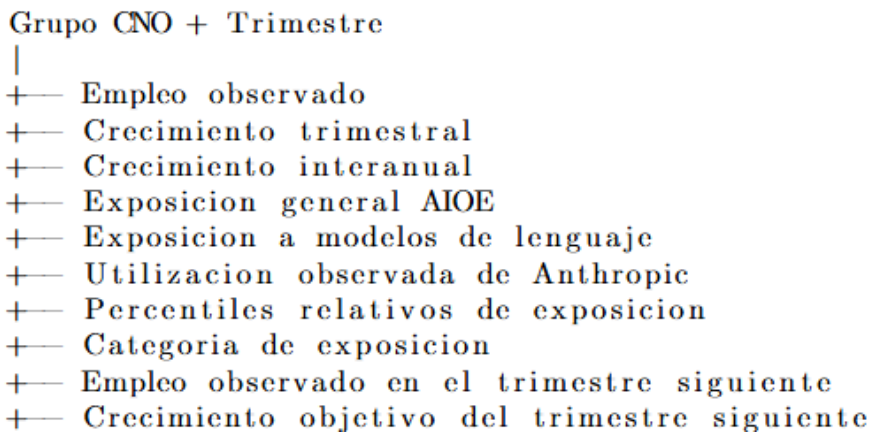
Integración de los indicadores de exposición

La tabla laboral se combinó con la tabla de exposición mediante la variable cno_major. La unión añadió a cada observación trimestral las puntuaciones, los percentiles y la categoría correspondientes a su gran grupo ocupacional.

Las variables de exposición permanecen constantes en el tiempo porque las fuentes AIOE y Anthropic utilizadas proporcionan indicadores estructurales y no series históricas trimestrales. Por el contrario, el empleo y sus tasas de variación cambian en cada periodo.

La estructura conceptual del panel queda formada por los siguientes componentes:

4. Estructura conceptual del panel analítico integrado (Fuente: elaboración propia)



Variables incluidas

Las variables principales del panel fueron las siguientes:

6. Variables principales del panel analítico integrado (Fuente: elaboración propia)

Variable	Tipo	Descripción
periodo	Temporal	Periodo original en formato YYYYTn.
period_date	Temporal	Fecha correspondiente al final del trimestre.
year	Numérica	Año de la observación.
quarter	Numérica	Número de trimestre, entre 1 y 4.
cno_major	Categórica	Código del gran grupo CNO.
cno_title	Categórica	Denominación resumida del grupo ocupacional.
employment_thousand_people	Numérica	Empleo observado, expresado en miles de personas.
employment_qoq_pct	Numérica	Variación porcentual respecto al trimestre anterior.
employment_yoy_pct	Numérica	Variación porcentual respecto al mismo trimestre del año anterior.
mapped_soc_majors	Categórica	Grandes grupos SOC utilizados en la correspondencia.
mapped_soc_occupations	Numérica	Número de ocupaciones SOC únicas asociadas.
aioe_score_cno_proxy	Numérica	Exposición general media a la inteligencia artificial.
language_modeling_aioe_score_cno_proxy	Numérica	Exposición media a modelos de lenguaje.
anthropic_observed_exposure_cno_proxy	Numérica	Utilización observada media según Anthropic.
aioe_percentile_cno_proxy	Numérica	Percentil relativo de exposición AIOE.
language_modeling_percentile_cno_proxy	Numérica	Percentil relativo de exposición a modelos de lenguaje.
anthropic_percentile_cno_proxy	Numérica	Percentil relativo del indicador de Anthropic.
ai_exposure_category	Categórica	Categoría baja, media, alta o sin categoría.
employment_next_quarter_thousand_people	Numérica	Empleo observado durante el trimestre siguiente.
employment_growth_next_quarter_pct	Numérica	Crecimiento porcentual del empleo durante el trimestre siguiente.

El panel conserva también algunas variables descriptivas procedentes del INE, como sexo, situación profesional, denominación completa de la ocupación y valor original. Aunque después

del filtrado algunas adoptan valores constantes, se mantuvieron para preservar la trazabilidad respecto a la fuente.

Creación de la variable objetivo

Para desarrollar los modelos era necesario conocer el crecimiento del empleo durante el trimestre siguiente. Las observaciones se ordenaron cronológicamente dentro de cada grupo CNO y se aplicó un desplazamiento de un periodo hacia el futuro para generar:

$$E_{i,t+1}$$

que representa el empleo del grupo i durante el trimestre posterior. Después se calculó la variable objetivo:

$$y_{i,t} = \frac{E_{i,t+1} - E_{i,t}}{E_{i,t}} \times 100$$

Esta variable se almacenó como employment_growth_next_quarter_pct. Las características correspondientes al trimestre t se utilizaron para estimar el crecimiento observado entre t y t+1. De esta forma, las variables predictoras no incorporan información del trimestre que se pretende anticipar.

Por ejemplo, la observación correspondiente a 2025T4 contiene como objetivo el crecimiento experimentado entre 2025T4 y 2026T1. Las diez observaciones de 2026T1 no disponen de variable objetivo porque no existe un trimestre posterior dentro del conjunto descargado. Estas filas se mantienen en el panel como origen de los escenarios futuros, pero se excluyen del entrenamiento y del backtesting.

En consecuencia, el panel contiene:

- 610 observaciones totales;

- 600 observaciones con variable objetivo conocida;

- 10 observaciones finales sin objetivo, utilizadas como origen predictivo.

Tratamiento de valores ausentes

Los primeros trimestres de cada grupo presentan valores ausentes en algunas variables temporales:

- el primer trimestre no dispone de una variación trimestral previa;

- los cuatro primeros trimestres no disponen de comparación interanual;

- el último trimestre no dispone de crecimiento futuro conocido.

Estos valores ausentes son consecuencia natural de las operaciones temporales y no representan errores de calidad. Durante el análisis descriptivo se mantienen como ausentes.

Para construir la matriz de los modelos, las variaciones históricas no disponibles se codificaron como cero. Esta es una convención operativa para permitir el procesamiento de las observaciones iniciales y no una imputación basada en una estimación estadística.

Las exposiciones de las ocupaciones militares también se mantienen como ausentes en el panel debido a la falta de observaciones AIOE para el grupo SOC 55. En la matriz numérica de los modelos se codificaron como cero, mientras que el grupo se identificó mediante su variable indicadora CNO y conservó la categoría sin_categoria. Esta decisión no implica que su exposición real sea nula y debe considerarse una limitación metodológica.

Validación estructural

Antes de exportar el panel se aplicaron las siguientes comprobaciones:

- presencia de los diez grandes grupos CNO;

- ausencia de claves duplicadas;

- existencia de 61 trimestres para cada grupo;

- orden cronológico correcto;

- conservación del empleo en miles de personas;

- ausencia de duplicados en las tablas de exposición;

- correspondencia única entre cada gran grupo CNO y su fila de exposición.

La clave lógica del panel está formada por:

$$cno_major + periodo$$

La verificación confirmó que las 610 combinaciones eran únicas. También se comprobó que el empleo total del último periodo ascendía a 22.292,8 miles de personas, equivalente aproximadamente a 22,29 millones de personas ocupadas.

Exportación del panel

El resultado se almacenó en:

data/processed/panel_ine_cno_ai_exposure.csv

Este archivo constituye la fuente principal del análisis exploratorio, la aplicación web y el proceso de modelización. A partir de él también se generan el histórico destinado a Power BI, las predicciones del backtesting, las métricas de comparación y los escenarios futuros del ensemble.

La construcción del panel permitió reunir información laboral y tecnológica en una estructura común. Sin embargo, debe recordarse que las puntuaciones de exposición son aproximaciones internacionales constantes en el tiempo. Por ello, el panel resulta adecuado para estudiar asociaciones, diferencias relativas y escenarios predictivos, pero no para estimar directamente la adopción trimestral de inteligencia artificial en España.

4.2.7 Metodología del análisis exploratorio

El análisis exploratorio tuvo como finalidad comprobar la calidad del panel integrado, describir la evolución del empleo e identificar posibles patrones relacionados con la exposición ocupacional a la inteligencia artificial. Antes de analizar los resultados se verificaron la cobertura temporal, la ausencia de claves duplicadas, la presencia de los diez grandes grupos CNO, la igualdad del número de trimestres por grupo y el tratamiento de los valores ausentes.

El análisis se estructuró en cuatro dimensiones complementarias:

1. Análisis descriptivo del empleo, mediante el volumen de ocupación y las variaciones trimestrales e interanuales de cada grupo CNO.

2. Análisis de la exposición, mediante las puntuaciones y percentiles de AIOE, Language Modeling AIOE y Anthropic.

3. Análisis conjunto de empleo y exposición, mediante comparaciones por categorías, rankings ocupacionales y gráficos de dispersión.

4. Análisis temporal, mediante series de empleo e índices de evolución por categoría de exposición.

Para describir el mercado laboral se analizó el empleo de cada gran grupo CNO, junto con sus variaciones trimestrales e interanuales. El último periodo disponible, 2026T1, registró un total de 22.292,8 miles de personas ocupadas, equivalente aproximadamente a 22,29 millones.

También se estudiaron las puntuaciones y los percentiles de AIOE, Language Modeling AIOE y Anthropic. La exposición a modelos de lenguaje se utilizó como indicador principal para clasificar los grupos en categorías baja, media y alta, mientras que el indicador de Anthropic se interpretó como una aproximación complementaria a la utilización observada dentro de su propia plataforma.

Cuando se calcularon los totales de empleo por categoría, las observaciones se agregaron primero por categoría y trimestre. Las tasas de evolución se calcularon después sobre esos totales agregados, evitando confundir medias ocupacionales con volúmenes de empleo.

En 2026T1, los grupos clasificados con exposición alta concentraban 10.393,0 miles de personas ocupadas, frente a 9.007,1 miles en los grupos de exposición media y 2.790,8 miles en los de exposición baja. Las ocupaciones militares, clasificadas como sin_categoria, representaban aproximadamente 101,9 miles de personas. Estas cantidades expresan el volumen de empleo incluido en cada categoría y no el número de trabajadores automatizados, afectados o en riesgo de despido.

Para facilitar la comparación de la evolución temporal entre categorías con distintos niveles de empleo, también se utilizaron índices de base 100. En estos gráficos, el empleo de cada categoría se fija en 100 durante el periodo inicial seleccionado y los valores posteriores representan su evolución relativa. Este procedimiento permite comparar tendencias sin que el diferente tamaño de las categorías domine la representación.

La relación entre exposición y crecimiento se examinó mediante rankings, series temporales y gráficos de dispersión. La inspección de estos resultados mostró que una exposición elevada podía coexistir tanto con variaciones positivas como negativas del empleo. Por tanto, el análisis descriptivo no reveló una asociación lineal, uniforme y generalizable entre mayor exposición a la inteligencia artificial y reducción de la ocupación.

Finalmente, se analizó la distribución de las 17.992 tareas únicas conservadas del Anthropic Economic Index. La penetración observada presentaba una elevada concentración de valores reducidos y un subconjunto limitado de tareas con valores comparativamente altos. Este resultado muestra que el uso registrado en la fuente no se distribuye de manera uniforme. No obstante, los datos pueden estar condicionados por sesgos de plataforma, selección de usuarios y cobertura ocupacional, por lo que no representan directamente el grado de adopción de inteligencia artificial en el mercado laboral español.

El análisis tuvo un carácter descriptivo y exploratorio. Sus resultados se utilizaron para validar el panel, construir y seleccionar las variables empleadas por los modelos, identificar limitaciones metodológicas y diseñar las visualizaciones de la aplicación web y Power BI. En ningún caso permiten establecer relaciones causales entre la inteligencia artificial y la evolución del empleo.

4.2.8 Metodología predictiva

La metodología predictiva se diseñó para estimar el crecimiento porcentual del empleo de cada gran grupo CNO durante el trimestre siguiente. La variable objetivo, denominada employment_growth_next_quarter_pct, se calculó comparando el empleo de cada periodo con el observado en el trimestre posterior:

$$y_{i,t} = \frac{E_{i,t+1} - E_{i,t}}{E_{i,t}} \times 100$$

donde E i,t representa el empleo del grupo ocupacional i durante el trimestre t.

Variables predictoras

Las variables numéricas utilizadas fueron:

- logaritmo del empleo observado;

- variación trimestral del empleo;

- variación interanual del empleo;

- percentil de exposición a modelos de lenguaje, normalizado entre 0 y 1;

- percentil del indicador observado de Anthropic, normalizado entre 0 y 1;

- índice de tendencia temporal;

- componentes seno y coseno del trimestre;

- interacción entre crecimiento trimestral y exposición a modelos de lenguaje;

- interacción entre crecimiento interanual y exposición a modelos de lenguaje.

También se incorporaron variables indicadoras para los diez grandes grupos CNO. Estas variables permiten representar diferencias estructurales entre grupos que no quedan recogidas por las variables numéricas.

El indicador AIOE general se conservó en el panel y se utilizó durante el análisis descriptivo, pero la modelización empleó como medida principal de exposición el percentil específico de Language Modeling AIOE, por encontrarse más directamente relacionado con las capacidades de la inteligencia artificial generativa.

Enfoques predictivos

Se compararon ocho enfoques:

1. **Crecimiento cero**, que predice una variación igual a cero.

2. **Persistencia trimestral**, que utiliza como predicción el crecimiento del trimestre actual.

3. **Regresión lineal**, utilizada como referencia paramétrica sin regularización.

4. **Ridge**, que aplica una penalización L2 para reducir la inestabilidad de los coeficientes.

5. **Elastic Net**, que combina regularización L1 y L2.

6. **Random Forest**, basado en la combinación de múltiples árboles entrenados con muestras y subconjuntos de variables diferentes.

7. **Gradient Boosting**, que construye árboles de forma secuencial para corregir los errores residuales.

8. **Ensemble ponderado**, que combina los tres modelos con mejor rendimiento en la ventana de validación.

La inclusión de modelos de referencia, modelos lineales regularizados y métodos no lineales permitió comprobar si el aumento de complejidad producía una mejora real fuera de muestra.

Selección de hiperparámetros

Los hiperparámetros se seleccionaron mediante una ventana temporal de validación formada por cuatro trimestres, situada inmediatamente antes del periodo reservado para el backtesting. Para cada configuración, el entrenamiento utilizó únicamente observaciones anteriores a la ventana de validación.

Las configuraciones seleccionadas fueron:

- Ridge: alpha=100;

- Elastic Net: alpha=10 y proporción L1 igual a 0,75;

- Random Forest: 80 árboles, profundidad máxima de 5, mínimo de 8 observaciones por hoja y 5 variables candidatas por división;

- Gradient Boosting: 50 estimadores, tasa de aprendizaje de 0,07, profundidad máxima de 2 y mínimo de 12 observaciones por hoja.

Las variables numéricas se estandarizaron utilizando exclusivamente la media y la desviación estándar del conjunto de entrenamiento correspondiente. Este procedimiento se repitió dentro de cada corte temporal para evitar que la información de los periodos evaluados influyera en la preparación de los datos.

Validación fuera de muestra

La evaluación se realizó mediante backtesting walk-forward con una ventana de entrenamiento expansiva. Para cada trimestre de prueba, los modelos se entrenaron exclusivamente con las observaciones cronológicamente anteriores y generaron predicciones para los diez grandes grupos CNO.

El periodo de prueba estuvo formado por los ocho últimos trimestres con variable objetivo conocida, desde 2024T1 hasta 2025T4. En consecuencia, se obtuvieron 80 predicciones fuera de muestra por modelo.

El rendimiento se comparó mediante tres métricas:

- raíz del error cuadrático medio (RMSE);

- error absoluto medio (MAE);

- coeficiente de determinación (R^2).

También se calculó la mejora porcentual del RMSE respecto al baseline de crecimiento cero. La robustez de la diferencia entre el mejor modelo y dicho baseline se evaluó mediante 2.000 remuestreos bootstrap realizados por bloques trimestrales.

Por último, se aplicó un procedimiento de importancia por permutación. Este método altera aleatoriamente cada variable y mide el aumento del RMSE resultante. Sus valores representan importancia predictiva y no deben interpretarse como efectos causales.

Construcción del ensemble

Random Forest obtuvo el mejor rendimiento durante el backtesting. No obstante, para generar los escenarios futuros se utilizó un ensemble ponderado con el objetivo de combinar capacidad predictiva, estabilidad y diversidad metodológica.

Los tres componentes seleccionados mediante la ventana de validación fueron:

- Random Forest, con un peso de 0,3379;

- Gradient Boosting, con un peso de 0,3342;

- Ridge, con un peso de 0,3279.

Los pesos se calcularon de manera inversamente proporcional al RMSE de validación. De este modo, los modelos con menor error recibieron una ponderación ligeramente superior.

Una vez completada la evaluación, los tres componentes del ensemble se entrenaron con las 600 observaciones que disponían de crecimiento futuro conocido. A partir de 2026T1 se generaron predicciones recursivas para ocho horizontes, desde T+1 hasta T+8.

En cada iteración, el crecimiento previsto se utilizó para calcular el empleo del trimestre siguiente. Este nuevo valor se incorporó al historial para reconstruir las variaciones y variables necesarias en el horizonte posterior. Por este motivo, los errores pueden acumularse a medida que aumenta la distancia temporal de la predicción.

Interpretación

Las predicciones deben entenderse como escenarios exploratorios. Los modelos utilizan indicadores internacionales de exposición constantes en el tiempo y no incluyen una medida trimestral de adopción de inteligencia artificial en España. Además, el número de grupos ocupacionales es reducido y las correspondencias CNO–SOC son aproximadas.

Por estas razones, la metodología permite comparar la capacidad predictiva de diferentes algoritmos y explorar posibles trayectorias futuras, pero no atribuir causalidad a la inteligencia artificial ni anticipar de forma determinista la evolución del empleo.

4.2.9 Backtesting y métricas de evaluación

La validación se realizó mediante un procedimiento de backtesting walk-forward con ventana de entrenamiento expansiva. Para cada trimestre de prueba, los modelos se entrenaron exclusivamente con observaciones anteriores y generaron predicciones sin utilizar información futura. Una vez evaluado cada periodo, las observaciones disponibles se incorporaron al conjunto de entrenamiento del siguiente corte temporal.

El periodo de evaluación comprendió desde 2024T1 hasta 2025T4. Al incluir diez grandes grupos ocupacionales y ocho trimestres, se obtuvieron 80 predicciones fuera de muestra para cada enfoque.

Los modelos se compararon con dos referencias sencillas:

- Persistencia trimestral: utiliza el crecimiento observado durante el trimestre actual como predicción del trimestre siguiente.

- Crecimiento cero: supone que el empleo no experimentará variación durante el siguiente trimestre.

La comparación incluyó también regresión lineal, Ridge, Elastic Net, Random Forest, Gradient Boosting y el ensemble ponderado. Todos los enfoques se evaluaron sobre las mismas observaciones y periodos.

Métricas de evaluación

El error absoluto medio se calculó mediante:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

La raíz del error cuadrático medio se calculó como:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

El coeficiente de determinación se obtuvo mediante:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

donde y_i representa el crecimiento observado, (hat{y}_i) la predicción y (bar{y}) la media de los valores observados.

Como la variable objetivo está expresada en porcentaje, el RMSE y el MAE se interpretan en puntos porcentuales. Un R^2 negativo indica que el modelo presenta un rendimiento inferior al obtenido utilizando la media observada como predicción constante.

También se calculó la mejora del RMSE respecto al baseline de crecimiento cero:

$$Mejora_{RMSE} = \frac{RMSE_{cero} - RMSE_{modelo}}{RMSE_{cero}} \times 100$$

Resultados fuera de muestra

7. Comparación del rendimiento fuera de muestra de los modelos (Fuente: elaboración propia)

Modelo	RMSE	MAE	R^2	Mejora frente a crecimiento cero
Random Forest	2,393	1,874	0,143	9,41 %
Gradient Boosting	2,415	1,929	0,127	8,59 %
Ensemble ponderado	2,429	1,943	0,116	8,04 %
Ridge	2,544	2,051	0,031	3,70 %
Elastic Net	2,557	2,065	0,021	3,20 %
Regresión lineal	2,633	2,161	−0,038	0,31 %
Crecimiento cero	2,641	2,089	−0,045	0,00 %
Persistencia trimestral	4,201	3,235	−1,643	−59,05 %

Random Forest obtuvo el mejor rendimiento, con un RMSE de 2,393 puntos porcentuales, un MAE de 1,874 y un R^2 de 0,143. Esto supone una reducción del RMSE del 9,41 % respecto al baseline de crecimiento cero. Gradient Boosting y el ensemble ponderado ocuparon la segunda y tercera posición, respectivamente.

Ridge mejoró ambos modelos de referencia, pero su rendimiento fue inferior al de los métodos basados en árboles. Por tanto, dejó de considerarse el mejor modelo individual después de ampliar la comparación. No obstante, se mantuvo como uno de los componentes del ensemble debido a su estabilidad y a que aporta una estructura predictiva diferente de la utilizada por Random Forest y Gradient Boosting.

Aunque Random Forest obtuvo el mejor resultado, su R^2 de 0,143 indica que la capacidad explicativa fuera de muestra continúa siendo moderada. Una parte considerable de la variabilidad trimestral del empleo depende de factores económicos, sectoriales e institucionales no incluidos en el panel.

Análisis de robustez

La robustez de la mejora de Random Forest frente al crecimiento cero se evaluó mediante 2.000 remuestreos bootstrap por bloques trimestrales. El remuestreo se realizó por periodos completos para conservar conjuntamente las diez observaciones ocupacionales de cada trimestre.

La diferencia media estimada entre el RMSE de Random Forest y el del crecimiento cero fue de −0,248 puntos. El intervalo bootstrap del 95 % se situó entre −0,432 y −0,049. Al permanecer ambos límites por debajo de cero, el resultado aporta evidencia de que la mejora no depende exclusivamente de un trimestre concreto. Sin embargo, la magnitud de la diferencia continúa siendo moderada.

Estimación de la incertidumbre

La incertidumbre de los escenarios se estimó utilizando los residuos fuera de muestra del ensemble ponderado:

$$e_i = y_i - \hat{y}_i$$

Los percentiles 5 y 95 de su distribución empírica se añadieron a cada predicción para construir límites aproximados del 90 %:

$$Límite\ inferior = \hat{y} + Q_{0,05}(e)$$

$$Límite\ superior = \hat{y} + Q_{0,95}(e)$$

Este procedimiento no exige asumir que los residuos siguen una distribución normal. No obstante, los límites son aproximados: se calculan a partir del conjunto agregado de errores y no constituyen intervalos calibrados específicamente para cada grupo ocupacional y horizonte predictivo.

Indicador empírico de contracción

Para cada escenario se estimó un indicador empírico de contracción mediante la proporción de residuos del backtesting que, combinados con el crecimiento previsto, habrían producido un crecimiento real inferior a cero:

$$\widehat{P}(Y < 0) = \frac{\sum_{i=1}^{n} 1(e_i < -\hat{y}) + 1}{n + 2}$$

La suma de una observación en el numerador y dos en el denominador actúa como suavizado y evita valores exactamente iguales a cero o uno en una muestra reducida.

Este resultado debe interpretarse como una frecuencia empírica basada en los errores históricos del modelo, no como una probabilidad causal o plenamente calibrada de destrucción de empleo. El indicador se combinó posteriormente con el empleo previsto y la exposición relativa para construir un índice comparativo de priorización. Dicho índice no representa una estimación de despidos ni el número de puestos de trabajo que desaparecerán.

4.2.10 Sistema de visualización

Los resultados se presentaron mediante dos herramientas complementarias: una aplicación web destinada al análisis exploratorio y un cuadro de mando en Power BI orientado a la comunicación de los resultados históricos, la evaluación de los modelos y los escenarios predictivos.

Aplicación web de análisis exploratorio

La aplicación web se desarrolló localmente mediante HTML, CSS y JavaScript. La herramienta carga el panel procesado desde un archivo CSV y permite filtrar la información por periodo, categoría de exposición, año inicial y término de búsqueda relacionado con la ocupación.

La aplicación incorpora indicadores sobre:

- empleo total;

- crecimiento interanual medio;

- variación trimestral media;

- número de grupos ocupacionales seleccionados;

- exposición media a modelos de lenguaje;

- indicador medio observado de Anthropic.

También incluye las siguientes visualizaciones:

- composición del empleo por categoría de exposición;

- empleo por gran grupo ocupacional;

- ranking de exposición a modelos de lenguaje;

- gráfico de dispersión entre exposición y crecimiento interanual;

- evolución temporal del empleo mediante índices de base 100;

- tabla detallada de las observaciones seleccionadas.

Los filtros actualizan conjuntamente los indicadores, los gráficos y la tabla de trabajo. La aplicación se utilizó también como mecanismo de control de calidad, ya que permitió detectar valores anómalos, periodos incompletos y posibles errores de agregación.

Su finalidad es exclusivamente descriptiva y exploratoria. La aplicación web no presenta los resultados de la comparación de modelos ni genera escenarios predictivos, que se reservan para Power BI.

Cuadro de mando en Power BI

Como complemento se desarrolló un cuadro de mando interactivo en Microsoft Power BI Desktop. Para su construcción se prepararon diferentes tablas destinadas a representar el histórico de empleo, las dimensiones ocupacionales, las métricas de evaluación y los escenarios predictivos.

Los principales archivos utilizados fueron:

- powerbi_dim_cno.csv, con la dimensión de grupos ocupacionales;

- powerbi_fact_employment_history.csv, con el histórico trimestral de empleo;

- metricas_comparacion_modelos.csv, con las métricas generales de los ocho enfoques;

- metricas_por_grupo_y_modelo.csv, con los errores por grupo ocupacional;

- predicciones_backtesting_todos_modelos.csv, con las predicciones fuera de muestra;

- importancia_variables_permutacion.csv, con la importancia predictiva de las variables;

- powerbi_fact_forecast_v2.csv, con los escenarios del ensemble entre T+1 y T+8;

- powerbi_fact_risk_summary_v2.csv, con el resumen correspondiente al horizonte más próximo.

El modelo analítico incorpora una dimensión ocupacional, una dimensión de modelos y distintas tablas de hechos relacionadas. La tabla de importancia por permutación se mantiene como tabla independiente, ya que sus registros se organizan por variable y no por grupo ocupacional.

El cuadro de mando se estructuró en cuatro páginas:

1. Resumen ejecutivo, con los principales indicadores de empleo, exposición y crecimiento previsto para T+1.

2. Análisis histórico de empleo, con la evolución trimestral, el empleo inicial y final, el crecimiento interanual y la variación acumulada.

3. Comparación y evaluación de modelos predictivos, con las métricas RMSE, MAE y R^2, la mejora frente al crecimiento cero, las predicciones fuera de muestra, los errores por grupo y la importancia de variables.

4. Predicción exploratoria y riesgo ocupacional, con los escenarios T+1 a T+8, el crecimiento previsto por grupo, la distribución del empleo por nivel de riesgo y la frecuencia empírica ponderada de contracción.

Para permitir la interacción se desarrollaron medidas DAX y segmentadores por grupo ocupacional, nivel de exposición, modelo, intervalo temporal y horizonte predictivo. Los archivos generados por el pipeline permiten actualizar los datos cuando se incorporan nuevos periodos, aunque la actualización del informe debe realizarse desde Power BI Desktop.

Criterios de interpretación

Los colores y categorías representan posiciones relativas dentro de las distribuciones de exposición y riesgo. No clasifican ocupaciones como seguras, amenazadas o destinadas a desaparecer.

Del mismo modo, la frecuencia empírica de contracción mostrada en Power BI se basa en los errores observados durante el backtesting. No representa una probabilidad causal de destrucción de empleo ni una estimación de despidos futuros.

En conjunto, la aplicación web facilita la exploración del panel integrado, mientras que Power BI proporciona una visión ejecutiva, histórica, técnica y predictiva de los resultados. Ambas herramientas se diseñaron para apoyar la interpretación del análisis sin exceder las posibilidades explicativas de los datos.

4.2.11 Reproducibilidad y control de calidad

El proyecto se diseñó para que sus principales etapas pudieran ejecutarse de forma automatizada y reproducible. El script run_full_pipeline.py coordina secuencialmente la limpieza e integración de los datos, la ejecución de la primera aproximación predictiva basada en Ridge, la comparación ampliada de modelos y la generación de métricas, escenarios e información destinada a Power BI.

El proceso ejecuta, en este orden:

1. clean_and_link_data.py;

2. train_forecast_model.py;

3. enhanced_model_comparison.py.

Cada etapa se ejecuta como un proceso independiente. Si alguno de los scripts devuelve un error, la ejecución se detiene y no se continúa con las fases posteriores. De esta forma se evita generar resultados predictivos a partir de datos incompletos o inconsistentes.

La descarga de las fuentes no forma parte de la ejecución ordinaria del pipeline. Esta decisión evita sustituir accidentalmente los archivos originales cada vez que se repite la modelización. La actualización se realiza de manera deliberada mediante download_data.py y, una vez revisado el registro de descarga, se ejecuta el pipeline completo.

Separación y trazabilidad de los datos

Los datos originales se conservan separados de las versiones procesadas. Los archivos descargados se almacenan en data/raw, mientras que las transformaciones intermedias, el panel integrado, las métricas y los escenarios se guardan en data/processed.

Esta separación permite:

- comprobar las transformaciones realizadas;

- reconstruir los resultados desde las fuentes originales;

- comparar distintas versiones de los datos;

- localizar errores en una fase concreta;

- actualizar el proyecto sin modificar los archivos de partida.

Además, se mantuvieron una bitácora metodológica, un registro de descargas y diferentes documentos con las decisiones adoptadas, las incidencias detectadas y las limitaciones del análisis.

Validaciones automáticas

Antes de exportar el panel, el script de limpieza e integración comprueba automáticamente:

- la presencia exacta de los diez grandes grupos CNO;

- la ausencia de claves cno_major-periodo duplicadas;

- la ausencia de códigos SOC duplicados en la tabla integrada;

- la existencia de una única fila de exposición para cada grupo CNO;

- la eliminación de duplicados exactos en los datos de tareas de Anthropic;

- la igualdad de la cobertura temporal entre todos los grupos ocupacionales.

Si alguna de estas condiciones no se cumple, el script genera un error y detiene el procesamiento.

La validación confirmó que el panel definitivo contiene 610 observaciones únicas, correspondientes a diez grupos CNO y 61 trimestres por grupo. De ellas, 600 disponen de crecimiento futuro conocido y pueden utilizarse durante el entrenamiento y el backtesting.

Reproducibilidad de la modelización

Los modelos se evaluaron sobre los mismos periodos y observaciones mediante un procedimiento de backtesting walk-forward. La preparación de las variables y la estandarización se ajustaron nuevamente dentro de cada corte utilizando exclusivamente los datos anteriores al periodo evaluado.

Las operaciones aleatorias de Random Forest, Gradient Boosting, bootstrap e importancia por permutación se ejecutaron utilizando una semilla fija. Esta decisión permite obtener los mismos resultados cuando se utilizan los mismos datos, el mismo código y la misma configuración.

Los hiperparámetros seleccionados y los pesos del ensemble se almacenaron en configuracion_modelos.json. Las predicciones, métricas y resultados de importancia se exportaron como archivos independientes, lo que permite revisar cada resultado sin necesidad de volver a entrenar inmediatamente los modelos.

Revisión de los resultados predictivos

Después de ejecutar la modelización se revisaron:

- la existencia de 80 predicciones fuera de muestra por modelo;

- la correspondencia entre periodos observados y predichos;

- la ausencia de valores no válidos en las métricas principales;

- el orden correcto de los límites inferior y superior;

- la permanencia del indicador empírico de contracción entre 0 y 1;

- la presencia de los ocho horizontes predictivos para los diez grupos CNO;

- la coherencia entre los archivos generados y las visualizaciones de Power BI.

Estas comprobaciones formaron parte de la auditoría de resultados, aunque no todas se implementaron como condiciones automáticas dentro del código. Esta distinción evita atribuir al pipeline controles que se realizaron durante la revisión técnica y visual.

Limitaciones de la reproducibilidad

La reproducibilidad externa depende de que las fuentes mantengan sus direcciones, formatos y estructuras. Por este motivo se conservaron localmente los archivos utilizados para obtener los resultados incluidos en el TFM.

Si el INE publica un nuevo trimestre con la misma estructura, el procedimiento de actualización consiste en:

1. ejecutar nuevamente la descarga;

2. revisar download_log.csv;

3. ejecutar run_full_pipeline.py;

4. comprobar las validaciones y los archivos generados;

5. actualizar manualmente las fuentes del informe en Power BI Desktop.

Por tanto, el procesamiento y la generación de archivos son reproducibles mediante el pipeline, mientras que la actualización del archivo PBIX requiere una operación adicional dentro de Power BI Desktop.

4.3 Recursos requeridos

El proyecto se desarrolló utilizando recursos técnicos, documentales y de datos accesibles, sin necesidad de contratar infraestructura especializada ni servicios de computación en la nube. El volumen de información y la complejidad computacional de los modelos permitieron ejecutar todo el procesamiento en un entorno local.

Los principales recursos empleados fueron los siguientes:

8. Recursos tecnológicos y fuentes de datos utilizados en el proyecto (Fuente: elaboración propia)

Tipo	Recurso	Utilización
Hardware	Ordenador personal	Procesamiento, modelización, visualización y redacción.
Comunicaciones	Conexión a Internet	Descarga de fuentes y consulta bibliográfica.
Software	Python	Automatización, limpieza, integración, análisis y modelización.
Bibliotecas	pandas	Procesamiento tabular, transformación, agrupación e integración.
Bibliotecas	NumPy	Operaciones matriciales, modelos predictivos, métricas, bootstrap y ensemble.
Bibliotecas	Pillow	Generación de gráficos técnicos.
Desarrollo web	HTML, CSS y JavaScript	Construcción de la aplicación web de análisis exploratorio.
Visualización	SVG	Generación de gráficos interactivos en el navegador.
Visualización	Power BI Desktop y DAX	Análisis histórico, comparación de modelos y escenarios predictivos.
Documentación	Microsoft Word	Elaboración y maquetación de la memoria.
Documentación	Notación LaTeX	Representación de expresiones matemáticas.
Documentación	Markdown	Elaboración de informes técnicos y documentación del pipeline.
Datos	INE EPA	Evolución trimestral del empleo en España.
Datos	AIOE y LM AIOE	Exposición ocupacional general y a modelos de lenguaje.
Datos	Anthropic Economic Index	Utilización observada por ocupación y penetración por tarea.
Almacenamiento	Sistema de archivos local	Conservación de datos originales, tablas procesadas y resultados.
Organización	Estructura modular de directorios	Separación de código, datos, documentación y visualizaciones.

El volumen de los datos permitió ejecutar todo el procesamiento en un ordenador personal. No fue necesario utilizar sistemas distribuidos, servidores externos, bases de datos de gran capacidad ni servicios de computación en la nube. Esta decisión se ajustó al tamaño real del problema y evitó añadir una complejidad técnica que no habría producido mejoras significativas en el análisis.

La mayor parte del software empleado es de código abierto o está disponible sin costes adicionales para el uso realizado. Las fuentes de datos son públicas o de acceso abierto. Microsoft Word se utilizó mediante una licencia ya disponible y Power BI Desktop no requirió contratar un servicio de publicación en la nube.

El principal recurso requerido fue el tiempo dedicado a la revisión bibliográfica, adquisición y preparación de los datos, programación, comparación de modelos, validación, interpretación de resultados, construcción de las visualizaciones y redacción de la memoria. Su valoración económica se presenta en el apartado de presupuesto.

4.4 Presupuesto

El presupuesto recoge tanto los recursos materiales y tecnológicos como el tiempo dedicado al desarrollo del proyecto. Aunque gran parte del software y de los datos utilizados fueron gratuitos, se estimó su coste económico para reflejar el valor real de los recursos necesarios.

La principal partida corresponde al trabajo personal realizado durante la revisión bibliográfica, preparación de los datos, programación, análisis, validación y redacción. Para su valoración se utilizó una tarifa orientativa de 20 euros por hora.

9. Estimación de costes y recursos empleados en el proyecto (Fuente: elaboración propia)

Concepto	Cálculo	Coste estimado
Trabajo personal	250 horas × 20 /hora	5.000
Ordenador personal	Amortización correspondiente al periodo de uso	250
Electricidad y conexión a Internet	Estimación durante el desarrollo	100
Python, pandas y NumPy	Software libre	0
HTML, CSS y JavaScript	Tecnologías abiertas	0
Power BI Desktop	Versión gratuita	0
LaTeX y Markdown	Herramientas abiertas	0
Microsoft Word	Licencia académica o ya disponible	0
Datos del INE	Fuente pública	0
Datos AIOE	Fuente académica abierta	0
Anthropic Economic Index	Dataset de acceso público	0
Almacenamiento en la nube y local	Recursos ya disponibles	0
Total estimado		**5.350**

El presupuesto representa una valoración aproximada y no un desembolso directo de 5.350 euros. La mayor parte corresponde al coste de oportunidad del tiempo invertido. Los gastos monetarios reales fueron reducidos porque se utilizaron recursos ya disponibles, software gratuito y fuentes de datos abiertas.

4.5 Viabilidad

La viabilidad del proyecto se analizó desde las perspectivas técnica, económica, operativa y metodológica.

Desde el punto de vista técnico, la solución es viable porque puede ejecutarse en un ordenador personal y utiliza herramientas ampliamente disponibles. El volumen de información no requiere infraestructura distribuida, servidores especializados ni servicios de computación en la nube. La organización modular del código permite ejecutar, revisar y actualizar cada etapa de forma independiente.

La arquitectura también permite incorporar nuevos periodos, volver a calcular las variables derivadas y repetir la comparación de modelos. El uso de formatos como CSV y JSON facilita el intercambio de información entre Python, la aplicación web y Power BI.

La viabilidad económica resulta igualmente favorable. Las principales fuentes de datos son públicas o de acceso abierto y las herramientas de procesamiento utilizadas, como Python, pandas, NumPy, HTML, CSS, JavaScript, Markdown y la notación LaTeX, no requieren el pago de licencias. Power BI Desktop puede utilizarse sin contratar un servicio de publicación en la nube y Microsoft Word se empleó mediante una licencia previamente disponible. El principal coste del proyecto corresponde al tiempo dedicado a su desarrollo.

Desde una perspectiva operativa, el pipeline puede reutilizarse cuando el INE publique nuevos datos trimestrales. Si las fuentes mantienen sus direcciones y estructuras, la actualización consiste en descargar los nuevos archivos, revisar el registro de descarga y ejecutar nuevamente el proceso de limpieza, integración y modelización. Los conjuntos procesados, las métricas y los escenarios predictivos se regeneran automáticamente.

La aplicación web utiliza directamente el panel procesado, por lo que puede actualizarse sustituyendo el archivo correspondiente. En el caso de Power BI, el pipeline genera las tablas necesarias, aunque posteriormente debe actualizarse el modelo desde Power BI Desktop para incorporar los nuevos datos.

La principal limitación de viabilidad metodológica es la correspondencia agregada entre CNO-11 y SOC. Esta aproximación permite realizar comparaciones entre grandes grupos, pero no garantiza equivalencias exactas entre ocupaciones individuales. Asimismo, los indicadores de exposición son internacionales, permanecen constantes durante el periodo analizado y no miden directamente la adopción trimestral de inteligencia artificial en las empresas españolas.

La capacidad predictiva también es moderada. Aunque Random Forest mejoró el baseline de crecimiento cero, su R^2 fuera de muestra fue de 0,143. Esto indica que una parte considerable de la variabilidad trimestral del empleo depende de factores no incluidos en el panel. Por tanto, el sistema resulta técnicamente útil para comparar métodos y generar escenarios exploratorios, pero no para producir previsiones deterministas.

Desde el punto de vista de los datos, el proyecto utiliza información pública y agregada por grandes grupos ocupacionales. No se tratan datos personales ni registros individuales de trabajadores, lo que reduce los riesgos asociados a la privacidad y facilita su mantenimiento académico.

En conjunto, el proyecto es viable como sistema de análisis descriptivo, evaluación de modelos y predicción exploratoria. Su mantenimiento presenta un coste reducido y puede ampliarse mediante nuevas fuentes, una correspondencia ocupacional más precisa, variables macroeconómicas o indicadores temporales de adopción tecnológica. No obstante, sus resultados no deben utilizarse como predicciones causales ni como estimaciones directas de destrucción de empleo .

4.6 Resultados del proyecto

El proyecto produjo una solución reproducible que integra información del mercado laboral español con indicadores internacionales de exposición ocupacional a la inteligencia artificial. Los resultados se estructuran en cuatro bloques: construcción del panel integrado, análisis exploratorio, modelización predictiva y desarrollo de un sistema de visualización en Power BI.

4.6.1 Dataset integrado

El principal resultado técnico fue la construcción de un panel formado por los diez grandes grupos de la Clasificación Nacional de Ocupaciones de 2011 (CNO-11) y 61 trimestres,

comprendidos entre 2011T1 y 2026T1. El conjunto final contiene 610 observaciones únicas e incorpora las siguientes variables:

- empleo trimestral, expresado en miles de personas;

- variación trimestral e interanual del empleo;

- indicador general de exposición ocupacional a la inteligencia artificial (AIOE);

- exposición específica a modelos de lenguaje;

- exposición observada procedente del Anthropic Economic Index;

- percentiles y categorías agregadas de exposición;

- empleo y crecimiento observados en el trimestre siguiente, cuando se encuentran disponibles.

Para construir estos indicadores se procesaron 774 ocupaciones SOC únicas y 17.992 tareas únicas del Anthropic Economic Index. La correspondencia entre las clasificaciones CNO-11 y SOC generó 1.057 asignaciones agregadas CNO–SOC, debido a que determinados grupos ocupacionales españoles se relacionan con más de un gran grupo de la clasificación estadounidense.

El proceso de integración incluyó controles de duplicados, normalización de códigos, comprobación de unicidad de las observaciones y validaciones de coherencia temporal. Como resultado, se obtuvo una base analítica reproducible que permite combinar la evolución del empleo en España con diferentes aproximaciones a la exposición ocupacional a la IA.

4.6.2 Resultados exploratorios

En 2026T1, último trimestre observado, el empleo agregado de los diez grandes grupos CNO ascendió a 22.292,8 miles de personas. Los grupos con mayor volumen de empleo fueron los técnicos y profesionales científicos e intelectuales, con 4.634,0 miles de personas, y los trabajadores de los servicios de restauración, personales, protección y ventas, con 4.617,9 miles.

La distribución del empleo según la categoría de exposición a la IA fue la siguiente:

10. Distribución del empleo por categoría de exposición a la IA en 2026T1 (Fuente: elaboración propia)

Categoría	Número de grupos	Empleo en 2026T1
Alta	4	10.393,0 miles
Media	3	9.007,1 miles
Baja	2	2.790,8 miles
Sin categoría	1	101,9 miles

La categoría de exposición alta agrupó cuatro grandes grupos ocupacionales y concentró el 46,62 % del empleo analizado. La exposición media representó el 40,40 % y la exposición baja el 12,52 %. El 0,46 % restante correspondió a las ocupaciones militares, para las que no se asignó una categoría de exposición comparable.

Los grupos con mayor exposición relativa a modelos de lenguaje fueron los directores y gerentes, los técnicos y profesionales científicos e intelectuales, los empleados contables y

administrativos y los técnicos y profesionales de apoyo. En los niveles inferiores se situaron los trabajadores cualificados del sector agrícola y determinados perfiles industriales y manufactureros.

El análisis conjunto de exposición y evolución laboral mostró que una exposición elevada a la IA puede coexistir con un crecimiento positivo del empleo. En 2026T1, por ejemplo, los técnicos y profesionales científicos e intelectuales presentaron una variación interanual del 2,95 %, mientras que los técnicos y profesionales de apoyo crecieron un 3,75 %. Por el contrario, los empleados administrativos, también clasificados con exposición alta, registraron una reducción interanual del 2,41 %.

Estos resultados no respaldan una relación automática según la cual una mayor exposición a la IA implique necesariamente una reducción de la ocupación. La exposición debe interpretarse como una medida del potencial de transformación de las tareas y no como una estimación directa de sustitución o destrucción de puestos de trabajo.

5. Página de resumen ejecutivo del dashboard desarrollado en Power BI (Fuente: elaboración propia)



4.6.3 Resultados del modelo predictivo

os ocho enfoques se evaluaron mediante backtesting walk-forward sobre los ocho últimos trimestres con variable objetivo conocida, desde 2024T1 hasta 2025T4. Para cada modelo se generaron 80 predicciones fuera de muestra, correspondientes a diez grupos CNO y ocho periodos de evaluación.

La comparación produjo los siguientes resultados:

11. Rendimiento fuera de muestra de los modelos predictivos (Fuente: elaboración propia)

Modelo	RMSE	MAE	R^2	Mejora frente a crecimiento cero
Random Forest	2,393	1,874	0,143	9,41 %
Gradient Boosting	2,415	1,929	0,127	8,59 %
Ensemble ponderado	2,429	1,943	0,116	8,04 %
Ridge	2,544	2,051	0,031	3,70 %
Elastic Net	2,557	2,065	0,021	3,20 %
Regresión lineal	2,633	2,161	−0,038	0,31 %
Crecimiento cero	2,641	2,089	−0,045	0,00 %
Persistencia trimestral	4,201	3,235	−1,643	−59,05 %

Random Forest obtuvo el mejor rendimiento, con un RMSE de 2,393 puntos porcentuales, un MAE de 1,874 y un R^2 de 0,143. Su error cuadrático medio fue un 9,41 % inferior al del baseline de crecimiento cero. Gradient Boosting y el ensemble ponderado ocuparon la segunda y tercera posición.

Ridge mejoró ambos modelos de referencia, pero su rendimiento quedó por debajo de los métodos basados en árboles. Por tanto, no se seleccionó como mejor modelo individual. No obstante, se mantuvo dentro del ensemble por aportar una estructura lineal regularizada diferente de las utilizadas por Random Forest y Gradient Boosting.

El análisis bootstrap por bloques trimestrales situó la diferencia media de RMSE entre Random Forest y el crecimiento cero en −0,248 puntos, con un intervalo del 95 % comprendido entre −0,432 y −0,049. Este resultado respalda la existencia de una mejora fuera de muestra, aunque su magnitud continúa siendo moderada.

El R^2 máximo de 0,143 muestra que una parte importante de la variabilidad trimestral no queda explicada por las variables disponibles. Por tanto, los modelos aportan capacidad predictiva respecto a las referencias simples, pero sus resultados deben interpretarse con prudencia.

Escenario correspondiente a T+1

Aunque Random Forest obtuvo el menor error, los escenarios futuros se generaron mediante el ensemble ponderado de Random Forest, Gradient Boosting y Ridge. Las predicciones principales para T+1 fueron las siguientes:

12. Principales predicciones de crecimiento e indicador empírico de contracción en T+1 (Fuente: elaboración propia)

Grupo CNO	Exposición	Crecimiento previsto	Indicador empírico de contracción
Trabajadores de servicios, restauración, protección y ventas	Media	1,836 %	23,17 %
Ocupaciones elementales	Media	1,408 %	32,93 %
Técnicos y profesionales científicos e intelectuales	Alta	1,384 %	32,93 %
Directores y gerentes	Alta	1,257 %	35,37 %
Técnicos y profesionales de apoyo	Alta	1,231 %	35,37 %

Las predicciones centrales de T+1 fueron positivas para los diez grandes grupos ocupacionales. El mayor crecimiento previsto correspondió a los trabajadores de los servicios de restauración, servicios personales, protección y ventas, con un 1,836 %. Las ocupaciones elementales y los profesionales científicos e intelectuales presentaron también crecimientos superiores al 1,3 %.

El crecimiento agregado previsto para T+1, ponderado por el empleo observado de cada grupo, fue del 1,36 %. El empleo total pasaría de 22,29 millones de personas observadas en 2026T1 a aproximadamente 22,60 millones en el trimestre siguiente.

El indicador empírico de contracción ponderado por el empleo observado fue del 32,41 %. Este valor resume los indicadores calculados para los grupos ocupacionales teniendo en cuenta su peso relativo en el empleo. No representa una probabilidad causal de destrucción de puestos de trabajo.

Los valores más elevados del índice compuesto risk_index correspondieron a los profesionales científicos e intelectuales, los técnicos y profesionales de apoyo, los empleados administrativos y los trabajadores de servicios. Este resultado se explica porque el índice combina tres componentes: volumen de empleo previsto, indicador empírico de contracción y exposición relativa a modelos de lenguaje.

La distribución del empleo previsto según la categoría compuesta de riesgo fue:

- riesgo alto: 14,29 millones, equivalentes al 63,25 %;

- riesgo medio: 5,39 millones, equivalentes al 23,83 %;

- riesgo bajo: 2,92 millones, equivalentes al 12,92 %.

Estas categorías son relativas y se calculan por separado dentro de cada horizonte. No representan niveles absolutos de peligro ni porcentajes de empleo que vaya a desaparecer.

Evolución entre T+1 y T+8

Para el horizonte completo, el escenario agregado mostró una evolución general positiva, aunque no estrictamente creciente en todos los trimestres. El empleo previsto evolucionó de la siguiente manera:

13. Evolución agregada prevista del empleo entre 2026T2 y 2028T1 (Fuente: elaboración propia)

Horizonte	Empleo previsto	Variación acumulada desde 2026T1
T+1	22,60 millones	1,36 %
T+2	22,79 millones	2,24 %
T+3	22,84 millones	2,46 %
T+4	22,83 millones	2,40 %
T+5	23,14 millones	3,79 %
T+6	23,35 millones	4,76 %
T+7	23,41 millones	5,02 %
T+8	23,41 millones	5,00 %

Al final del horizonte, el empleo previsto se sitúa alrededor de 23,41 millones de personas, lo que supone una variación acumulada aproximada del 5,00 % respecto a 2026T1. El escenario presenta pequeñas reducciones en T+4 y T+8, por lo que no debe describirse como un crecimiento continuo, sino como una trayectoria agregada positiva con estabilizaciones intermedias.

Aunque las predicciones centrales fueron mayoritariamente positivas, los límites construidos con los residuos del backtesting muestran un grado elevado de incertidumbre. Cuanto mayor es el horizonte, mayor es también el riesgo de acumulación de errores debido al carácter recursivo de las predicciones.

El indicador exposure_weighted_risk_thousand permitió ordenar los grupos combinando empleo previsto, exposición y contracción estimada. Aunque conserva la escala de miles de personas, no representa una estimación de despidos ni el número de puestos de trabajo que desaparecerán.

6. Página de predicción y riesgo del dashboard desarrollado en Power BI (Fuente: elaboración propia)



4.6.4 Visualización y productos generados

El proyecto generó dos herramientas complementarias para consultar y analizar los resultados: una aplicación web destinada al análisis exploratorio y un cuadro de mando interactivo desarrollado en Power BI para presentar la evolución histórica, la comparación de modelos y los escenarios predictivos.

Aplicación web de análisis exploratorio

La aplicación web presenta los principales indicadores mediante una interfaz accesible desde el navegador. Incluye filtros por periodo, categoría de exposición y año inicial, además de un buscador textual de ocupaciones. Estos controles actualizan conjuntamente los indicadores, los gráficos y la tabla de trabajo.

La herramienta incorpora indicadores de empleo, crecimiento y exposición, junto con gráficos comparativos, evolución temporal y una tabla detallada. Su finalidad es facilitar la consulta general del panel sin exigir conocimientos técnicos sobre las fuentes o los modelos predictivos.

7. Pantalla principal y guía de interpretación del dashboard web (Fuente: elaboración propia)



La interfaz incorpora una guía para interpretar los colores y evitar que la exposición ocupacional se confunda con sustitución automática o destrucción de empleo. Las categorías alta, media y baja representan posiciones relativas dentro del conjunto analizado, mientras que el color gris identifica el grupo para el que no se dispone de una categoría equivalente.

8. Visualizaciones de exposición a la IA y evolución del empleo en el dashboard web (Fuente: elaboración propia)



Las visualizaciones permiten comparar la exposición relativa de los grupos ocupacionales, examinar conjuntamente la exposición y el crecimiento interanual, y observar la evolución del empleo mediante un índice de base 100. Los resultados muestran que los grupos con exposición alta o media también pueden presentar trayectorias positivas de empleo. Por tanto, la exposición no puede interpretarse como una medida directa de pérdida de puestos de trabajo.

La aplicación web no incorpora la comparación de modelos ni las predicciones futuras. Estas funciones se presentan exclusivamente en Power BI, manteniendo así una separación clara entre el análisis exploratorio y la modelización predictiva.

Cuadro de mando en Power BI

De forma complementaria, se construyó un modelo analítico en Power BI. Su estructura incluye una dimensión de grandes grupos CNO, una dimensión de modelos y distintas tablas con el histórico de empleo, las predicciones fuera de muestra, las métricas de evaluación, los errores por grupo ocupacional y los escenarios del ensemble. La tabla de importancia por permutación se mantuvo como una tabla independiente.

Las relaciones principales se configuraron con cardinalidad de uno a varios desde las dimensiones hacia las tablas de hechos correspondientes. Esta estructura permite aplicar filtros comunes y mantener la coherencia entre los indicadores históricos, ocupacionales y predictivos.

El informe de Power BI se organizó en cuatro páginas.

Resumen ejecutivo

La primera página reúne los principales indicadores de empleo, exposición y crecimiento. Incluye:

- empleo observado;

- número de grupos ocupacionales;

- empleo asociado a exposición alta;

- crecimiento interanual;

- crecimiento previsto para T+1;

- empleo por grupo y nivel de exposición;

- crecimiento previsto por grupo;

- evolución histórica del empleo total.

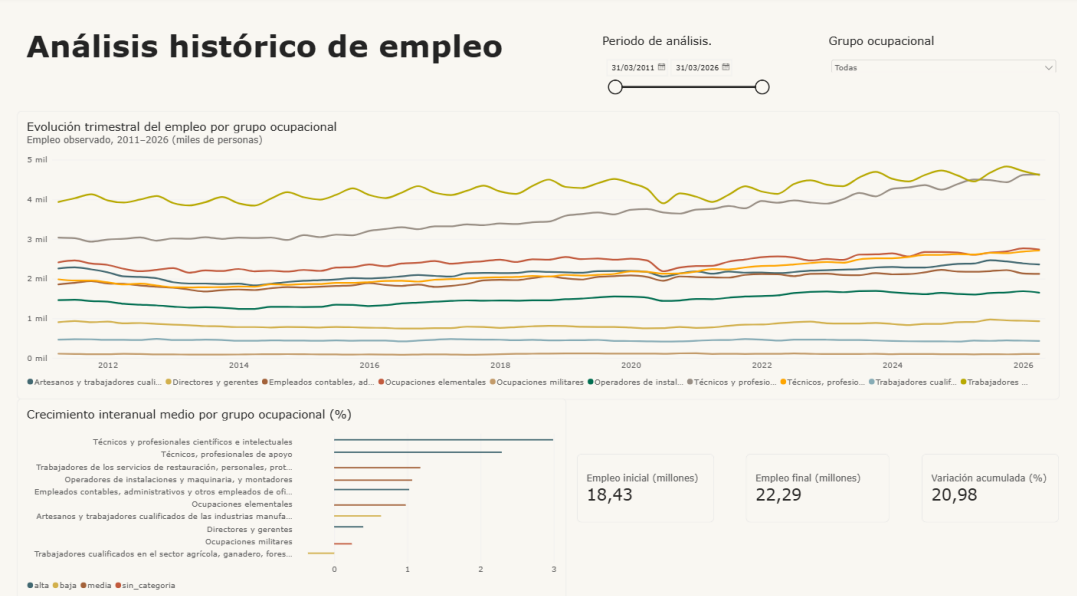
El crecimiento previsto para T+1 se fijó específicamente en el primer horizonte del ensemble, evitando que la tarjeta agregara resultados correspondientes a diferentes horizontes.

Análisis histórico de empleo

La segunda página permite seleccionar un intervalo temporal y uno o varios grupos ocupacionales. Muestra la evolución trimestral del empleo, el crecimiento interanual medio y tres indicadores dependientes del periodo seleccionado: empleo inicial, empleo final y variación acumulada.

Para el intervalo completo, el empleo pasó de 18,43 millones de personas en 2011T1 a 22,29 millones en 2026T1, lo que representa un crecimiento acumulado del 20,98 % .

9. Página de análisis histórico del empleo del dashboard desarrollado en Power BI (Fuente: elaboración propia)



Comparación y evaluación de modelos predictivos

La tercera página presenta los resultados técnicos del backtesting. Incluye:

- modelo con mejor rendimiento;

- RMSE, MAE y R^2;

- mejora frente al baseline de crecimiento cero;

- comparación del RMSE de los ocho enfoques;

- tabla completa de métricas;

- crecimiento observado frente a predicción media;

- RMSE por grupo ocupacional;

- importancia de variables de Random Forest.

También incorpora un segmentador de modelo que permite actualizar las métricas y visualizaciones dependientes del algoritmo seleccionado.

Predicción exploratoria y riesgo ocupacional

La cuarta página presenta los escenarios generados mediante el ensemble ponderado de Random Forest, Gradient Boosting y Ridge. Muestra:

- evolución prevista del empleo entre T+1 y T+8;

- crecimiento previsto por grupo ocupacional;

- indicador empírico ponderado de contracción;

- distribución del empleo previsto por categoría de riesgo;

- empleo observado y previsto;

- crecimiento correspondiente al horizonte seleccionado;

- variación acumulada desde 2026T1.

Para T+1, la página muestra un empleo previsto de 22,60 millones, un crecimiento ponderado del 1,36 % y un indicador empírico ponderado de contracción del 32,41 %.

10. Página de predicción y riesgo del dashboard desarrollado en Power BI (Fuente: elaboración propia)



El informe incorpora una advertencia para indicar que el indicador de contracción se basa en los errores observados durante el backtesting y no representa una probabilidad causal de destrucción de empleo. Asimismo, las categorías de riesgo se presentan como instrumentos relativos de comparación y priorización, no como estimaciones del número de puestos que desaparecerán.

Para construir las cuatro páginas se desarrollaron medidas DAX destinadas a calcular el empleo observado, el empleo asociado a exposición alta, el crecimiento interanual, las métricas del modelo seleccionado, el mejor modelo, el empleo previsto, el crecimiento previsto ponderado y la variación acumulada. También se configuraron segmentadores por grupo ocupacional, exposición, periodo, modelo y horizonte.

Productos de documentación

Finalmente, se elaboraron una bitácora de datos, un registro de descargas, una guía de reproducibilidad y diferentes informes automáticos. Estos elementos permiten revisar las decisiones metodológicas, consultar la configuración de los modelos y regenerar los resultados cuando se actualicen las fuentes.

En conjunto, los productos desarrollados proporcionan una base reproducible para estudiar la exposición ocupacional a la inteligencia artificial y la evolución del empleo en España. Permiten

realizar análisis descriptivos, comparaciones de modelos y predicciones exploratorias, pero no demuestran que la inteligencia artificial haya causado los cambios observados en el mercado laboral.

Capítulo 5. DISCUSIÓN

Los resultados muestran que la exposición ocupacional a la inteligencia artificial no mantiene una relación simple, uniforme ni necesariamente negativa con la evolución del empleo. Los grupos con mayor exposición incluyen ocupaciones directivas, profesionales, técnicas y administrativas, caracterizadas por un peso elevado de tareas cognitivas, lingüísticas y relacionadas con el procesamiento de información.

Esta distribución resulta coherente con la literatura sobre inteligencia artificial generativa. Mientras que anteriores procesos de automatización afectaron especialmente a tareas rutinarias y codificables, tanto manuales como administrativas, los modelos de lenguaje amplían el ámbito tecnológico hacia actividades como la redacción, el análisis documental, la programación, la comunicación y el apoyo a la toma de decisiones. Sin embargo, la exposición representa una capacidad potencial de transformación y no la sustitución completa de una ocupación.

En 2026T1, los grupos clasificados con exposición alta concentraban aproximadamente 10,39 millones de personas, equivalentes al 46,62 % del empleo analizado. Este resultado muestra que una parte considerable del mercado laboral pertenece a grupos con potencial de transformación elevado. No obstante, no significa que ese volumen de empleo vaya a ser automatizado o destruido.

El análisis temporal confirma esta diferencia conceptual. Algunos grupos clasificados con exposición alta presentaron una evolución positiva del empleo, mientras que otros experimentaron reducciones en determinados periodos. Los gráficos de dispersión tampoco mostraron una asociación lineal simple y generalizable entre mayor exposición y menor crecimiento. Por tanto, no puede afirmarse que una exposición elevada provoque automáticamente una caída de la ocupación.

La inteligencia artificial puede automatizar determinadas tareas, pero también complementar el trabajo humano, aumentar la productividad, modificar la distribución de funciones y generar nuevas necesidades de competencias. El resultado final sobre el empleo depende de múltiples mecanismos que actúan simultáneamente y que no pueden observarse completamente mediante un indicador agregado de exposición.

Interpretación de la comparación predictiva

La ampliación técnica permitió comprobar que la regresión Ridge mejoraba los baselines de persistencia y crecimiento cero, pero no constituía el enfoque con mejor rendimiento. Random Forest obtuvo el menor error fuera de muestra, con un RMSE de 2,393, un MAE de 1,874 y un R^2 de 0,143. Su RMSE fue un 9,41 % inferior al del baseline de crecimiento cero.

Gradient Boosting y el ensemble ponderado también superaron a los modelos lineales y a las referencias simples. Este resultado sugiere que la relación entre las variables laborales, temporales y de exposición contiene determinados comportamientos no lineales e

interacciones que no quedan completamente representados mediante una regresión lineal regularizada.

No obstante, la mejora de Random Forest frente al crecimiento cero fue moderada. El análisis bootstrap por bloques trimestrales produjo un intervalo del 95 % para la diferencia de RMSE comprendido entre −0,432 y −0,049. El intervalo se mantiene por debajo de cero, lo que aporta evidencia de una mejora fuera de muestra, pero su proximidad a cero aconseja no sobredimensionar la ventaja obtenida.

El R^2 de 0,143 también indica que una parte considerable de la variabilidad trimestral del empleo continúa sin ser explicada. La evolución laboral depende de factores no incluidos en el panel, como el ciclo económico, la actividad sectorial, los salarios, la inflación, la regulación, las políticas públicas, las decisiones empresariales, los cambios demográficos y diferentes perturbaciones externas.

La comparación muestra además que el baseline de crecimiento cero resultó más competitivo que la persistencia trimestral. Esto indica que prolongar directamente la variación del último trimestre no constituye una referencia adecuada para estas series, debido a su volatilidad y a la posible reversión de movimientos coyunturales. La persistencia obtuvo un R^2 muy negativo, lo que confirma su escasa capacidad para representar el comportamiento posterior.

Interpretación de la importancia de las variables

El análisis de importancia por permutación mostró que el componente estacional quarter_cos fue la variable con mayor contribución predictiva en Random Forest. A continuación aparecieron el segundo componente estacional, la variable indicadora correspondiente al grupo CNO 5 y las variaciones interanual y trimestral del empleo.

Los indicadores de exposición a modelos de lenguaje y Anthropic aportaron información predictiva, pero su importancia fue inferior a la de los componentes estacionales y a la de la evolución reciente del empleo. Este resultado es relevante porque muestra que la exposición a la inteligencia artificial no constituye el principal determinante de las predicciones.

Las importancias deben interpretarse exclusivamente en términos predictivos. Un aumento del error al permutar una variable indica que el modelo utilizaba esa información, pero no demuestra que la variable sea la causa de los cambios observados. Además, los indicadores de exposición permanecen constantes dentro de cada grupo, por lo que representan diferencias estructurales entre ocupaciones y no variaciones temporales en la adopción de tecnología.

Elección del ensemble

Aunque Random Forest obtuvo el mejor resultado individual, los escenarios futuros se generaron mediante un ensemble ponderado de Random Forest, Gradient Boosting y Ridge. Esta elección permitió combinar un modelo de árboles aleatorios, un método secuencial de boosting y una regresión lineal regularizada.

El ensemble no obtuvo el menor RMSE en el backtesting, pero presentó un rendimiento próximo al de los dos mejores modelos y superior al de Ridge y los baselines. Su utilización para generar

escenarios se justifica por la búsqueda de mayor estabilidad y diversidad metodológica, evitando que las proyecciones dependan exclusivamente de la estructura de un único algoritmo.

Los escenarios agregados muestran una evolución positiva del empleo desde 22,29 millones de personas en 2026T1 hasta aproximadamente 23,41 millones en T+8, lo que representa una variación acumulada cercana al 5 %. Sin embargo, la trayectoria no es completamente creciente y presenta pequeñas reducciones en algunos horizontes. Además, el procedimiento recursivo puede acumular errores conforme aumenta la distancia temporal.

Por este motivo, las predicciones deben interpretarse como escenarios exploratorios. Su utilidad principal reside en comparar grupos mediante una metodología común, examinar posibles trayectorias y detectar ocupaciones que combinan un elevado volumen de empleo, una exposición significativa y una mayor incertidumbre predictiva.

Interpretación de los indicadores de riesgo

La frecuencia empírica de contracción se estimó mediante los errores obtenidos durante el backtesting del ensemble. Para T+1, su valor ponderado por el empleo fue del 32,41 %. Este resultado no representa una probabilidad causal de destrucción de empleo, sino la frecuencia con la que los errores históricos serían compatibles con un crecimiento inferior a cero para la predicción considerada.

Del mismo modo, las categorías de riesgo se construyeron mediante un índice que combina empleo previsto, exposición relativa y contracción estimada. La categoría alta concentró el 63,25 % del empleo previsto en T+1, pero este porcentaje no significa que dicho empleo vaya a desaparecer o que todos sus trabajadores estén amenazados.

El índice debe entenderse como una herramienta de priorización analítica. Permite identificar grupos que merecen un seguimiento más detallado por combinar un volumen de empleo relevante con exposición tecnológica e incertidumbre laboral. No constituye una estimación de despidos ni un indicador directamente utilizable para tomar decisiones individuales.

Limitaciones metodológicas

La principal limitación metodológica es la correspondencia agregada entre CNO-11 y SOC. Aunque permite integrar las fuentes, no constituye una equivalencia oficial y puede ocultar diferencias relevantes entre ocupaciones pertenecientes al mismo gran grupo. Una misma familia SOC puede contribuir a más de un grupo CNO, lo que introduce solapamientos necesarios pero reduce la precisión ocupacional.

Asimismo, los indicadores internacionales no miden directamente la adopción de inteligencia artificial en las empresas españolas y permanecen constantes durante toda la serie temporal. En consecuencia, el panel permite comparar diferencias estructurales de exposición, pero no estudiar cómo cambia trimestralmente la utilización de la inteligencia artificial en España.

Los datos del Anthropic Economic Index presentan también un posible sesgo de plataforma, ya que reflejan interacciones realizadas mediante los sistemas de Anthropic. Su composición depende de los usuarios, países, ocupaciones y tipos de tareas representados en la plataforma.

Por ello, no pueden considerarse una descripción completa del uso de inteligencia artificial en el mercado laboral español.

Otra limitación es el nivel de agregación. El análisis utiliza únicamente diez grandes grupos CNO, lo que reduce la diversidad transversal disponible para los modelos y puede ocultar comportamientos diferentes dentro de cada categoría. Además, las 600 observaciones supervisadas no son completamente independientes, ya que proceden de diez series temporales relacionadas.

Los límites predictivos se construyeron mediante la distribución agregada de los residuos del ensemble. Aunque este procedimiento evita imponer normalidad, no proporciona intervalos calibrados específicamente por grupo ocupacional y horizonte. Por tanto, deben interpretarse como aproximaciones empíricas a la incertidumbre.

Implicaciones

A pesar de estas limitaciones, el proyecto aporta una infraestructura reproducible para combinar datos oficiales de empleo con indicadores internacionales de exposición tecnológica, comparar diferentes enfoques predictivos y presentar sus resultados de forma accesible.

Los resultados pueden servir como punto de partida para identificar necesidades de formación, recualificación y seguimiento. Las ocupaciones con mayor exposición no deben considerarse necesariamente amenazadas, pero sí pueden requerir una adaptación más intensa de tareas, competencias y procedimientos de trabajo.

En conjunto, la evidencia obtenida respalda una interpretación basada en la transformación del trabajo y no únicamente en su sustitución. El impacto futuro dependerá de la forma en que se adopten las herramientas, de las competencias de los trabajadores, de la reorganización de las tareas y de la capacidad de empresas e instituciones para acompañar el cambio tecnológico.

En conjunto, la evidencia obtenida respalda una interpretación basada en la transformación del trabajo y no únicamente en su sustitución. El impacto futuro dependerá de cómo se adopten las herramientas, de las competencias de los trabajadores y de la capacidad de empresas e instituciones para adaptar la organización laboral.

Capítulo 6. CONCLUSIONES

6.1 Conclusiones del trabajo

El objetivo general del TFM fue analizar la evolución del mercado laboral español en relación con la exposición ocupacional a la inteligencia artificial y desarrollar una metodología predictiva de carácter exploratorio. Para ello, se integraron datos oficiales de empleo de la Encuesta de Población Activa del INE con los indicadores AIOE, Language Modeling AIOE y Anthropic Economic Index.

El proyecto permitió construir un panel reproducible compuesto por diez grandes grupos de la Clasificación Nacional de Ocupaciones y 61 trimestres, desde 2011T1 hasta 2026T1. El conjunto resultante contiene 610 observaciones únicas y permite estudiar conjuntamente el volumen de empleo, sus variaciones temporales y diferentes aproximaciones a la exposición ocupacional a la inteligencia artificial.

Los resultados exploratorios muestran que las ocupaciones directivas, profesionales, técnicas y administrativas presentan los mayores niveles relativos de exposición. Sin embargo, no se identificó una relación directa y uniforme entre una exposición elevada y la reducción del empleo. Algunos grupos altamente expuestos mantuvieron una evolución positiva, lo que confirma que la exposición representa principalmente un potencial de transformación de las tareas y no una previsión automática de sustitución laboral.

La metodología predictiva comparó ocho enfoques mediante un procedimiento de backtesting walk-forward: dos modelos de referencia, regresión lineal, regresión ridge, Elastic Net, Random Forest, Gradient Boosting y un ensemble ponderado. Random Forest obtuvo el mejor resultado individual, con un RMSE de 2,393 y un MAE de 1,874, y redujo el RMSE del baseline de crecimiento cero en un 9,41 %. El intervalo obtenido mediante bootstrap para esta diferencia respaldó que la mejora no se debía únicamente a una partición concreta del periodo de evaluación.

La importancia de las variables mostró que la estacionalidad y la evolución reciente del empleo desempeñaron un papel destacado en las predicciones. Los indicadores de exposición a la inteligencia artificial también aportaron información, aunque no constituyeron por sí solos los principales determinantes de la evolución laboral. Este resultado refuerza la necesidad de interpretar el empleo como un fenómeno influido por múltiples factores económicos, sectoriales e institucionales.

Las proyecciones definitivas se generaron mediante un ensemble de Random Forest, Gradient Boosting y regresión ridge. La agregación ponderada por el volumen de empleo estimó para T+1 un crecimiento del 1,36 % y un empleo aproximado de 22,60 millones de personas. Para T+8, la proyección alcanzó alrededor de 23,41 millones, lo que supone un crecimiento acumulado del 5,00 % respecto a 2026T1. Estos valores deben entenderse como escenarios exploratorios sujetos a una incertidumbre elevada y no como previsiones deterministas.

El índice de riesgo desarrollado permitió ordenar los grupos ocupacionales combinando volumen de empleo, exposición a la IA y probabilidad empírica de contracción. No obstante, este indicador no representa el número esperado de despidos ni permite atribuir a la inteligencia artificial una eventual reducción del empleo. Su finalidad es facilitar comparaciones relativas e identificar grupos que podrían requerir un seguimiento más detallado.

El proyecto también produjo un dashboard web para el análisis exploratorio y un cuadro de mando en Power BI con información histórica, comparación de modelos, predicciones e indicadores de riesgo. Estas herramientas, junto con el pipeline automatizado, permiten revisar los resultados y actualizar el análisis cuando se publiquen nuevas observaciones trimestrales.

La principal contribución del trabajo es la creación de una infraestructura analítica documentada y reproducible para estudiar conjuntamente la evolución del empleo y la exposición ocupacional a la inteligencia artificial en España. Entre sus principales limitaciones se encuentran la correspondencia agregada entre las clasificaciones CNO y SOC, el reducido nivel de detalle ocupacional, el carácter internacional de los indicadores de exposición y la ausencia de una medida temporal de adopción efectiva de IA en las empresas españolas.

En conclusión, la inteligencia artificial debe analizarse principalmente como un factor de transformación del contenido y la organización del trabajo. Sus efectos dependerán de las tareas realizadas, del grado y la forma de adopción tecnológica, de las competencias profesionales y de la capacidad de adaptación de empresas, trabajadores e instituciones. Los resultados obtenidos no permiten demostrar relaciones causales, pero proporcionan una base empírica y metodológica para continuar investigando esta relación.

6.2 Conclusiones personales

La realización de este TFM me ha permitido aplicar de forma integrada los conocimientos adquiridos durante el Máster en Análisis de Datos Masivos. El proyecto no se ha limitado al entrenamiento de un modelo, sino que ha requerido abordar todas las etapas de un trabajo de datos: búsqueda y evaluación de fuentes, descarga, limpieza, integración, análisis exploratorio, modelado, validación, visualización y comunicación de resultados.

Uno de los principales aprendizajes ha sido comprender la importancia de la calidad, el linaje y la trazabilidad de los datos. La construcción del panel exigió relacionar clasificaciones ocupacionales diferentes y revisar cuidadosamente las correspondencias y agregaciones. Este proceso mostró que una decisión aparentemente menor durante la preparación de los datos puede alterar tanto los resultados posteriores como su interpretación.

También he aprendido que un modelo predictivo no debe valorarse únicamente por su complejidad o por el hecho de generar predicciones. Es imprescindible compararlo con referencias sencillas, respetar el orden temporal de las observaciones, evitar fugas de información y representar adecuadamente la incertidumbre. La comparación de varios algoritmos confirmó que los modelos más flexibles podían mejorar las referencias utilizadas, aunque las diferencias continuaban siendo moderadas y debían comunicarse con prudencia.

La utilización de un ensemble también me permitió comprender la diferencia entre seleccionar el modelo con el mejor resultado individual y combinar varios modelos para obtener predicciones más estables. Del mismo modo, el análisis de importancia de las variables ayudó a evitar una interpretación excesiva del papel de la inteligencia artificial, al mostrar que la estacionalidad y la dinámica reciente del empleo también condicionaban de manera relevante las predicciones.

Desde el punto de vista técnico, el proyecto me permitió reforzar mis conocimientos de Python, pandas y NumPy, desarrollar un pipeline reproducible y construir una herramienta de visualización web. La preparación del modelo de datos y de los indicadores para Power BI también me ayudó a comprender la importancia de adaptar la estructura de la información a las necesidades posteriores de análisis y comunicación.

Otra conclusión personal ha sido la necesidad de diferenciar claramente entre exposición tecnológica, utilización observada, automatización de tareas y sustitución laboral. Al comenzar el trabajo, el impacto de la inteligencia artificial podía plantearse principalmente como un riesgo de automatización. Sin embargo, la revisión bibliográfica y los resultados obtenidos muestran una realidad más compleja, en la que la IA puede sustituir determinadas tareas, complementar las capacidades humanas, modificar las competencias requeridas y transformar ocupaciones sin provocar necesariamente su desaparición.

El desarrollo del proyecto también ha puesto de manifiesto la importancia de comunicar las limitaciones. Reconocer que la correspondencia CNO–SOC es aproximada, que los indicadores utilizados no miden directamente la adopción de IA en España o que el modelo no permite demostrar causalidad no reduce el valor del trabajo. Por el contrario, permite establecer con precisión qué conclusiones están respaldadas por los datos y qué aspectos requieren investigaciones adicionales.

En conjunto, considero que este TFM ha supuesto una experiencia útil para consolidar una forma de trabajo basada en la reproducibilidad, la validación temporal, la revisión crítica y la interpretación responsable. Además de ampliar mis conocimientos técnicos, me ha permitido desarrollar una mayor capacidad para convertir un problema amplio y actual en un proceso analítico estructurado, documentado y susceptible de mejora.

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

La primera línea de mejora consiste en desarrollar una correspondencia más precisa entre las clasificaciones CNO-11, ISCO-08 y SOC. La utilización de tablas oficiales y códigos ocupacionales con un mayor nivel de detalle reduciría los solapamientos y permitiría estudiar perfiles profesionales concretos, en lugar de limitar el análisis a los diez grandes grupos CNO. También sería conveniente evaluar la incertidumbre asociada a cada correspondencia y realizar análisis de sensibilidad con diferentes criterios de asignación.

Otra ampliación relevante sería incorporar indicadores temporales de adopción de inteligencia artificial en España. Las variables utilizadas en este proyecto representan principalmente la exposición estructural o la utilización observada en plataformas internacionales, pero no muestran cómo evoluciona trimestralmente la adopción de estas tecnologías en las empresas españolas. Esta dimensión podría aproximarse mediante encuestas empresariales, ofertas de empleo, inversión tecnológica, uso de herramientas digitales o estadísticas sectoriales.

El panel también podría enriquecerse con variables económicas y laborales como salarios, nivel educativo, sector de actividad, edad, sexo, tipo de contrato, desempleo, productividad, vacantes o indicadores del ciclo económico. Su incorporación podría mejorar la capacidad explicativa de los modelos y permitiría analizar si los efectos asociados a la exposición tecnológica se distribuyen de forma diferente entre colectivos, sectores y territorios.

En el ámbito predictivo, el trabajo ya ha comparado modelos lineales regularizados, Random Forest, Gradient Boosting y un ensemble ponderado. Como continuación, podrían evaluarse modelos específicamente diseñados para series temporales y datos longitudinales, así como métodos jerárquicos capaces de aprovechar simultáneamente la información común y las particularidades de cada grupo ocupacional. También podría estudiarse el ajuste dinámico de los pesos del ensemble y la utilización de modelos probabilísticos que generen distribuciones predictivas completas.

La evaluación debería ampliarse a medida que se publiquen nuevos trimestres. Un periodo de backtesting más extenso permitiría comprobar si la mejora obtenida por Random Forest y por el ensemble se mantiene en distintas fases del ciclo económico. También sería conveniente analizar la estabilidad de las variables más relevantes, revisar periódicamente los hiperparámetros e incorporar procedimientos de detección de cambios estructurales.

Los intervalos predictivos podrían mejorarse mediante técnicas de cuantificación de la incertidumbre con mayores garantías de cobertura, como la predicción conformal adaptada a series temporales. Del mismo modo, la probabilidad empírica de contracción podría sustituirse o complementarse con modelos probabilísticos calibrados y evaluados mediante métricas específicas, como el Brier score y las curvas de calibración.

Cuando se disponga de información más desagregada, podrían construirse modelos diferenciados por ocupación, sector o territorio. Esto permitiría estudiar si la relación entre exposición tecnológica y evolución del empleo cambia según el tipo de actividad y evitaría que la agregación en grandes grupos oculte comportamientos heterogéneos.

Para aproximarse a una interpretación causal sería necesario conocer el momento, la intensidad y las características de la adopción efectiva de inteligencia artificial. Con esta información podrían aplicarse diseños cuasiexperimentales, como diferencias en diferencias o estudios de eventos, comparando empresas, sectores u ocupaciones con distintos niveles de adopción antes y después de la incorporación de estas tecnologías. Estos análisis requerirían comprobar cuidadosamente los supuestos de identificación y controlar otros cambios concurrentes.

El sistema de visualización también podría evolucionar hacia una aplicación desplegada en línea y conectada a un proceso de actualización controlado. Entre las posibles ampliaciones se encuentran la incorporación automática de nuevos trimestres del INE, la generación de alertas ante cambios relevantes, las comparaciones territoriales, la descarga de informes y la configuración interactiva de escenarios. Asimismo, sería conveniente añadir funciones para supervisar la calidad de los datos y la posible degradación del rendimiento predictivo.

Finalmente, el proyecto podría incorporar información sobre competencias profesionales y contenido de las tareas. El análisis conjunto de exposición, habilidades y necesidades formativas ayudaría a identificar qué grupos podrían beneficiarse de programas de formación y recualificación. Esta ampliación reforzaría la utilidad del sistema para apoyar la toma de decisiones de trabajadores, empresas, instituciones educativas y administraciones públicas.

La modificación principal está en el apartado predictivo: ya no se propone comparar ridge con Random Forest y Gradient Boosting porque esa comparación ya forma parte del trabajo. Las futuras líneas se orientan ahora hacia modelos temporales y jerárquicos, ensembles dinámicos, calibración probabilística y mejores métodos para cuantificar la incertidumbre.

Capítulo 8. REFERENCIAS

1. *OECD. (2023).* **OECD Employment Outlook 2023: Artificial Intelligence and the Labour Market. OECD Publishing.** (https://doi.org/10.1787/08785bba-en)

2. *Acemoglu, D., & Restrepo, P. (2018).* **Artificial Intelligence, Automation and Work. NBER Working Paper No. 24196.** (https://doi.org/10.3386/w24196)

3. *Instituto Nacional de Estadística. (2026*). **Encuesta de Población Activa. Primer trimestre 2026.** (https://www.ine.es/dyngs/Prensa/EPA1T26.htm)

4. *Gmyrek, P., Berg, J., & Bescond, D. (2023).* **Generative AI and Jobs: A Global Analysis of Potential Effects on Job Quantity and Quality* (ILO Working Paper No. 96).** (https://doi.org/10.54394/FHEM8239)

5. *Autor, D. H. (2015).* **Why Are There Still So Many Jobs? The History and Future of Workplace Automation. Journal of Economic Perspectives, 29(3), 3–30.** (https://doi.org/10.1257/jep.29.3.3)

6. *Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2023).* **GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models. arXiv.** (https://arxiv.org/abs/2303.10130)

7. *Felten, E. W., Raj, M., & Seamans, R. (2021).* **Occupational, industry, and geographic exposure to artificial intelligence: A novel dataset and its potential uses. Strategic Management Journal, 42(12), 2195–2217.** *(https://doi.org/10.1002/smj.3286)*

8. *Handa, K., Tamkin, A., McCain, M., Huang, S., Durmus, E., Heck, S., Mueller, J., Hong, J., Ritchie, S., Belonax, T., Troy, K. K., Amodei, D., Kaplan, J., Clark, J., & Ganguli, D. (2025).* **Which economic tasks are performed with AI? Evidence from millions of Claude conversations*. arXiv.*** (https://doi.org/10.48550/arXiv.2503.04761)

9. *Tolan, S., Pesole, A., Martínez-Plumed, F., Fernández-Macías, E., Hernández-Orallo, J., & Gómez, E. (2021*). **Measuring the occupational impact of AI: Tasks, cognitive abilities and AI benchmarks. Journal of Artificial Intelligence Research, 71, 191–236.** *(https://doi.org/10.1613/jair.1.12647)*

10. *Noy, S., & Zhang, W. (2023).* **Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence. Science, 381(6654), 187–192.** (https://doi.org/10.1126/science.adh2586)

11. *Brynjolfsson, E., Li, D., & Raymond, L. R. (2023).* **Generative AI at Work. NBER Working Paper No. 31161.** (https://doi.org/10.3386/w31161)

12. *World Economic Forum. (2025).* **The Future of Jobs Report 2025.** (https://www.weforum.org/publications/the-future-of-jobs-report-2025/)

13. *Cedefop. (2025).* **Skills Forecast.** (https://www.cedefop.europa.eu/en/tools/skills-forecast)

14. *Randstad Research. (2024).* **IA y mercado de trabajo en España.** (https://www.randstadresearch.es/ia-mercado-trabajo-espana/ia-mercado-de-trabajo-espana_1200x370/)

15. *Hyndman, R. J., & Athanasopoulos, G. (2021).* **Forecasting: Principles and Practice *(3rd ed.). OTexts*.** (https://otexts.com/fpp3/)

16. European Commission. (2025). Spain 2025 Digital Decade Country Report. (https://digital-strategy.ec.europa.eu/en/factpages/spain-2025-digital-decade-country-report)

17. *Hoerl, A. E., & Kennard, R. W. (1970).* **Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1), 55–67.** https://doi.org/10.1080/00401706.1970.10488634

18. *Zou, H., & Hastie, T. (2005).* **Regularization and variable selection via the elastic net. Journal of the Royal Statistical Society: Series B, 67(2), 301–320.** https://doi.org/10.1111/j.1467-9868.2005.00503.x

19. *Breiman, L. (2001).* **Random forests. Machine Learning, 45, 5–32.** https://doi.org/10.1023/A:1010933404324

20. *Friedman, J. H. (2001).* **Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232.** https://doi.org/10.1214/aos/1013203451

Capítulo 9. ANEXOS

Anexo A. Estructura y organización del proyecto

Este anexo presenta la estructura de directorios utilizada para organizar las fuentes de datos, los conjuntos de datos procesados, el código fuente, las herramientas de visualización y la documentación técnica generada durante el proyecto. La separación de estos componentes permite conservar la trazabilidad de las transformaciones y facilita la reproducción completa del análisis.

A.1 Estructura general del proyecto

La estructura principal del proyecto se organiza en cuatro directorios: data, scripts, dashboard y docs

```
TFM_MASTER/
|
+-- data/
|   +-- raw/
|   +-- processed/
|       +-- model_comparison/
|
+-- scripts/
+-- dashboard/
+-- docs/
+-- entregables/
+-- Visualizacion.pbix
+-- TFM Pedro Ariznavarreta.docx
```

Figura A.1. Estructura general de directorios del proyecto

Fuente: elaboración propia.

El directorio data/raw contiene los archivos originales obtenidos de las distintas fuentes. Estos documentos se conservan sin modificaciones, lo que permite contrastar los resultados procesados con la información de origen.

El directorio data/processed almacena las tablas limpias, las integraciones intermedias, el panel analítico, los resultados del backtesting, las previsiones, los indicadores de riesgo y las tablas preparadas para Microsoft Power BI. Dentro de este directorio, la carpeta model_comparison reúne los resultados de la comparación ampliada de modelos, el ajuste de hiperparámetros, las métricas de evaluación, la importancia de las variables y las previsiones generadas por el ensemble.

El directorio scripts contiene los programas desarrollados en Python:

- download_data.py: descarga las fuentes y registra el resultado de las operaciones.

- clean_and_link_data.py: limpia, valida, transforma e integra los conjuntos de datos.

- train_forecast_model.py: entrena y valida el modelo ridge, genera las predicciones y prepara las tablas iniciales para Power BI.

- enhanced_model_comparison.py: compara los modelos predictivos, selecciona sus hiperparámetros, realiza el backtesting común y genera las previsiones mediante un ensemble ponderado.

- run_full_pipeline.py: coordina la ejecución secuencial de las etapas de procesamiento y modelización.

El directorio dashboard contiene los archivos HTML, CSS y JavaScript utilizados para construir el dashboard web local. La aplicación carga los datos procesados desde archivos CSV y genera las visualizaciones directamente en el navegador.

El directorio docs reúne la documentación técnica del proyecto. Entre sus contenidos se encuentran la bitácora de datos, el registro de descargas, la guía de reproducibilidad, el análisis exploratorio, la auditoría del pipeline, la documentación del modelo predictivo, la comparación ampliada de modelos y las instrucciones de utilización de Power BI.

El directorio entregables se reserva para los documentos finales asociados al TFM. Además, el archivo Visualizacion.pbix contiene el informe interactivo elaborado en Microsoft Power BI.

Esta organización separa los datos originales, los archivos transformados, el código fuente, las visualizaciones y la documentación. Asimismo, permite actualizar las fuentes y volver a ejecutar el pipeline sin modificar manualmente los resultados intermedios.

A.2 Archivos originales

Los archivos originales utilizados durante el proyecto se almacenan en el directorio data/raw.

```
data/raw/
|
+-- ine_epa_ocupados_situacion_sexo_ocupacion_65136.csv
+-- ine_epa_ocupados_edad_sexo_ocupacion_65135.csv
+-- aioe_data_appendix.xlsx
+-- aioe_language_modeling.xlsx
+-- anthropic_job_exposure.csv
+-- anthropic_task_penetration.csv
```

A.2 Archivos originales almacenados en el directorio data/raw

Fuente: elaboración propia

Este directorio contiene dos tablas procedentes de la Encuesta de Población Activa del Instituto Nacional de Estadística, dos archivos asociados al índice de exposición ocupacional a la inteligencia artificial y dos conjuntos de datos de Anthropic relativos a la exposición laboral y a la penetración de la inteligencia artificial en las tareas.

Estos archivos se conservan sin modificaciones. Las operaciones de depuración, normalización e integración se realizan sobre las copias generadas en data/processed.

A.3 Archivos procesados

Los principales archivos generados durante la limpieza, integración, modelización y preparación de las visualizaciones se almacenan en data/processed.

```
data/processed/
|
+-- powerbi_fact_forecast_v2.csv
+-- powerbi_fact_risk_summary_v2.csv
+-- model_comparison/
    +-- ajuste_hiperparametros.csv
    +-- configuracion_modelos.json
    +-- importancia_variables_permutacion.csv
    +-- metricas_comparacion_modelos.csv
    +-- metricas_por_grupo_y_modelo.csv
    +-- predicciones_backtesting_todos_modelos.csv
    +-- previsiones_ensemble_8_trimestres.csv
    +-- figures/
        +-- comparacion_rmse_modelos.png
        +-- importancia_variables.png
```

Figura A.3. Principales archivos almacenados en el directorio data/processed

Fuente: elaboración propia.

Los archivos terminados en _clean.csv contienen las versiones depuradas y normalizadas de las fuentes originales. Durante esta fase se eliminaron registros duplicados, se normalizaron los códigos ocupacionales y se incorporaron validaciones automáticas sobre la cobertura temporal y la unicidad de las observaciones.

El archivo soc_ai_exposure_integrated.csv integra las fuentes de exposición ocupacional a la inteligencia artificial. A partir de esta información se genera cno_ai_exposure_proxy.csv, que adapta los indicadores disponibles a los diez grandes grupos de la Clasificación Nacional de Ocupaciones.

El archivo panel_ine_cno_ai_exposure.csv constituye el conjunto de datos principal del proyecto. Contiene 610 observaciones correspondientes a diez grandes grupos CNO y 61 trimestres comprendidos entre 2011T1 y 2026T1.

El archivo panel_ine_cno_forecast_backtest.csv contiene 80 predicciones fuera de muestra, correspondientes a diez grupos ocupacionales evaluados durante ocho trimestres. El archivo cno_future_risk_summary.csv resume los indicadores predictivos y de riesgo por grupo ocupacional.

La carpeta model_comparison contiene los resultados de la comparación de ocho alternativas: crecimiento cero, persistencia trimestral, regresión lineal, ridge, elastic net, random forest, gradient boosting y ensemble ponderado. Todos los modelos se evaluaron sobre los mismos ocho trimestres, comprendidos entre 2024T1 y 2025T4, mediante backtesting walk-forward.

El archivo previsiones_ensemble_8_trimestres.csv contiene 80 previsiones: diez grupos CNO para ocho horizontes trimestrales, desde 2026T2 hasta 2028T1. Estas previsiones parten de la información disponible en 2026T1.

Los archivos powerbi_dim_cno.csv, powerbi_fact_employment_history.csv, powerbi_fact_forecast_v2.csv y powerbi_fact_risk_summary_v2.csv forman el modelo de datos actualizado utilizado en Power BI. Las versiones v2 incorporan las predicciones individuales de random forest, gradient boosting y ridge, además del resultado combinado del ensemble.

La estructura adoptada permite identificar el origen, las transformaciones y el destino de cada resultado, además de reproducir las principales etapas del análisis mediante la ejecución automatizada del pipeline.

Anexo B. Diccionario de variables

Este anexo describe las principales variables del panel analítico, del backtesting, de la comparación de modelos y de las predicciones futuras. El proyecto evalúa cinco modelos predictivos, dos modelos de referencia y un ensemble ponderado.

B.1 Variables del panel analítico

El archivo panel_ine_cno_ai_exposure.csv constituye el conjunto de datos principal. Contiene 610 observaciones correspondientes a diez grandes grupos CNO y 61 trimestres comprendidos entre 2011T1 y 2026T1. Su clave lógica está formada por cno_major y periodo.

Las variables periodo, period_date, year y quarter identifican temporalmente las observaciones. cno_major y cno_title contienen el código y la denominación del grupo ocupacional.

El empleo se expresa mediante employment_thousand_people, en miles de personas. employment_qoq_pct representa la variación respecto al trimestre anterior y employment_yoy_pct, la variación respecto al mismo trimestre del año anterior.

Las variables mapped_soc_majors y mapped_soc_occupations documentan la correspondencia agregada entre los grupos CNO y las ocupaciones SOC.

La exposición a la inteligencia artificial se representa mediante aioe_score_cno_proxy, language_modeling_aioe_score_cno_proxy y anthropic_observed_exposure_cno_proxy. Sus correspondientes percentiles se almacenan en aioe_percentile_cno_proxy, language_modeling_percentile_cno_proxy y anthropic_percentile_cno_proxy.

La variable ai_exposure_category clasifica la exposición relativa como baja, media, alta o sin categoría. Estas medidas permiten comparar grupos ocupacionales, pero no representan probabilidades de automatización ni porcentajes de puestos de trabajo que vayan a desaparecer.

employment_growth_next_quarter_pct contiene el crecimiento observado del empleo en el trimestre siguiente y constituye la variable objetivo del modelado.

B.2 Variables utilizadas en el modelado

Para el modelado se generaron variables que representan la evolución del empleo, la tendencia temporal, la estacionalidad y su interacción con la exposición a la inteligencia artificial.

ai_exposure_score y anthropic_exposure_score expresan los percentiles de exposición en una escala de 0 a 1. employment_log es la transformación logarítmica del empleo y time_index representa la tendencia temporal.

Las variables quarter_sin y quarter_cos representan la estacionalidad trimestral. interaction_qoq_ai y interaction_yoy_ai combinan la exposición a modelos de lenguaje con las variaciones trimestral e interanual del empleo.

Estas variables se utilizaron para comparar regresión lineal, ridge, elastic net, random forest y gradient boosting. También se incluyeron los baselines de crecimiento cero y persistencia trimestral.

El archivo panel_ine_cno_forecast_backtest.csv conserva los resultados de la primera experimentación con ridge. Se mantiene como resultado auxiliar, pero no constituye la evaluación definitiva del proyecto.

B.3 Backtesting y comparación de modelos

La comparación principal se almacena en predicciones_backtesting_todos_modelos.csv. Contiene 640 registros: 80 observaciones fuera de muestra evaluadas mediante ocho alternativas.

El backtesting comprende los ocho trimestres situados entre 2024T1 y 2025T4. En cada trimestre, los modelos se entrenaron exclusivamente con información anterior al periodo evaluado.

Las variables periodo, period_date, cno_major y cno_title identifican la observación. actual contiene el crecimiento real, modelo identifica la alternativa evaluada y prediccion recoge el crecimiento estimado.

El archivo metricas_comparacion_modelos.csv contiene el RMSE, el MAE, el R^2 y la mejora respecto al baseline de crecimiento cero. Random forest obtuvo el menor RMSE, seguido de gradient boosting y del ensemble ponderado.

El archivo metricas_por_grupo_y_modelo.csv desglosa los resultados por grupo ocupacional. ajuste_hiperparametros.csv registra las configuraciones evaluadas e importancia_variables_permutacion.csv contiene la importancia predictiva de las variables.

B.4 Predicciones futuras

Las predicciones definitivas se generaron mediante un ensemble ponderado formado por random forest, gradient boosting y ridge. Los pesos se calcularon de manera inversamente proporcional al RMSE obtenido por cada modelo durante la validación.

Los resultados se almacenan en previsiones_ensemble_8_trimestres.csv y powerbi_fact_forecast_v2.csv. Ambos archivos contienen 80 predicciones: diez grupos CNO para ocho horizontes, desde 2026T2 hasta 2028T1.

forecast_origin_period identifica el último trimestre observado y forecast_horizon_quarters indica el horizonte de predicción. forecast_period y forecast_period_date identifican el trimestre previsto.

prediction_random_forest_pct, prediction_gradient_boosting_pct y prediction_ridge_pct contienen las predicciones individuales. predicted_growth_pct representa la combinación ponderada de los tres modelos y predicted_employment_thousand_people contiene el empleo resultante.

prediction_lower_90_pct y prediction_upper_90_pct delimitan un intervalo predictivo aproximado del 90 %, calculado a partir de los errores del backtesting.

contraction_probability estima empíricamente la probabilidad de que el crecimiento sea inferior a cero. exposure_weighted_risk_thousand y risk_index combinan el empleo, la probabilidad de contracción y la exposición relativa. risk_category clasifica comparativamente los grupos como de riesgo bajo, medio o alto.

El archivo powerbi_fact_risk_summary_v2.csv contiene estas variables para el primer horizonte, correspondiente a 2026T2.

Los indicadores de riesgo sirven exclusivamente para comparar y priorizar grupos ocupacionales. No representan previsiones de despidos, empleos automatizados o puestos de trabajo que vayan a desaparecer. Las predicciones tampoco demuestran una relación causal entre la inteligencia artificial y la evolución del empleo.

Anexo C. Correspondencia agregada entre los grandes grupos CNO-11 y SOC

Este anexo presenta la correspondencia utilizada para integrar los datos de empleo de la Encuesta de Población Activa con los indicadores internacionales de exposición a la inteligencia artificial.

Los datos laborales españoles se organizan mediante la Clasificación Nacional de Ocupaciones de 2011 (CNO-11), mientras que AIOE y el Anthropic Economic Index utilizan la clasificación estadounidense SOC. Debido a que ambas clasificaciones presentan estructuras y niveles de detalle diferentes, no fue posible realizar una equivalencia directa entre sus códigos.

Por este motivo, se construyó una correspondencia agregada basada en la proximidad conceptual entre las familias ocupacionales de ambas clasificaciones.

Gran grupo CNO	Denominación resumida	Grandes grupos SOC asignados	Ocupaciones SOC utilizadas
0	Ocupaciones militares	55	0
1	Directores y gerentes	11	33
2	Profesionales científicos e intelectuales	15, 17, 19, 23, 25, 27 y 29	258
3	Técnicos y profesionales de apoyo	13, 21, 27 y 29	141
4	Empleados administrativos y de oficina	43	52
5	Trabajadores de servicios y vendedores	31, 33, 35, 37, 39 y 41	113
6	Trabajadores cualificados del sector agrícola	45	13
7	Artesanos, industria y construcción	47, 49 y 51	211
8	Operadores de instalaciones y maquinaria	51 y 53	151
9	Ocupaciones elementales	35, 37, 45 y 53	85

Tabla C.1. Correspondencia agregada entre los grandes grupos CNO-11 y SOC

Fuente: elaboración propia a partir de las clasificaciones CNO-11 y SOC.

C.1 Criterio de correspondencia

La asignación se realizó atendiendo a la similitud general entre las familias profesionales. Por ejemplo, el grupo CNO 1, correspondiente a directores y gerentes, se relacionó con el gran grupo SOC 11, que reúne ocupaciones de gestión. El grupo CNO 2 se vinculó con familias SOC relacionadas con informática, ingeniería, ciencias, educación, derecho, salud y comunicación.

Algunos grandes grupos SOC aparecen asociados a más de un grupo CNO. Esto sucede porque ambas clasificaciones delimitan las familias profesionales de manera diferente. Por ejemplo, el grupo SOC 51 participa en los grupos CNO 7 y 8, mientras que los grupos SOC 35 y 37 aparecen en los grupos CNO 5 y 9.

Estos solapamientos no generan duplicados dentro de cada grupo CNO, ya que cada ocupación SOC se contabiliza una sola vez al calcular la exposición del grupo correspondiente. Sin embargo, una misma ocupación SOC puede contribuir a la estimación de varios grupos CNO.

C.2 Número de ocupaciones y asignaciones

El conjunto de AIOE utilizado contiene 774 ocupaciones SOC únicas. La suma de las ocupaciones asociadas a los diferentes grupos CNO asciende a 1.057 asignaciones. La diferencia se debe a los solapamientos existentes en la correspondencia.

Por tanto, deben distinguirse los siguientes conceptos:

- 774 ocupaciones SOC únicas: número de ocupaciones diferentes disponibles en AIOE.

- 1.057 asignaciones CNO–SOC: suma de las ocupaciones utilizadas por los distintos grupos CNO, incluyendo los solapamientos.

Las 1.057 asignaciones no representan 1.057 ocupaciones diferentes.

C.3 Agregación de la exposición

Para calcular la exposición de cada gran grupo CNO se seleccionaron las ocupaciones pertenecientes a los grandes grupos SOC asignados. Antes de realizar el cálculo se eliminaron los posibles códigos SOC duplicados, de manera que cada ocupación se contabilizara una sola vez dentro de cada grupo CNO.

La exposición agregada se calculó mediante la media aritmética de las puntuaciones válidas de las ocupaciones SOC únicas:

$$\text{Exposición}_c^{(k)} = \frac{1}{N_c^{(k)}} \sum_{j=1}^{N_c^{(k)}} \text{Exposición}_j^{(k)}$$

donde E_c^k representa la exposición agregada del grupo CNO c para el indicador k; N_c^k es el número de ocupaciones SOC únicas con una puntuación válida; y E_j^k es la puntuación correspondiente a la ocupación SOC j.

El cálculo se realizó independientemente para la exposición general AIOE, la exposición específica a modelos de lenguaje y la exposición laboral observada de Anthropic.

Este procedimiento asigna el mismo peso a cada ocupación SOC incluida en el grupo. No se calcularon primero medias por gran grupo SOC, ya que ese procedimiento habría otorgado el mismo peso a familias SOC con distinto número de ocupaciones..

C.4 Tratamiento de las ocupaciones militares

El grupo CNO 0 se relacionó conceptualmente con el gran grupo SOC 55, correspondiente a las ocupaciones militares. Sin embargo, el archivo AIOE utilizado no contiene observaciones disponibles para este grupo SOC.

Por esta razón, no se calculó una puntuación de exposición para las ocupaciones militares. Las variables de exposición, sus percentiles y la categoría de exposición se mantuvieron como valores ausentes.

No se aplicó ninguna imputación, ya que hacerlo habría supuesto atribuir al grupo una exposición sin respaldo en los datos originales. En las visualizaciones, esta ausencia debe mostrarse como «sin datos» o «sin categoría», sin interpretarla como una exposición baja o nula.

C.5 Limitaciones de la correspondencia

La correspondencia presentada constituye una aproximación metodológica y no una tabla de equivalencias oficial. Su utilización permite relacionar fuentes con clasificaciones diferentes a escala agregada, pero implica varias limitaciones:

- los grandes grupos contienen ocupaciones heterogéneas;

- algunas familias SOC se asignan a más de un grupo CNO;

- la exposición media puede ocultar diferencias entre ocupaciones concretas;

- los resultados no deben trasladarse automáticamente a perfiles profesionales individuales.

En consecuencia, la correspondencia resulta adecuada para realizar comparaciones exploratorias entre grandes grupos ocupacionales, pero no para establecer equivalencias exactas entre ocupaciones CNO-11 y SOC.

Anexo D. Fuentes y registro de descargas

Este anexo recoge las fuentes de datos utilizadas, su finalidad dentro del proyecto y el resultado del proceso automatizado de adquisición. Las descargas se realizaron mediante el programa download_data.py, que registra cada operación en el archivo docs/download_log.csv.

D.1 Fuentes incorporadas al proyecto

Fuente	Institución o autor	Archivo local	Finalidad
EPA: ocupados por situación profesional, sexo y ocupación	Instituto Nacional de Estadística	ine_epa_ocupados_situacion_sexo_ocupacion_65136.csv	Construcción del histórico trimestral de empleo por gran grupo CNO.
EPA: ocupados por edad, sexo y ocupación	Instituto Nacional de Estadística	ine_epa_ocupados_edad_sexo_ocupacion_65135.csv	Información complementaria sobre la composición del empleo.
AIOE Data Appendix	Felten, Raj y Seamans	aioe_data_appendix.xlsx	Puntuación general de exposición ocupacional a la inteligencia artificial.
Language Modeling AIOE	AIOE	aioe_language_modeling.xlsx	Exposición ocupacional específica a modelos de lenguaje.
Anthropic Job Exposure	Anthropic Economic Index	anthropic_job_exposure.csv	Exposición observada a la IA por ocupación SOC.
Anthropic Task Penetration	Anthropic Economic Index	anthropic_task_penetration.csv	Penetración observada de la IA por tarea.
BLS Skills Data	Bureau of Labor Statistics	No incorporado	Fuente complementaria de habilidades y proyecciones de empleo.

Tabla D.1. Fuentes de datos utilizadas o evaluadas durante el proyecto

Fuente: elaboración propia a partir del registro de descargas.

D.2 Direcciones de descarga

Las direcciones registradas para las fuentes incorporadas fueron las siguientes:

- INE-EPA, tabla 65136:

https://www.ine.es/jaxiT3/files/t/csv_bdsc/65136.csv

- INE-EPA, tabla 65135:

https://www.ine.es/jaxiT3/files/t/csv_bdsc/65135.csv

- AIOE Data Appendix:

https://github.com/AIOE-Data/AIOE/raw/main/AIOE_DataAppendix.xlsx

- Language Modeling AIOE:

https://github.com/AIOE-Data/AIOE/raw/main/Language%20Modeling%20AIOE%20and%20AIIE.xlsx

- Anthropic Job Exposure:

https://huggingface.co/datasets/Anthropic/EconomicIndex/resolve/main/labor_market_impacts/job_exposure.csv

- Anthropic Task Penetration:

https://huggingface.co/datasets/Anthropic/EconomicIndex/resolve/main/labor_market_impacts/task_penetration.csv

Las direcciones pueden cambiar como consecuencia de modificaciones realizadas por las entidades proveedoras. Por ello, se conservaron localmente los archivos utilizados para generar los resultados del TFM.

D.3 Resumen del registro de descargas

La descarga inicial se efectuó el 1 de mayo de 2026. Las seis fuentes principales se descargaron correctamente y se incorporaron al proyecto. La descarga de BLS Skills Data devolvió un error HTTP 403, que indicaba el rechazo de la petición automatizada por parte del servidor. La incidencia se conservó en el registro, pero el archivo no se incorporó a data/raw ni se utilizó durante el análisis:

Fuente	Estado	Tamaño registrado	Resultado
INE–EPA, tabla 65136	Correcto	2.082.274 bytes	Archivo descargado e incorporado.
INE–EPA, tabla 65135	Correcto	2.461.355 bytes	Archivo descargado e incorporado.
AIOE Data Appendix	Correcto	170.359 bytes	Archivo descargado e incorporado.
Language Modeling AIOE	Correcto	55.714 bytes	Archivo descargado e incorporado.
Anthropic Job Exposure	Correcto	37.176 bytes	Archivo descargado e incorporado.
Anthropic Task Penetration	Correcto	1.889.822 bytes	Archivo descargado e incorporado.
BLS Skills Data	Error	0 bytes	Descarga rechazada mediante HTTP 403.

Tabla D.2. Resumen del resultado de las descargas automatizadas

Fuente: elaboración propia a partir de docs/download_log.csv.

Las seis fuentes principales se descargaron correctamente. La fuente BLS Skills Data devolvió un error HTTP 403 (Forbidden), que indicaba el rechazo de la petición automatizada por parte del

servidor. La incidencia se conservó en el registro, pero el archivo no se integró ni se utilizó en el análisis.

D.4 Estructura del registro

El archivo docs/download_log.csv contiene los siguientes campos:

Campo	Descripción
`timestamp`	Fecha y hora de la operación.
`name`	Identificador interno de la fuente.
`source`	Institución o entidad responsable.
`url`	Dirección utilizada para realizar la descarga.
`filename`	Ruta y nombre del archivo de destino.
`status`	Resultado de la operación: correcto o error.
`bytes`	Tamaño del archivo descargado.
`purpose`	Finalidad prevista dentro del proyecto.
`error`	Descripción de la incidencia, cuando corresponde.

Tabla D.3. Tabla de logs

Fuente: elaboración propia.

Tabla D.3. Campos incluidos en el registro de descargas

Fuente: elaboración propia.

El registro permite comprobar la procedencia de los archivos, conocer el resultado de cada operación y conservar información sobre las incidencias producidas durante el proceso de adquisición.

D.5 Conservación de los datos originales

Los seis archivos descargados correctamente se almacenaron en data/raw y se conservaron sin modificaciones. Las operaciones de limpieza, integración y modelado se realizaron en memoria y sus resultados se exportaron como nuevos archivos en data/processed.

Esta separación permite contrastar los resultados procesados con las fuentes originales y volver a ejecutar las transformaciones cuando sea necesario. El proceso de descarga se mantiene separado del pipeline ordinario para evitar que los datos originales se sobrescriban automáticamente cada vez que se ejecutan los modelos.

Anexo E. Guía de reproducibilidad

El proyecto puede reproducirse desde un ordenador con Windows y Python instalado. Los archivos deben conservarse dentro de la estructura original de carpetas.

El procedimiento es el siguiente:

1. Abrir una terminal en la carpeta raíz TFM_MASTER.

2. Descargar o actualizar las fuentes:

python scripts/download_data.py

3. Revisar el resultado en:

docs/download_log.csv

4. Ejecutar la limpieza, la integración, la comparación de modelos y la generación de predicciones:

python scripts/run_full_pipeline.py

5. Comprobar los resultados generados en data/processed.

6. Iniciar el dashboard web:

python -m http.server 8000

7. Abrir en el navegador:

http://localhost:8000/dashboard/

8. Para actualizar Power BI, abrir Visualizacion.pbix y seleccionar Actualizar.

El proceso de descarga se ejecuta por separado para evitar que los datos originales se sobrescriban accidentalmente. Si alguna validación falla, el pipeline se detiene antes de generar nuevos resultados.

Anexo F. Resultados de la comparación de modelos y de las predicciones

Este anexo presenta los resultados completos de la comparación de modelos y las predicciones generadas para los diez grandes grupos CNO.

La evaluación se realizó mediante un backtesting walk-forward sobre los ocho trimestres comprendidos entre 2024T1 y 2025T4. En cada trimestre se utilizaron exclusivamente observaciones anteriores al periodo evaluado.

Se compararon cinco modelos predictivos —regresión lineal, ridge, elastic net, random forest y gradient boosting—, dos modelos de referencia —crecimiento cero y persistencia trimestral— y un ensemble ponderado.

F.1 Resultados de la comparación de modelos

La siguiente tabla presenta las métricas obtenidas sobre las 80 observaciones fuera de muestra.

Modelo	RMSE	MAE	R^2	Mejora frente a crecimiento cero
Random forest	2,393	1,874	0,143	9,41 %
Gradient boosting	2,415	1,929	0,127	8,59 %
Ensemble ponderado	2,429	1,943	0,116	8,04 %
Ridge	2,544	2,051	0,031	3,70 %
Elastic net	2,557	2,065	0,021	3,20 %
Regresión lineal	2,633	2,161	−0,038	0,31 %
Crecimiento cero	2,641	2,089	−0,045	0,00 %
Persistencia trimestral	4,201	3,235	−1,643	−59,05 %

Tabla F.1. Resultados de la comparación de modelos

Fuente: elaboración propia a partir del backtesting walk-forward.

Random forest obtuvo el menor RMSE y el mayor R^2 fuera de muestra. No obstante, las predicciones futuras se generaron mediante un ensemble ponderado para evitar que los resultados dependieran de una única especificación.

El ensemble combina random forest, gradient boosting y ridge con unos pesos aproximados del 33,8 %, 33,4 % y 32,8 %, respectivamente. Estos pesos se calcularon de forma inversamente proporcional al RMSE obtenido por cada modelo durante la validación.

F.2 Predicciones para el primer horizonte

El último periodo observado es 2026T1. La siguiente tabla presenta las predicciones del ensemble para 2026T2, correspondiente al horizonte T+1.

Grupo CNO	Exposición	Crecimiento previsto	Probabilidad de contracción
Trabajadores de servicios y vendedores	Media	1,836 %	23,2 %
Ocupaciones elementales	Media	1,408 %	32,9 %
Profesionales científicos e intelectuales	Alta	1,384 %	32,9 %
Directores y gerentes	Alta	1,257 %	35,4 %
Técnicos y profesionales de apoyo	Alta	1,231 %	35,4 %
Empleados administrativos	Alta	1,161 %	35,4 %
Operadores de instalaciones y maquinaria	Media	1,156 %	35,4 %
Artesanos, industria y construcción	Baja	1,001 %	36,6 %
Trabajadores cualificados agrícolas	Baja	0,687 %	45,1 %
Ocupaciones militares	Sin categoría	0,512 %	47,6 %

Fuente: elaboración propia a partir de las predicciones del ensemble ponderado.

Todos los grupos presentan un crecimiento central positivo en T+1. Sin embargo, los límites inferiores de los intervalos predictivos del 90 % son negativos en todos los casos. Por tanto, las estimaciones no permiten descartar una contracción del empleo.

La probabilidad de contracción no depende únicamente del valor central de la predicción, sino también de la distribución empírica de los errores observados durante el backtesting.

F.3 Evolución agregada prevista

Las predicciones se generaron recursivamente para ocho horizontes, desde 2026T2 hasta 2028T1. En cada horizonte posterior al primero, el empleo previsto en el trimestre anterior se utiliza como punto de partida.

Horizonte	Periodo	Empleo previsto	Variación acumulada
T+1	2026T2	22.596,1 miles	1,36 %
T+2	2026T3	22.792,7 miles	2,24 %
T+3	2026T4	22.841,7 miles	2,46 %
T+4	2027T1	22.828,9 miles	2,40 %
T+5	2027T2	23.136,8 miles	3,79 %
T+6	2027T3	23.354,5 miles	4,76 %
T+7	2027T4	23.412,0 miles	5,02 %
T+8	2028T1	23.408,2 miles	5,00 %

Tabla F.3. Evolución agregada del empleo prevista entre T+1 y T+8

Fuente: Elaboración propia

El empleo agregado de partida en 2026T1 asciende a 22.292,8 miles de personas. El escenario central estima 23.408,2 miles en 2028T1, lo que representa una variación acumulada aproximada del 5,00 %.

La trayectoria no es completamente lineal: se observan ligeros descensos agregados en 2027T1 y 2028T1 respecto a los trimestres inmediatamente anteriores. Estas variaciones proceden de la dinámica recursiva, la tendencia y la estacionalidad incorporadas por los modelos.

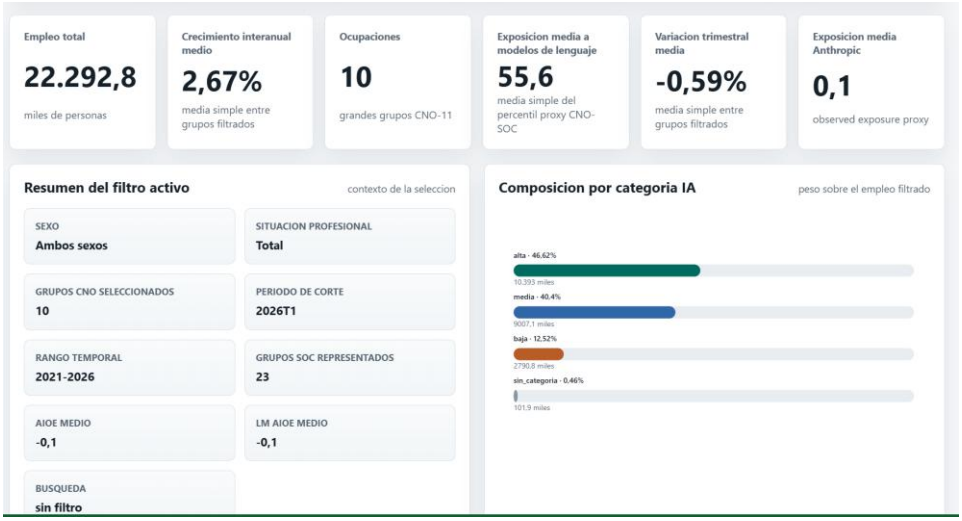
F.4 Interpretación de los resultados

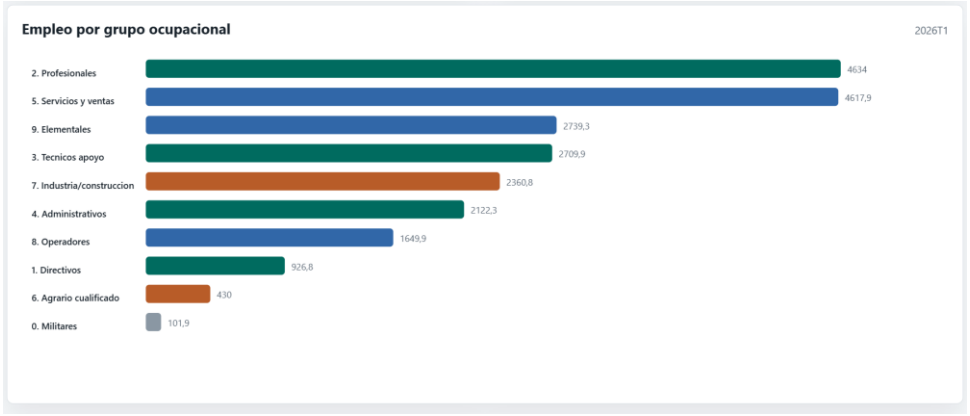
Los resultados deben interpretarse como escenarios predictivos exploratorios. El rendimiento de los modelos mejora el baseline de crecimiento cero, pero la magnitud de la mejora es moderada y los intervalos predictivos reflejan una incertidumbre considerable.

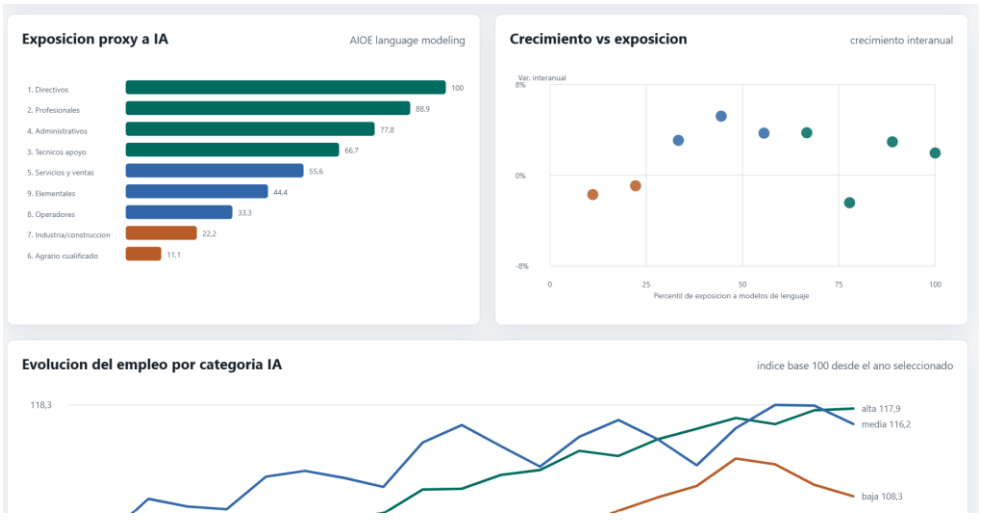
Las estimaciones no constituyen predicciones causales del efecto de la inteligencia artificial. Tampoco representan cifras esperadas de despidos, empleos automatizados o puestos de trabajo que vayan a desaparecer.

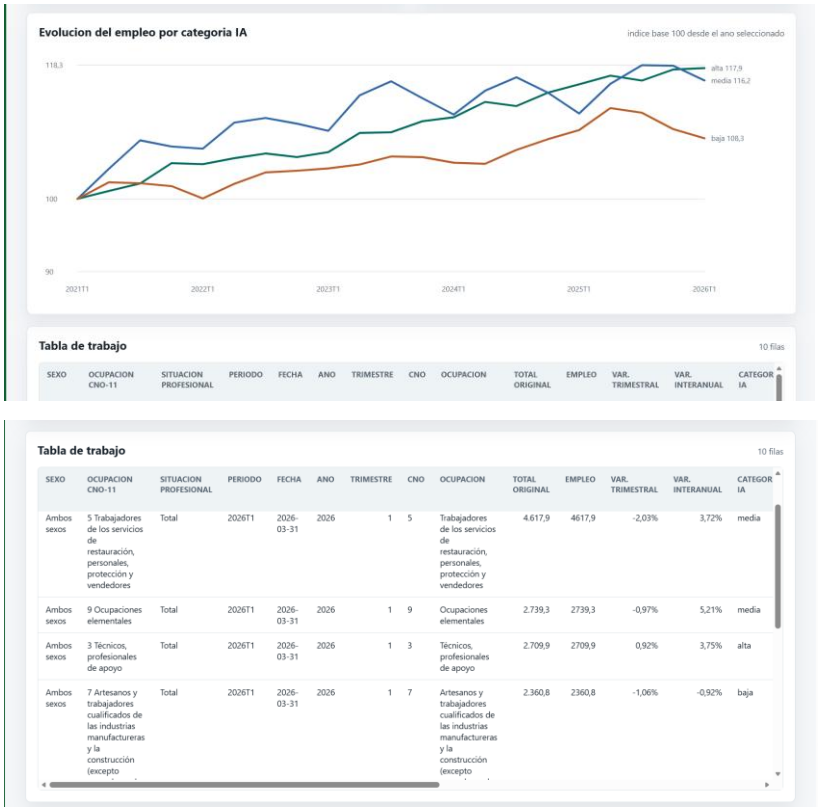
Los indicadores de exposición y riesgo permiten comparar y priorizar grandes grupos ocupacionales, pero no deben utilizarse para realizar inferencias sobre trabajadores, profesiones concretas o decisiones individuales.

Anexo G. Capturas de las herramientas de visualización


Empleo total
22.292,8
miles de personas
Crecimiento interanual medio
2,67%
media simple entre grupos filtrados
Ocupaciones
10
grandes grupos CNO-11
Exposicion media a modelos de lenguaje
55,6
media simple del percentil proxy CNO-SOC
Variacion trimestral media
-0,59%
media simple entre grupos filtrados
Exposicion media Anthropic
0,1
observed exposure proxy
Resumen del filtro activo
contexto de la seleccion
SEXO
Ambos sexos
SITUACION PROFESIONAL
Total
GRUPOS CNO SELECCIONADOS
10
PERIODO DE CORTE
2026T1
RANGO TEMPORAL
2021-2026
GRUPOS SOC REPRESENTADOS
23
AIOE MEDIO
-0,1
LM AIOE MEDIO
-0,1
BUSQUEDA
sin filtro
Composicion por categoria IA
peso sobre el empleo filtrado
alta · 46.62%
10.393 miles
media · 40.4%
9007,1 miles
baja · 12.52%
2790,8 miles
sin_categoria · 0.46%
101,9 miles


Empleo por grupo ocupacional
2026T1
2. Profesionales 4634
5. Servicios y ventas 4617,9
9. Elementales 2739,3
3. Tecnicos apoyo 2709,9
7. Industria/construccion 2360,8
4. Administrativos 2122,3
8. Operadores 1649,9
1. Directivos 926,8
6. Agrario cualificado 430
0. Militares 101,9


Exposicion proxy a IA
AIOE language modeling
1. Directivos 100
2. Profesionales 88,9
4. Administrativos 77,8
3. Tecnicos apoyo 66,7
5. Servicios y ventas 55,6
9. Elementales 44,4
8. Operadores 33,3
7. Industria/construccion 22,2
6. Agrario cualificado 11,1
Crecimiento vs exposicion
crecimiento interanual
Var. interanual
8%
0%
-8%
0
25
50
75
100
Percentil de exposicion a modelos de lenguaje
Evolucion del empleo por categoria IA
indice base 100 desde el ano seleccionado
118,3
alta 117,9
media 116,2
baja 108,3



Anexo H. Validaciones y controles de calidad

Durante el procesamiento se aplicaron controles automáticos para evitar que las etapas posteriores se ejecutaran a partir de datos incompletos, duplicados o estructuralmente inconsistentes.

Las validaciones automáticas comprueban:

- La presencia de los diez grandes grupos CNO.

- La unicidad de la combinación formada por cno_major y periodo.

- La ausencia de códigos SOC duplicados en la tabla integrada de exposición.

- La existencia de un único registro de exposición para cada gran grupo CNO.

- La eliminación de duplicados exactos en los datos de tareas de Anthropic.

- La igualdad de la cobertura temporal entre los grupos CNO.

Si alguna de estas condiciones no se cumple, el programa genera un error y el pipeline se detiene antes de ejecutar las etapas posteriores.

Además de las validaciones automáticas, durante la auditoría del proyecto se realizaron las siguientes comprobaciones:

- El panel contiene 610 observaciones, correspondientes a diez grupos CNO y 61 trimestres.

- Todos los grupos presentan una cobertura temporal comprendida entre 2011T1 y 2026T1.

- El empleo agregado en 2026T1 asciende a 22.292,8 miles de personas.

- Los registros se encuentran ordenados cronológicamente dentro de cada grupo ocupacional.

- Los archivos originales se conservan sin modificaciones en data/raw.

- Las transformaciones se exportan como nuevos archivos en data/processed.

- El backtesting contiene 80 observaciones fuera de muestra por cada modelo evaluado.

- La comparación ampliada contiene 640 predicciones, correspondientes a 80 observaciones evaluadas mediante ocho alternativas.

- Las predicciones futuras incluyen diez grupos CNO y ocho horizontes, desde 2026T2 hasta 2028T1.

- Las tablas powerbi_fact_forecast_v2.csv y powerbi_fact_risk_summary_v2.csv contienen las variables necesarias para actualizar el informe de Power BI.

El pipeline ejecuta secuencialmente la limpieza e integración de los datos, el modelo ridge inicial y la comparación ampliada de modelos. Si uno de los programas finaliza con un error, las etapas siguientes no se ejecutan.

Estos controles mejoran la trazabilidad y reproducibilidad del proyecto, pero no eliminan las limitaciones derivadas de la correspondencia agregada entre CNO y SOC, del carácter internacional y estático de los indicadores de exposición ni de la incertidumbre asociada a las predicciones futuras.

[PÁGINA INTENCIONADAMENTE EN BLANCO]